第二章　随机变量及其分布

郭永江

1　随机变量与分布函数

1.1　随机变量的概念

一、从函数的角度理解随机变量

在微积分中，我们学过函数的概念：设 D 是一个实数集合，若对每个 $x \in D$，都有唯一确定的实数 y 与之对应，则称 y 是 x 的函数，记作

$$y = f(x), \qquad x \in D.$$

这里的自变量 x 是一个实数，因变量 y 也是一个实数。函数的本质是**一个对应规则**：给定一个输入，输出唯一确定的结果。

在概率论中，随机变量也是函数，但它的“输入”和“输出”与微积分中的函数有所不同：

- 微积分中的函数：输入是实数 x，输出是实数 $y = f(x)$；
- 概率论中的随机变量：输入是样本点 ω，输出是实数 $X(\omega)$。

也就是说，随机变量是**定义在样本空间 Ω 上的实值函数**。为了便于理解，先看下面的示意图。

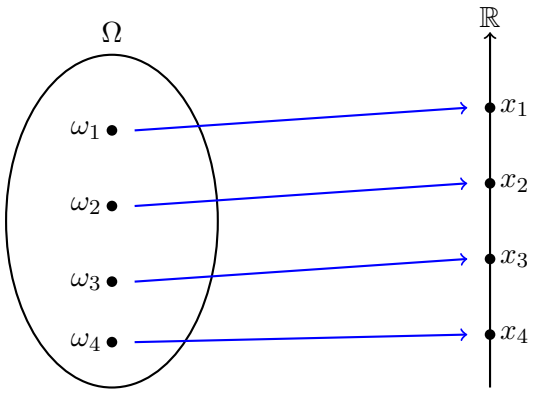


图 1: 随机变量是把样本空间 Ω 中的每个样本点 ω 映射为实数 $X(\omega)$ 的函数。

从图 1 可以看出：随机变量 X 的定义域是样本空间 Ω，值域是实数轴 $\mathbb{R}$ 的一个子集。对每个样本点 ω，X 赋予它一个实数 $X(\omega)$。

二、引入随机变量的必要性

在第一章中，我们用样本空间和事件来描述随机现象。例如，抛一枚硬币两次，样本空间为

$$S = \{HH, HT, TH, TT\}.$$

如果要研究“正面出现的次数”，就必须先定义事件：

$$A_0 = \{TT\}, \qquad A_1 = \{HT, TH\}, \qquad A_2 = \{HH\}.$$

这里 A_k 表示“正面恰好出现 k 次”这一事件。若要计算“正面出现次数不超过 1 次”的概率，就要计算

$$P(A_0 \cup A_1).$$

这种用事件来描述随机现象的方法虽然严谨，但不便于进行数学运算，尤其是当试验结果较多时，用事件语言表达会显得繁琐。

引入随机变量之后，上述问题可以大大简化。例如，定义

$$X = \{\text{正面出现的次数}\},$$

则

$$\{X = 0\} = \{TT\}, \qquad \{X = 1\} = \{HT, TH\}, \qquad \{X = 2\} = \{HH\}.$$

“正面出现次数不超过 1 次”就可以写成

$$\{X \le 1\} = \{X = 0\} \cup \{X = 1\},$$

其概率为

$$P(X \le 1) = P(X = 0) + P(X = 1).$$

这样，就**把事件的语言转化成了数的语言**，可以利用函数的性质来研究随机现象。

三、引入随机变量的好处

引入随机变量有以下三个主要好处：

(1) **把随机现象数量化**：随机变量的取值是实数，这样就可以用数学分析、微积分等工具来研究随机现象。

(2) **简化事件的表示**：许多复杂的事件可以用随机变量的等式或不等式来表示，例如 $\{X \le x\}$、$\{a < X \le b\}$ 等。

(3) **统一描述概率规律**：无论随机试验的具体内容如何，只要知道了随机变量的分布函数 $F(x) = P(X \le x)$，就完整地掌握了这个随机变量的概率规律。

四、随机变量的定义

定义 1.1 (随机变量的定义)**.** 设 X 是定义在样本空间 Ω 上、取值于实数轴 $\mathbb{R}$ 的函数，$X:\Omega\to\mathbb{R}$，且要求：**对任意实数 x，区间 $(-\infty,x]$ 的原像**

$$X^{-1}\big((-\infty,x]\big)=\{\omega\in\Omega:X(\omega)\le x\}$$

是事件，也就是 $\{X\le x\}$ 是事件，则称 X **为随机变量**，简记为 X。

从定义可以看出，随机变量本质上是定义在样本空间上的**实值函数**。它的自变量是样本点（可以是数，也可以不是数），因变量是实数。

注 1.1 (用逆映射理解随机变量)**.** 事实上，随机变量还有更一般、更严格的描述方式。设 X 是定义在样本空间 Ω 上、取值于实数轴 $\mathbb{R}$ 的函数，即 $X:\Omega\to\mathbb{R}$，并进一步要求：**对任意实数集合 $B\subset\mathbb{R}$，它的原像**

$$X^{-1}(B)=\{\omega\in\Omega:X(\omega)\in B\}$$

都必须是事件（即属于事件域 $\mathcal{F}$）。满足这一要求的函数 X 才称为随机变量。

用逆映射的语言说，随机变量 X 的作用就是把实数轴上的任意集合 B“拉回”到样本空间，得到事件 $X^{-1}(B)$。这样一来，原本定义在样本空间上的随机现象，就可以借助实数集上的集合运算和分析工具来研究，这正是引入随机变量的核心意义。

那么为什么在正式定义中，只要求形如 $(-\infty,x]$ 的区间之原像是事件呢？原因在于：实数轴上的任意集合都可以由形如 $(-\infty,x]$ 的区间通过有限次或可数次交、并、补运算得到，而事件域 $\mathcal{F}$ 对这些运算又是封闭的。因此，只要对每个实数 x 都保证 $\{X\le x\}$ 是事件，就能保证对一切实数集合 B 的逆像 $X^{-1}(B)$ 也都是事件。也就是说，$\{X\le x\}$ 是事件这一简化要求，已经包含了“X 是随机变量”的全部信息。这正是正式定义采用这一简化形式的原因。

例 1.1 (常数也是随机变量)**.** 设 Ω 是任意一个样本空间，c 是一个固定的实数。定义

$$X(\omega)=c,\qquad \omega\in\Omega,$$

即对每个样本点 ω，X 都取同一个值 c。下面用逆映射的方法证明 X 是一个随机变量。

对任意实数 x，考虑 X 的原像

$$X^{-1}\big((-\infty,x]\big)=\{\omega\in\Omega:X(\omega)\le x\}.$$

因为对每个 ω 都有 $X(\omega)=c$，所以

$$X(\omega)\le x\iff c\le x.$$

因此

$$X^{-1}\big((-\infty,x]\big)=\begin{cases}\varnothing, & x<c,\\ \Omega, & x\ge c.\end{cases}$$

无论 $x<c$ 还是 $x\ge c$，$\varnothing$ 与 Ω 都是事件（即都属于事件域 $\mathcal{F}$），故 $X^{-1}\big((-\infty,x]\big)$ 是一个事件。由随机变量的定义，X 是一个随机变量。

注 1.2. 这个例子说明：**常数可以看作随机变量的退化情形**。虽然在实际问题中我们通常不把常数看作随机变量，但从定义上看，它完全满足“对每个样本点 ω，都有唯一确定的实数 $X(\omega)$ 与之对应”这一要求。

用逆映射的语言来说，常数 $X \equiv c$ 把整个样本空间 Ω “压”到了实数轴上的一个点 c。对于任意 x，原像要么是 $\varnothing$（当 $x < c$），要么是 Ω（当 $x \geq c$），都是合法的事件。因此，X 满足随机变量的定义。

例 1.2. 抛一枚硬币，样本空间为 $S = \{H, T\}$。定义

$$X(H) = 1, \qquad X(T) = 0,$$

则 X 就是一个随机变量，它表示“正面出现的次数”。

例 1.3. 掷一颗骰子，样本空间为 $S = \{1, 2, 3, 4, 5, 6\}$。定义 $X(\omega) = \omega$，即 X 表示掷出的点数，则 X 是一个随机变量。

五、与微积分中函数概念的对照

为了帮助理解，下面把微积分中的函数与概率论中的随机变量做一对照。

	微积分中的函数	**概率论中的随机变量**
定义域	实数集合 D	样本空间 Ω
自变量	实数 x	样本点 ω
因变量	实数 $y = f(x)$	实数 $X = X(\omega)$
对应规则	给定 x，输出 $f(x)$	给定 ω，输出 $X(\omega)$

从对照表可以看出，随机变量与微积分中的函数在结构上完全一致，区别只在于**定义域不同**：微积分中的函数定义在实数集上，而随机变量定义在样本空间上。

理解了这一点，就可以把微积分中关于函数的许多概念（如单调性、有界性、连续性、可导性等）移植到随机变量的研究中，这也是后面引入分布函数、概率密度函数的基础。

1.2 分布函数

一、分布函数的定义

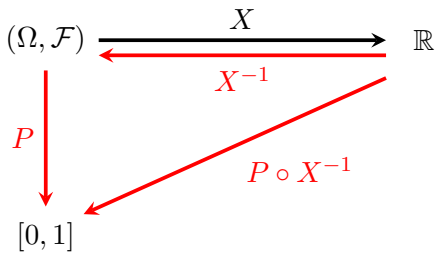
对于随机变量，我们不仅关心它取哪些值，更关心它取这些值的**概率规律**。

定义 1.2 (分布函数)**.** 设 X 是一个随机变量，对任意实数 x，称

$$F(x) = P(X \leq x)$$

为随机变量 X 的**分布函数**，且称 X 服从 $F(x)$，记为 $X \sim F(x)$。

分布函数 $F(x)$ 表示事件 $\{X \leq x\}$ 发生的概率。由于 $\{X \leq x\}$ 是样本空间的一个子集，其概率是确定的，因此 $F(x)$ 是一个定义在 $\mathbb{R}$ 上的函数，取值在 $[0, 1]$ 之间。



$$P \circ X^{-1}\big((-\infty, x]\big) = P\big\{\omega : X(\omega) \le x\big\} = F(x)$$

例 1.4 (退化分布的分布函数)**.** *设随机变量 $X \equiv c$，即 X 以概率 1 取常数 c。求 X 的分布函数 $F(x)$。*

解. 由分布函数的定义，

$$F(x) = P(X \le x).$$

因为 $X \equiv c$，所以事件 $\{X \le x\}$ 取决于 x 与 c 的大小关系：

- 当 $x < c$ 时，$X \le x$ 不可能发生，即 $\{X \le x\} = \varnothing$，故
$$F(x) = P(\varnothing) = 0;$$
- 当 $x \ge c$ 时，$X \le x$ 必然发生，即 $\{X \le x\} = \Omega$，故
$$F(x) = P(\Omega) = 1.$$

因此

$$F(x) = \begin{cases} 0, & x < c, \\ 1, & x \ge c. \end{cases}$$

这个分布函数是一个**阶梯函数**，在 $x = c$ 处有一个跳跃，跳跃高度为 1。这种分布称为**退化分布**（或**单点分布**），记作 $X \equiv c$。 □

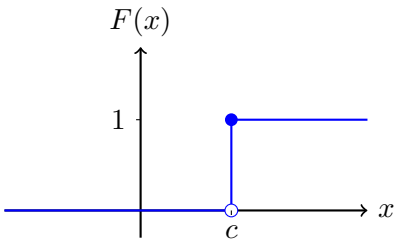


图 2: 退化分布 $X \equiv c$ 的分布函数：在 $x = c$ 处从 0 跳到 1，跳跃高度为 1。

例 1.5 (离散型：取两个值)**.** *抛一枚均匀硬币，令*

$$X = \begin{cases} 1, & \text{若出现正面}, \\ 0, & \text{若出现反面}. \end{cases}$$

求 X 的分布函数 $F(x)$。

解. X 的可能取值为 0 和 1，且

$$P(X=0)=\frac{1}{2},\qquad P(X=1)=\frac{1}{2}.$$

对任意实数 x：

- 当 $x<0$ 时，$\{X\le x\}=\varnothing$，故 $F(x)=0$；
- 当 $0\le x<1$ 时，$\{X\le x\}=\{X=0\}$，故 $F(x)=\dfrac{1}{2}$；
- 当 $x\ge 1$ 时，$\{X\le x\}=S$，故 $F(x)=1$。

因此

$$F(x)=\begin{cases}0, & x<0,\\ \dfrac{1}{2}, & 0\le x<1,\\ 1, & x\ge 1.\end{cases}$$

这个分布函数是**阶梯函数**，在 $x=0$ 和 $x=1$ 处各有一个跳跃，跳跃高度均为 $\dfrac{1}{2}$。 □

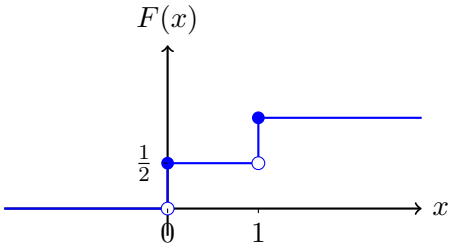


图 3: 离散型（抛硬币）的分布函数：阶梯函数，在 $x=0$ 和 $x=1$ 处各有跳跃。

例 1.6 (连续型：区间上随机取数)**.** 在区间 $[0,1]$ 上随机取一个数 X，即 X 落在 $[0,1]$ 中任意一点的可能性相同。求 X 的分布函数 $F(x)$。

解. 分布函数为

$$F(x)=P(X\le x).$$

按 x 与区间 $[0,1]$ 的位置关系，分三种情形讨论。

(1) 当 $x<0$ 时，

事件 $\{X\le x\}$ 不可能发生，即 $\{X\le x\}=\varnothing$，故

$$F(x)=P(\varnothing)=0.$$

(2) 当 $0\le x\le 1$ 时，

事件 $\{X\le x\}$ 表示“X 落在 $[0,x]$ 上”。由于 X 在 $[0,1]$ 上等可能取值，故 X 落在 $[0,x]$ 上的概率等于 $[0,x]$ 的长度与 $[0,1]$ 的长度之比：

$$F(x)=P(X\le x)=\frac{\text{区间}[0,x]\text{ 的长度}}{\text{区间}[0,1]\text{ 的长度}}=\frac{x}{1}=x.$$

(3) 当 $x > 1$ 时，

事件 $\{X \le x\}$ 必然发生，即 $\{X \le x\} = \Omega$，故

$$F(x) = P(\Omega) = 1.$$

综上，

$$F(x) = \begin{cases} 0, & x < 0, \\ x, & 0 \le x \le 1, \\ 1, & x > 1. \end{cases}$$

这个分布函数在整个数轴上是**连续函数**，没有跳跃点。这与上面离散型随机变量的分布函数（阶梯函数）形成鲜明对照。 □

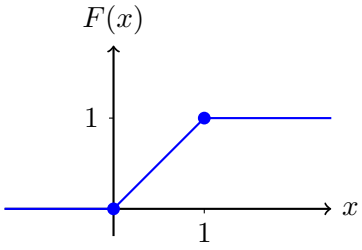


图 4: 连续型（区间 $[0,1]$ 上随机取数）的分布函数：连续函数，没有跳跃点。

注 1.3. 把上述两个分布函数放在一起比较：

- **离散型（抛硬币）**：分布函数是阶梯函数，在 $x = 0$ 和 $x = 1$ 处有跳跃；
- **连续型（区间上随机取数）**：分布函数是连续函数，没有跳跃点。

这正好体现了离散型与连续型随机变量在分布函数形状上的本质区别。

例 1.7 (混合型：离散与连续的“拼接”)**.** 设随机试验如下：先抛一枚均匀硬币。

- 若硬币出现正面，则取 $X = 1$；
- 若硬币出现反面，则在区间 $[0,1]$ 上随机取一个数，令 X 表示这个数。

求 X 的分布函数 $F(x)$。

解. 设

$$A = \{\text{硬币出现正面}\}, \qquad A^c = \{\text{硬币出现反面}\}.$$

则

$$P(A) = P(A^c) = \frac{1}{2}.$$

当 A 发生时，$X = 1$ 恒成立，即

$$P(X \le x \mid A) = \begin{cases} 0, & x < 1, \\ 1, & x \ge 1. \end{cases}$$

当 A^c 发生时，X 是在 $[0,1]$ 上等可能取值的数，故

$$P(X \le x \mid A^c) = \begin{cases} 0, & x < 0, \\ x, & 0 \le x \le 1, \\ 1, & x > 1. \end{cases}$$

由全概率公式，对任意实数 x，

$$F(x) = P(X \le x) = P(A)P(X \le x \mid A) + P(A^c)P(X \le x \mid A^c).$$

下面分区间计算。

(1) 当 $x < 0$ 时，

$$P(X \le x \mid A) = 0, \qquad P(X \le x \mid A^c) = 0,$$

故

$$F(x) = 0.$$

(2) 当 $0 \le x < 1$ 时，

$$P(X \le x \mid A) = 0, \qquad P(X \le x \mid A^c) = x,$$

故

$$F(x) = \frac{1}{2} \cdot 0 + \frac{1}{2} \cdot x = \frac{x}{2}.$$

(3) 当 $x \ge 1$ 时，

$$P(X \le x \mid A) = 1, \qquad P(X \le x \mid A^c) = 1,$$

故

$$F(x) = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 1 = 1.$$

综上，X 的分布函数为

$$F(x) = \begin{cases} 0, & x < 0, \\ \dfrac{x}{2}, & 0 \le x < 1, \\ 1, & x \ge 1. \end{cases}$$

□

注 1.4 (混合型分布函数的形状)**.** 把上面得到的 $F(x)$ 画成图形，可以看到：

- 在区间 $[0,1)$ 上，$F(x) = \dfrac{x}{2}$ 是**连续且严格增加**的，这一段对应“在 $[0,1]$ 上随机取数”的部分；
- 在 $x = 1$ 处，$F(x)$ 从 $\dfrac{1}{2}$ 跳跃到 1，跳跃高度为

$$F(1) - F(1-0) = 1 - \frac{1}{2} = \frac{1}{2},$$

这一段跳跃对应“取 $X = 1$”的离散部分。

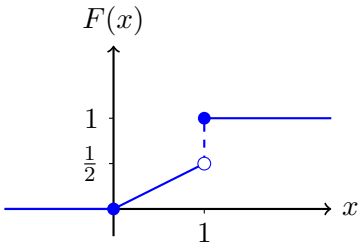


图 5: 混合型分布函数：在 $[0,1)$ 上连续增加，在 $x=1$ 处跳跃，跳跃高度为 $\frac{1}{2}$。

因此，这个分布函数**既有连续段，又有跳跃点**：它既不是纯离散型的阶梯函数，也不是纯连续型的连续函数，而是**一个混合型分布函数**。

这个例子说明：**把离散型随机变量和连续型随机变量按一定概率"混合"起来，就得到一个混合型随机变量**。它可以用全概率公式来求分布函数，方法就是把两种情形分别加权再相加。

三、分布函数的基本性质

定理 1.1. 设 $F(x)$ 是随机变量 X 的分布函数，则：

(1) **单调性**：$F(x)$ 是 $\mathbb{R}$ 上的单调非减函数，即对任意 $x_1 < x_2$，有

$$F(x_1) \le F(x_2);$$

(2) **有界性**：对任意 $x \in \mathbb{R}$，有 $0 \le F(x) \le 1$，且

$$\lim_{x\to-\infty} F(x) = 0, \qquad \lim_{x\to+\infty} F(x) = 1;$$

(3) **右连续性**：$F(x)$ 是右连续函数，即对任意 $x_0 \in \mathbb{R}$，

$$\lim_{x\to x_0^+} F(x) = F(x_0).$$

证明. **(1) 单调性**。

设 $x_1 < x_2$。考察事件

$$A_1 = \{X \le x_1\}, \qquad A_2 = \{X \le x_2\}.$$

若 $\omega \in A_1$，则 $X(\omega) \le x_1$。由于 $x_1 < x_2$，故 $X(\omega) < x_2$，从而 $\omega \in A_2$。因此

$$A_1 \subset A_2.$$

由概率的单调性（即若 $A \subset B$，则 $P(A) \le P(B)$），得

$$P(A_1) \le P(A_2),$$

即

$$F(x_1) = P(X \le x_1) \le P(X \le x_2) = F(x_2).$$

故 $F(x)$ 是 $\mathbb{R}$ 上的单调非减函数。

(2) 有界性。

先证 $0 \le F(x) \le 1$。因为对任意 $x \in \mathbb{R}$，$F(x) = P(X \le x)$ 是事件 $\{X \le x\}$ 的概率，由概率的非负性公理，有

$$F(x) \ge 0.$$

又因为 $\{X \le x\} \subset \Omega$，由概率的单调性与规范性公理，

$$F(x) = P(X \le x) \le P(\Omega) = 1.$$

因此

$$0 \le F(x) \le 1.$$

再证 $\lim\limits_{x \to -\infty} F(x) = 0$。

取数列 $x_n = -n$（$n = 1, 2, \dots$），则 $x_n \downarrow -\infty$。考察事件列

$$A_n = \{X \le x_n\} = \{X \le -n\}, \qquad n = 1, 2, \dots$$

因为 $x_1 > x_2 > \cdots$，所以

$$\{X \le -1\} \supset \{X \le -2\} \supset \cdots,$$

即 $\{A_n\}$ 是单调减少的事件列。

下面计算其交集。设 $\omega \in \bigcap_{n=1}^{\infty} A_n$，则对每个 n，都有 $X(\omega) \le -n$。但 $X(\omega)$ 是一个固定的实数，不可能对所有 n 都满足 $X(\omega) \le -n$（只需取 $n > |X(\omega)|$ 即可矛盾）。因此

$$\bigcap_{n=1}^{\infty} A_n = \varnothing.$$

由概率的**上连续性**（即若 $A_n \downarrow A$，则 $P(A_n) \to P(A)$），得

$$\lim_{n \to \infty} P(A_n) = P\left(\bigcap_{n=1}^{\infty} A_n \right) = P(\varnothing) = 0.$$

即

$$\lim_{n \to \infty} F(-n) = 0.$$

由于 F 单调非减，对任意 $x < -n$，有 $0 \le F(x) \le F(-n)$。令 $n \to \infty$，得

$$\lim_{x \to -\infty} F(x) = 0.$$

最后证 $\lim\limits_{x \to +\infty} F(x) = 1$。

取数列 $x_n = n$（$n = 1, 2, \dots$），则 $x_n \uparrow +\infty$。考察事件列

$$B_n = \{X \le x_n\} = \{X \le n\}, \qquad n = 1, 2, \dots$$

因为 $x_1 < x_2 < \cdots$，所以

$$\{X \le 1\} \subset \{X \le 2\} \subset \cdots,$$

即 $\{B_n\}$ 是单调增加的事件列。

下面计算其并集。设 $\omega \in \Omega$，则 $X(\omega)$ 是一个固定的实数。取 N 为大于 $X(\omega)$ 的某个正整数，则 $X(\omega) < N$，从而 $\omega \in B_N$。因此

$$\bigcup_{n=1}^{\infty} B_n = \Omega.$$

由概率的**下连续性**（即若 $B_n \uparrow B$，则 $P(B_n) \to P(B)$），得

$$\lim_{n\to\infty} P(B_n) = P\left(\bigcup_{n=1}^{\infty} B_n\right) = P(\Omega) = 1.$$

即

$$\lim_{n\to\infty} F(n) = 1.$$

由于 F 单调非减，对任意 $x > n$，有 $F(n) \le F(x) \le 1$。令 $n \to \infty$，得

$$\lim_{x\to+\infty} F(x) = 1.$$

(3) 右连续性。

设 $x_0 \in \mathbb{R}$。取数列 $x_n \downarrow x_0$，即 $x_1 > x_2 > \cdots > x_0$，且 $x_n \to x_0$。考察事件列

$$C_n = \{X \le x_n\}, \qquad n = 1, 2, \ldots$$

因为 $x_1 > x_2 > \cdots$，所以

$$\{X \le x_1\} \supset \{X \le x_2\} \supset \cdots,$$

即 $\{C_n\}$ 是单调减少的事件列。

下面计算其交集。设 $\omega \in \bigcap_{n=1}^{\infty} C_n$，则对每个 n，都有 $X(\omega) \le x_n$。因为 $x_n \downarrow x_0$，令 $n \to \infty$，得 $X(\omega) \le x_0$，故 $\omega \in \{X \le x_0\}$。

反之，设 $\omega \in \{X \le x_0\}$，则 $X(\omega) \le x_0 < x_n$（因为 $x_n > x_0$），故对每个 n，都有 $\omega \in C_n$，即 $\omega \in \bigcap_{n=1}^{\infty} C_n$。

因此

$$\bigcap_{n=1}^{\infty} C_n = \{X \le x_0\}.$$

由概率的**上连续性**，得

$$\lim_{n\to\infty} P(C_n) = P\left(\bigcap_{n=1}^{\infty} C_n\right) = P(X \le x_0) = F(x_0).$$

即

$$\lim_{n\to\infty} F(x_n) = F(x_0).$$

由于 $\{x_n\}$ 是任意单调减少到 x_0 的数列，故对任意 $x \to x_0^+$，都有

$$\lim_{x\to x_0^+} F(x) = F(x_0).$$

因此 $F(x)$ 在 x_0 处右连续。由 x_0 的任意性，$F(x)$ 在 $\mathbb{R}$ 上右连续。

综上所述，分布函数 $F(x)$ 具有单调性、有界性和右连续性三条基本性质。 □

例 1.8 (判断下列函数是否为分布函数)**.** 判断下列函数是否为某个随机变量的分布函数，并说明理由：

(a) $F_1(x) = \dfrac{1}{1+e^x}, \qquad x \in \mathbb{R};$

(b) $F_2(x) = \begin{cases} 0, & x \le 0, \\ 1, & x > 0; \end{cases}$

(c) $F_3(x) = \begin{cases} 0, & x < 0, \\ \dfrac{1}{2}, & 0 \le x < 1, \\ 1, & x \ge 1. \end{cases}$

解. 判断一个函数是否为分布函数，需要逐条检验三条基本性质：**单调性、有界性、右连续性**。

(a) $F_1(x)$ **不满足单调性**。

先看 F_1 的单调性。对 F_1 求导：

$$F_1'(x) = \frac{-e^x}{(1+e^x)^2} < 0, \qquad x \in \mathbb{R}.$$

因此 F_1 在 $\mathbb{R}$ 上严格**减少**，不满足分布函数的单调非减性。

另外，

$$\lim_{x\to-\infty} F_1(x) = 1, \qquad \lim_{x\to+\infty} F_1(x) = 0,$$

也不满足分布函数在 $-\infty$ 处趋于 0、在 $+\infty$ 处趋于 1 的极限要求。

因此，F_1 **不是**分布函数。它的问题出在**单调性**上。

(b) $F_2(x)$ **不满足右连续性**。

先检验单调性：当 $x \le 0$ 时 $F_2(x) = 0$，当 $x > 0$ 时 $F_2(x) = 1$，故 F_2 单调非减。

再检验有界性：

$$0 \le F_2(x) \le 1, \qquad \lim_{x\to-\infty} F_2(x) = 0, \qquad \lim_{x\to+\infty} F_2(x) = 1.$$

有界性满足。

最后检验右连续性。在 $x = 0$ 处，

$$F_2(0) = 0, \qquad \lim_{x\to0^+} F_2(x) = 1.$$

因此

$$\lim_{x\to0^+} F_2(x) \ne F_2(0),$$

F_2 在 $x = 0$ 处**不右连续**。

因此，F_2 **不是**分布函数。它满足单调性和有界性，唯独不满足右连续性。

(c) $F_3(x)$ **是分布函数**。

逐条检验三条性质。

单调性：F_3 在 $(-\infty, 0)$、$[0, 1)$、$[1, +\infty)$ 上分别为 0、$\dfrac{1}{2}$、1，故 F_3 单调非减。

有界性：

$$0 \le F_3(x) \le 1, \qquad \lim_{x\to-\infty} F_3(x) = 0, \qquad \lim_{x\to+\infty} F_3(x) = 1.$$

有界性满足。

右连续性：只需检查 $x = 0$ 和 $x = 1$ 两点。

$$F_3(0) = \frac{1}{2} = \lim_{x\to0^+} F_3(x), \qquad F_3(1) = 1 = \lim_{x\to1^+} F_3(x).$$

故 F_3 右连续。

因此，F_3 **是**分布函数。事实上，它是"以概率 $\frac{1}{2}$ 取 0、以概率 $\frac{1}{2}$ 取 1"的离散型随机变量的分布函数。 □

注 1.5. 这个例子说明：判断一个函数是否为分布函数，必须逐条检验三条基本性质：

(1) **单调性**：F 在 $\mathbb{R}$ 上单调非减；

(2) **有界性**：$0 \le F(x) \le 1$，且 $\lim_{x\to-\infty} F(x) = 0$，$\lim_{x\to+\infty} F(x) = 1$；

(3) **右连续性**：F 在每一点处右连续。

三条缺一不可：

- F_1 满足有界性的极限条件，但**单调性不满足**（严格减少）；
- F_2 满足单调性和有界性，但**右连续性不满足**；
- F_3 满足全部三条性质，故是分布函数。

通过这三个例子的对照，可以清楚地看到三条性质各自的作用，以及判断一个函数是否为分布函数的标准流程。

例 1.9 (由分布函数的有界性确定常数)**.** 设随机变量 X 的分布函数为

$$F(x) = A + B\arctan x, \qquad -\infty < x < +\infty.$$

求：

(1) 常数 A 和 B；

(2) $P\left(1 < X < \sqrt{3}\right)$。

解. **(1) 求常数 A 和 B。**

由分布函数的有界性，有

$$\lim_{x\to-\infty} F(x) = 0, \qquad \lim_{x\to+\infty} F(x) = 1.$$

因为

$$\lim_{x\to-\infty} \arctan x = -\frac{\pi}{2}, \qquad \lim_{x\to+\infty} \arctan x = \frac{\pi}{2},$$

所以

$$0 = \lim_{x\to-\infty} F(x) = \lim_{x\to-\infty} (A + B\arctan x) = A - \frac{\pi}{2}B,$$

$$1=\lim_{x\to+\infty}F(x)=\lim_{x\to+\infty}(A+B\arctan x)=A+\frac{\pi}{2}B.$$

两式相加，得

$$2A=1,\qquad A=\frac{1}{2}.$$

两式相减，得

$$\pi B=1,\qquad B=\frac{1}{\pi}.$$

因此

$$F(x)=\frac{1}{2}+\frac{1}{\pi}\arctan x.$$

(2) 求 $P\left(1<X<\sqrt{3}\right)$。

由分布函数的性质，

$$P(a<X\le b)=F(b)-F(a).$$

由于 $F(x)$ 是连续函数，$P(X=1)=P(X=\sqrt{3})=0$，故

$$P\left(1<X<\sqrt{3}\right)=P\left(1<X\le\sqrt{3}\right)=F(\sqrt{3})-F(1).$$

代入 $F(x)=\frac{1}{2}+\frac{1}{\pi}\arctan x$，得

$$F(\sqrt{3})=\frac{1}{2}+\frac{1}{\pi}\arctan\sqrt{3}=\frac{1}{2}+\frac{1}{\pi}\cdot\frac{\pi}{3}=\frac{1}{2}+\frac{1}{3}=\frac{5}{6},$$

$$F(1)=\frac{1}{2}+\frac{1}{\pi}\arctan 1=\frac{1}{2}+\frac{1}{\pi}\cdot\frac{\pi}{4}=\frac{1}{2}+\frac{1}{4}=\frac{3}{4}.$$

因此

$$P\left(1<X<\sqrt{3}\right)=F(\sqrt{3})-F(1)=\frac{5}{6}-\frac{3}{4}=\frac{10}{12}-\frac{9}{12}=\frac{1}{12}.$$

□

注 1.6. 这个例子综合运用了分布函数的两条性质：

- **有界性**：由 $\lim_{x\to-\infty}F(x)=0$ 和 $\lim_{x\to+\infty}F(x)=1$ 确定常数 A 和 B；
- **计算概率**：由 $P(a<X\le b)=F(b)-F(a)$ 计算区间概率。

此外，由于本例中的 $F(x)$ 是连续函数，连续型随机变量取单点的概率为 0，所以 $P\left(1<X<\sqrt{3}\right)$ 与 $P\left(1<X\le\sqrt{3}\right)$ 相等。

1.3 本节小结

本节小结

(1) **随机变量**是定义在样本空间 Ω 上的实值函数 $X:\Omega\to\mathbb{R}$，它把随机现象的结果数量化。

(2) 从逆映射的角度看，$\{X\le x\}=X^{-1}((-\infty,x])$ 是样本空间中的事件，随机变量把实数集上的事件“拉回”到样本空间。

(3) 引入随机变量的三大好处：把随机现象数量化、简化事件的表示、统一描述概率规律。

(4) **分布函数** $F(x)=P(X\le x)$ 完整地描述了随机变量的全部统计规律：由 $F(x)$ 可以计算任意事件的概率。

(5) 分布函数具有**单调性、有界性和右连续性**三条基本性质。

(6) 判断一个函数是否为分布函数，必须逐条检验这三条性质，三条缺一不可。

(7) 通过退化分布、抛硬币、均匀分布、混合型四个例子，可以看到分布函数形状的多样性：退化分布只有一个跳跃点，离散型分布是阶梯函数，连续型分布是连续函数，混合型分布既有连续段又有跳跃点。

1.4 习题

1. 抛一枚均匀硬币三次，令 X 表示正面出现的次数。写出 X 的所有可能取值，并求 X 的分布函数 $F(x)$。

2. 掷两颗均匀骰子，令 X 表示两颗骰子点数之和。写出 X 的所有可能取值，并求 $P(X\le 5)$。

3. 判断下列函数是否为某个随机变量的分布函数，并说明理由：

   (a) $F(x)=\dfrac{1}{1+e^{-x}}$，$x\in\mathbb{R}$；

   (b) $F(x)=\begin{cases}0, & x<0,\\ x, & 0\le x<1,\\ 1, & x\ge 1;\end{cases}$

   (c) $F(x)=\begin{cases}0, & x<0,\\ \sin x, & 0\le x<\pi,\\ 0, & x\ge\pi.\end{cases}$

4. 设随机变量 X 的分布函数为

$$F(x)=\begin{cases}0, & x<-1,\\ 0.2, & -1\le x<0,\\ 0.5, & 0\le x<1,\\ 1, & x\ge 1.\end{cases}$$

求 $P(X=0)$、$P(X<0)$、$P(0<X\le 1)$。

5. 设随机变量 X 的分布函数为

$$F(x)=\begin{cases}0, & x<0,\\ Ax^2, & 0\le x<1,\\ 1, & x\ge 1.\end{cases}$$

求常数 A，并求 $P(0.5<X\le 1)$。

6. 设随机变量 X 的分布函数为

$$F(x)=\begin{cases}0, & x<0,\\ \dfrac{1}{2}+\dfrac{x}{4}, & 0\le x<2,\\ 1, & x\ge 2.\end{cases}$$

求 $P(X<1)$、$P(X=1)$、$P(1<X\le 2)$。

2 一维离散型随机变量

2.1 离散型随机变量的定义与分布律

在第一节中，我们根据随机变量取值的特点，将其分为离散型与连续型两类。本节详细讨论离散型随机变量。

定义 2.1 (离散型随机变量)**.** 设 X 是一个随机变量。若 X 的全部可能取值是有限个或可列无穷个，即

$$X\in\{x_1,x_2,\dots,x_n\}\quad 或\quad X\in\{x_1,x_2,\dots\},$$

则称 X 为**离散型随机变量**。

对于离散型随机变量，我们关心它取每个值的概率。

定义 2.2 (分布律)**.** 设 X 是离散型随机变量，其全部可能取值为 $x_1,x_2,\dots$，称

$$p_k=P(X=x_k),\qquad k=1,2,\dots$$

为 X 的**概率分布律**，简称**分布律**（或概率质量函数）。

分布律满足以下两条基本性质：

(1) **非负性**：$p_k \geq 0$，$k = 1, 2, \ldots$；

(2) **规范性**：$\sum_k p_k = 1$。

性质 (2) 的直观含义是：随机变量 X 取到所有可能值的概率之和为 1。

2.2 分布律的表示方法

离散型随机变量的分布律有三种常用的表示方法。

一、表格表示

将随机变量的取值与对应的概率列成表格，称为**分布律表**：

X	x_1	x_2	$\cdots$	x_k	$\cdots$
P	p_1	p_2	$\cdots$	p_k	$\cdots$

也可以用矩阵形式简记：

$$X \sim \begin{pmatrix} x_1 & x_2 & \cdots & x_k & \cdots \\ p_1 & p_2 & \cdots & p_k & \cdots \end{pmatrix}.$$

二、公式表示

用解析式直接给出 p_k 的表达式。例如：

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad k = 0, 1, 2, \ldots$$

这是泊松分布的分布律。

三、图形表示

在直角坐标系中，用横轴表示随机变量的取值 x_k，纵轴表示对应的概率 p_k，在每一点 (x_k, p_k) 处画一条垂直线段。这种图形称为**分布律图**（或概率质量函数的柱形图）。

也可以将各点用线段连接，形成**概率分布多边形**（也称概率直方图或折线图）。两种方式都能直观展示概率在各取值之间的分配情况。

图形表示的特点是：所有垂直线段的高度之和等于 1，即 $\sum_k p_k = 1$，这与规范性条件一致。

2.3 离散型随机变量与分布函数的关系

设离散型随机变量 X 的分布律为 $p_k = P(X = x_k)$，$k = 1, 2, \ldots$，则其分布函数为

$$F(x) = P(X \leq x) = \sum_{x_k \leq x} p_k.$$

也就是说，$F(x)$ 等于所有不超过 x 的取值对应的概率之和。

命题 2.1 (离散型分布函数的特点)**.** $F(x)$ **是一个右连续的阶梯函数**。具体地说：

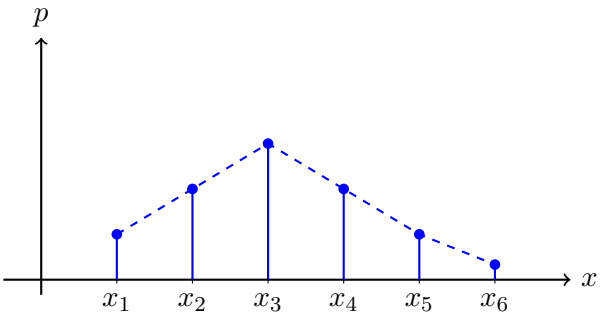


图 6: 离散型随机变量分布律的图形表示：垂直线段表示每个取值处的概率，虚线连接各顶点形成概率分布多边形。

- 在区间 $[x_{k-1}, x_k)$ 上 $F(x)$ 取常数值；
- 在每个可能取值 x_k 处产生一个跳跃，跳跃高度恰好等于 p_k。

  反过来，若已知分布函数 $F(x)$，可以通过跳跃点恢复分布律：

$$p_k = F(x_k) - F(x_{k-1}),$$

其中 x_0 取为任意小于 x_1 的实数。

例 2.1. 设 X 的分布律为

$$P(X=1)=\frac{1}{2}, \qquad P(X=2)=\frac{1}{3}, \qquad P(X=3)=\frac{1}{6}.$$

求 X 的分布函数 $F(x)$。

解. 按分布函数的定义，分区间计算：

- 当 $x<1$ 时，$F(x)=0$；
- 当 $1\le x<2$ 时，$F(x)=P(X=1)=\dfrac{1}{2}$；
- 当 $2\le x<3$ 时，$F(x)=P(X=1)+P(X=2)=\dfrac{1}{2}+\dfrac{1}{3}=\dfrac{5}{6}$；
- 当 $x\ge 3$ 时，$F(x)=1$。

因此

$$F(x)=\begin{cases} 0, & x<1,\\ \dfrac{1}{2}, & 1\le x<2,\\ \dfrac{5}{6}, & 2\le x<3,\\ 1, & x\ge 3. \end{cases}$$

这是一个右连续的阶梯函数，在 $x=1,2,3$ 处分别有跳跃，跳跃高度为 $\dfrac{1}{2},\dfrac{1}{3},\dfrac{1}{6}$。 □

2.4 常见的离散型随机变量

一、退化分布（单点分布）

若随机变量 X 以概率 1 取常数 c，即

$$P(X=c)=1,$$

则称 X 服从**退化分布**（或**单点分布**），记作 $X\equiv c$。

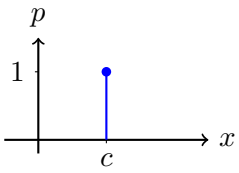
表格表示：

X	c
P	1

公式表示：

$$P(X=c)=1.$$

图形表示：



分布函数：

$$F(x)=\begin{cases}0, & x<c,\\ 1, & x\geq c.\end{cases}$$

二、两点分布（Bernoulli 分布）

定义 2.3 (两点分布)**.** 设随机变量 X 只取两个值 0 和 1，且

$$P(X=1)=p,\qquad P(X=0)=1-p,\qquad 0<p<1,$$

则称 X 服从参数为 p 的**两点分布**，也称 0-1 **分布**或 ***Bernoulli* 分布**，记作

$$X\sim B(1,p).$$

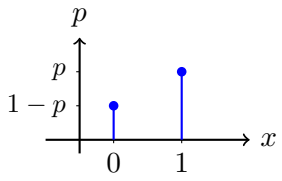
表格表示：

X	0	1
P	$1-p$	p

公式表示：

$$P(X=k)=p^k(1-p)^{1-k},\qquad k=0,1.$$

图形表示：



背景：两点分布描述一次 Bernoulli 试验中“成功”发生的次数。例如，抛一枚硬币（正面为 1，反面为 0）、检验一件产品（合格为 1，不合格为 0）。

当 $p=0$ 或 $p=1$ 时，两点分布退化为退化分布。

三、几何分布

定义 2.4 (几何分布). *设 X 为在独立重复的 Bernoulli 试验中，事件 A **首次发生**时所需的试验次数，且每次试验中 A 发生的概率为 p $(0<p<1)$，则 X 的分布律为*

$$P(X=k)=(1-p)^{k-1}p, \qquad k=1,2,\dots$$

*称 X 服从参数为 p 的**几何分布**，记作*

$$X\sim G(p).$$

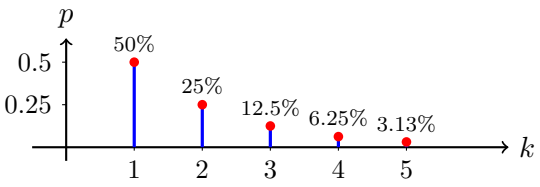
表格表示（以 $p=1/2$ 为例）：

X	1	2	3	4	$\cdots$
P	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{16}$	$\cdots$

公式表示：

$$P(X=k)=(1-p)^{k-1}p, \qquad k=1,2,\dots$$

图形表示（$p=1/2$）：



几何分布 Ge(1/2) 的分布律

规范性验证：

$$\sum_{k=1}^{\infty}(1-p)^{k-1}p=p\cdot\frac{1}{1-(1-p)}=p\cdot\frac{1}{p}=1.$$

注 2.1 (几何分布的含义：离散状态下的” 等待时间”). *几何分布描述的是**离散状态**下的”等待时间”：系统每一次试验处于两个状态之一（成功 A 或失败 A^c），试验独立重复地进行，直到状态发生改变（即事件 A 首次出现）为止，所需的试验次数 X 就服从几何分布。*

换句话说：

- ***持续**：在前 $k-1$ 次试验中，系统一直处于失败状态 A^c；*
- ***一旦改变就停止**：在第 k 次试验中，状态首次改变为 A，过程随即停止。*

参数 p 可以理解为**事件 A 出现的速率**：每次试验中 A 出现的概率都是 p，p 越大，状态改变得越快，所需等待次数 X 的期望 $E(X)=1/p$ 就越小。

几何分布与第 3 节将要介绍的**指数分布**形成一对”离散—连续”的对应：几何分布描述”离散状态下，一个持续状态一旦改变就停止的这段时间”；而指数分布则描述”连续状态下，一个持续状态一旦改变就停止的这段时间”（例如灯泡的寿命——从点亮到失效这段连续时间）。两者的共同特点是都具有**无记忆性**。

例 2.2 (几何分布的应用)**.** 某射手每次射击命中目标的概率为 $p=0.4$，独立重复射击直到首次命中目标为止。求：

(a) 恰好射击 3 次才首次命中的概率；

(b) 至多射击 3 次就首次命中的概率；

(c) 首次命中所需的射击次数超过 5 次的概率。

解. 设 X 为首次命中目标所需的射击次数，则 $X\sim G(0.4)$，且

$$P(X=k)=(0.6)^{k-1}\cdot 0.4,\qquad k=1,2,\dots$$

(a) 恰好射击 3 次才首次命中：

$$P(X=3)=(0.6)^2\times 0.4=0.36\times 0.4=0.144.$$

(b) 至多射击 3 次就首次命中：

$$P(X\le 3)=P(X=1)+P(X=2)+P(X=3)=0.4+0.6\times 0.4+0.6^2\times 0.4.$$

逐项计算：

$$P(X=1)=0.4,\qquad P(X=2)=0.24,\qquad P(X=3)=0.144,$$

故

$$P(X\le 3)=0.4+0.24+0.144=0.784.$$

(c) 首次命中所需次数超过 5 次：

$$P(X>5)=\sum_{k=6}^{\infty}(0.6)^{k-1}\cdot 0.4.$$

利用几何分布的尾概率公式，

$$P(X>m)=(1-p)^m,$$

取 $m=5$、$p=0.4$，得

$$P(X>5)=(0.6)^5=0.07776.$$

□

注 2.2. 第 *(c)* 问用到了几何分布的尾概率公式

$$P(X>m)=(1-p)^m,\qquad m=0,1,2,\dots$$

它的含义是：**前 m 次试验全部失败**，因此发生概率为 $(1-p)^m$。这个公式是几何分布无记忆性的直接体现，也是后面讨论”等待时间”问题时常用的工具。

四、二项分布

定义 2.5 (二项分布). 设 X 为 n 重 *Bernoulli* 试验中事件 A 发生的次数，且每次试验中 A 发生的概率为 p $(0<p<1)$，则 X 的分布律为

$$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k},\qquad k=0,1,\dots,n.$$

称 X 服从参数为 n,p 的**二项分布**，记作

$$X\sim B(n,p).$$

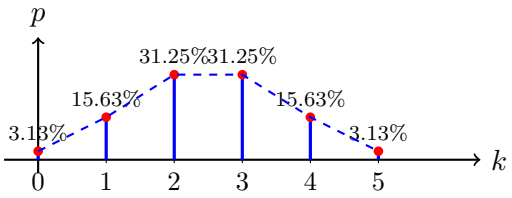
表格表示（以 $n=5$，$p=1/2$ 为例）：

X	0	1	2	3	4	5
P	$\frac{1}{32}$	$\frac{5}{32}$	$\frac{10}{32}$	$\frac{10}{32}$	$\frac{5}{32}$	$\frac{1}{32}$

公式表示：

$$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k},\qquad k=0,1,\dots,n.$$

图形表示（$n=5$，$p=1/2$）：



$B(5,\,1/2)$ 的分布律

规范性验证：由二项式定理，

$$\sum_{k=0}^{n}\binom{n}{k}p^k(1-p)^{n-k}=(p+(1-p))^n=1.$$

背景：二项分布描述 n 次独立重复试验中成功的总次数。例如，抛一枚均匀硬币 n 次，正面出现的次数服从 $B(n,1/2)$。

二项分布与两点分布的关系：两点分布是二项分布在 $n=1$ 时的特例，即 $B(1,p)$。

例 2.3. 某射手每次射击命中目标的概率为 0.8，独立射击 5 次。求恰好命中 3 次的概率。

解. 设 X 为 5 次射击中命中的次数，则 $X\sim B(5,0.8)$。由二项分布公式，

$$P(X=3)=\binom{5}{3}(0.8)^3(0.2)^2=10\times0.512\times0.04=0.2048.$$

□

例 2.4 (第一次成功与第二次成功：条件概率的综合讨论). 在独立重复的 *Bernoulli* 试验中，每次成功的概率为 p $(0<p<1)$。设

$$X_1=\{\text{第一次成功所需的试验次数}\},\qquad X_2=\{\text{第二次成功所需的试验次数}\}.$$

显然，$1\le X_1<X_2$，且 X_1 服从参数为 p 的几何分布。

(1) 求联合概率 $P(X_1 = k,\ X_2 = n)$；

(2) 求条件概率 $P(X_1 = k \mid X_2 = n)$；

(3) 求条件概率 $P(X_2 = n \mid X_1 = k)$；

(4) 说明上述结果与几何分布无记忆性的关系。

解. **(1) 联合概率** $P(X_1 = k,\ X_2 = n)$。

事件 $\{X_1 = k,\ X_2 = n\}$（$1 \le k < n$）表示：

- 第 k 次试验首次成功；
- 第 $k+1$ 次到第 $n-1$ 次试验都失败；
- 第 n 次试验成功。

由于各次试验相互独立，故

$$P(X_1 = k,\ X_2 = n) = \underbrace{(1-p)^{k-1}p}_{\text{第}k\text{ 次首次成功}} \cdot \underbrace{(1-p)^{n-1-k}}_{\text{中间}n-1-k\text{ 次失败}} \cdot \underbrace{p}_{\text{第}n\text{ 次成功}}.$$

化简得

$$P(X_1 = k,\ X_2 = n) = (1-p)^{n-2}p^2, \qquad 1 \le k < n.$$

值得注意的是，这个联合概率**与 k 无关**，只依赖于 n。

(2) 条件概率 $P(X_1 = k \mid X_2 = n)$。

由条件概率的定义，

$$P(X_1 = k \mid X_2 = n) = \frac{P(X_1 = k,\ X_2 = n)}{P(X_2 = n)}.$$

先求 $P(X_2 = n)$。事件 $\{X_2 = n\}$ 表示“第二次成功发生在第 n 次试验”。这意味着前 $n-1$ 次试验中恰好有 1 次成功，且第 n 次成功。由二项分布公式，

$$P(X_2 = n) = \binom{n-1}{1} p(1-p)^{n-2} \cdot p = (n-1)(1-p)^{n-2}p^2.$$

代入分子：

$$P(X_1 = k \mid X_2 = n) = \frac{(1-p)^{n-2}p^2}{(n-1)(1-p)^{n-2}p^2} = \frac{1}{n-1}, \qquad 1 \le k \le n-1.$$

这个结果表明：**在已知“第二次成功发生在第 n 次”的条件下，第一次成功的位置在 $\{1, 2, \ldots, n-1\}$ 上服从均匀分布**。

(3) 条件概率 $P(X_2 = n \mid X_1 = k)$。

由条件概率的定义，

$$P(X_2 = n \mid X_1 = k) = \frac{P(X_1 = k,\ X_2 = n)}{P(X_1 = k)}.$$

先求 $P(X_1 = k)$。因为 X_1 服从参数为 p 的几何分布，

$$P(X_1 = k) = (1-p)^{k-1}p.$$

代入分子：

$$P(X_2 = n \mid X_1 = k) = \frac{(1-p)^{n-2}p^2}{(1-p)^{k-1}p} = (1-p)^{n-k-1}p, \qquad k < n.$$

这个结果表明：**在已知"第一次成功发生在第 k 次"的条件下，第二次成功所需的额外试验次数 $X_2 - k$ 仍然服从参数为 p 的几何分布**，即

$$P(X_2 = n \mid X_1 = k) = P(X_2 - k = n - k \mid X_1 = k) = (1-p)^{n-k-1}p.$$

这正是**几何分布的无记忆性**的体现：**过去的失败次数不影响未来的成功概率**。

(4) 与几何分布无记忆性的关系。

综合上述结果：

- 在给定"第二次成功发生在第 n 次"的条件下，第一次成功的位置在 $\{1, \dots, n-1\}$ 上**等可能**；
- 在给定"第一次成功发生在第 k 次"的条件下，第二次成功所需的**额外**试验次数 $X_2 - k$ 仍然服从参数为 p 的几何分布。

这两个结论都源于同一事实：**各次试验相互独立，每次成功的概率保持为 p，过去的试验结果不影响未来的试验结果**。这就是几何分布的无记忆性：

$$P(X > m + n \mid X > m) = P(X > n), \qquad m, n \geq 1,$$

其中 X 服从几何分布。 □

注 2.3. 本例把"第一次成功"和"第二次成功"综合在同一个模型中讨论，得到三个相互印证的结果：

(1) $P(X_1 = k,\ X_2 = n)$ 与 k 无关；

(2) $P(X_1 = k \mid X_2 = n) = \dfrac{1}{n-1}$，第一次成功的位置在已知条件下等可能；

(3) $P(X_2 = n \mid X_1 = k) = (1-p)^{n-k-1}p$，额外等待时间仍服从几何分布。

这三个结果从不同角度刻画了 *Bernoulli* 试验的独立性与几何分布的无记忆性，是理解几何分布和负二项分布的重要桥梁。

五、负二项分布

定义 2.6 (负二项分布)**.** 在独立重复的 *Bernoulli* 试验中，每次成功的概率为 p $(0 < p < 1)$。设 X 为第 r 次成功出现时的试验总次数，则 X 的分布律为

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \qquad k = r, r+1, r+2, \dots$$

称 X 服从参数为 r, p 的**负二项分布**，记作

$$X \sim \mathrm{NB}(r, p).$$

推导. 设第 r 次成功恰好发生在第 k 次试验（$k \geq r$）。这意味着：

- 第 k 次试验必须成功，概率为 p；
- 前 $k-1$ 次试验中恰有 $r-1$ 次成功、$k-r$ 次失败。

前 $k-1$ 次试验中恰有 $r-1$ 次成功的概率为

$$\binom{k-1}{r-1} p^{r-1}(1-p)^{k-r}.$$

再乘以第 k 次成功的概率 p，得

$$P(X=k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \qquad k = r, r+1, r+2, \ldots$$

□

注 2.4. 当 $r=1$ 时，$\mathrm{NB}(1,p)$ 即为几何分布：

$$P(X=k) = (1-p)^{k-1}p, \qquad k = 1, 2, \ldots$$

因此，几何分布是负二项分布在 $r=1$ 时的特例。负二项分布也可以理解为 r 个独立几何分布随机变量之和。

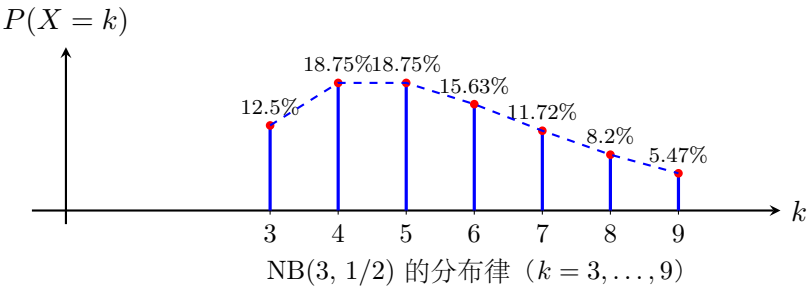
例 2.5 (负二项分布的应用)**.** 某射手每次射击命中目标的概率为 0.8，独立射击直到第 3 次命中为止。求总共射击了 5 次的概率。

解. 设 X 为首次出现第 3 次命中时的射击总次数，则 $X \sim \mathrm{NB}(3, 0.8)$。由负二项分布公式，

$$P(X=5) = \binom{5-1}{3-1}(0.8)^3(0.2)^{5-3} = \binom{4}{2}(0.8)^3(0.2)^2 = 6 \times 0.512 \times 0.04 = 0.12288.$$

□

以 $r=3$, $p=1/2$ 为例，分布律的竖线图如下：



NB(3, 1/2) 的分布律（$k = 3, \ldots, 9$）

例 2.6. 某射手每次射击命中目标的概率为 0.8，独立射击直到第 3 次命中为止。求总共射击了 5 次的概率。

解. 设 X 为首次出现第 3 次命中时的射击总次数，则 $X \sim \mathrm{NB}(3, 0.8)$。由负二项分布公式，

$$P(X=5) = \binom{5-1}{3-1}(0.8)^3(0.2)^{5-3} = \binom{4}{2}(0.8)^3(0.2)^2 = 6 \times 0.512 \times 0.04 = 0.12288.$$

□

注 2.5. 负二项分布是二项分布的”对偶”:

- 二项分布：固定试验次数 n，研究成功次数 X 的分布；
- 负二项分布：固定成功次数 r，研究试验总次数 X 的分布。

当 $r=1$ 时，$\mathrm{NB}(1,p)$ 即为**几何分布**：

$$P(X=k)=(1-p)^{k-1}p, \qquad k=1,2,\dots$$

五、泊松分布

定义 2.7 (泊松分布). 设随机变量 X 的分布律为

$$P(X=k)=\frac{\lambda^k}{k!}e^{-\lambda}, \qquad k=0,1,2,\dots$$

其中 $\lambda>0$ 为常数，则称 X 服从参数为 λ 的**泊松分布**，记作

$$X\sim P(\lambda).$$

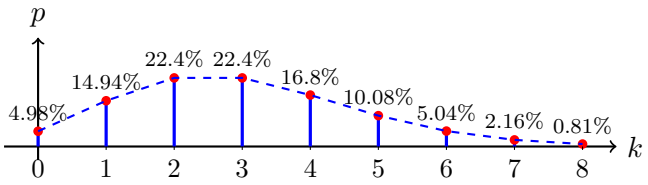
表格表示（以 $\lambda=3$ 为例）：

X	0	1	2	3	4	5	$\cdots$
P	0.0498	0.1494	0.2240	0.2240	0.1680	0.1008	$\cdots$

公式表示：

$$P(X=k)=\frac{\lambda^k}{k!}e^{-\lambda}, \qquad k=0,1,2,\dots$$

图形表示（$\lambda=3$）：



泊松分布 P(λ) 的分布律（$\lambda\approx 3$）

规范性验证：由 e^{λ} 的 Taylor 展开，

$$\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}e^{-\lambda}=e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}=e^{-\lambda}\cdot e^{\lambda}=1.$$

背景：泊松分布常用于描述**单位时间或空间内稀有事件发生的次数**。例如：放射性物质在单位时间内放射的粒子数、某路口一天内发生的交通事故数、某电话总机在一分钟内接到的呼叫次数等。

例 2.7 (电话交换台的呼叫次数). 某电话交换台每分钟接到的呼叫次数 X 服从参数为 $\lambda=3$ 的泊松分布。求：

(1) 一分钟内恰好接到 2 次呼叫的概率；

(2) 一分钟内至少接到 1 次呼叫的概率；

(3) 一分钟内接到不超过 2 次呼叫的概率。

解. 由题意，$X \sim P(3)$，即

$$P(X=k)=\frac{3^k}{k!}e^{-3}, \qquad k=0,1,2,\dots$$

(1) 恰好 2 次呼叫：

$$P(X=2)=\frac{3^2}{2!}e^{-3}=\frac{9}{2}e^{-3}\approx 0.2240.$$

(2) 至少 1 次呼叫，用补集思想：

$$P(X\geq 1)=1-P(X=0)=1-\frac{3^0}{0!}e^{-3}=1-e^{-3}\approx 0.9502.$$

(3) 不超过 2 次呼叫，即 $k=0,1,2$：

$$\begin{aligned}P(X\leq 2)&=P(X=0)+P(X=1)+P(X=2)\\&=e^{-3}+3e^{-3}+\frac{9}{2}e^{-3}\\&=\left(1+3+\frac{9}{2}\right)e^{-3}=\frac{17}{2}e^{-3}\\&\approx 0.4232.\end{aligned}$$

□

定理 2.1 (泊松定理)**.** 设随机变量 X_n 服从二项分布 $B(n,p_n)$，$n=1,2,\dots$。若

$$np_n\longrightarrow\lambda \qquad (n\to\infty),$$

其中 $\lambda>0$ 为常数，则对任意固定的非负整数 k，

$$\lim_{n\to\infty}P(X_n=k)=\lim_{n\to\infty}\binom{n}{k}p_n^k(1-p_n)^{n-k}=\frac{\lambda^k}{k!}e^{-\lambda}.$$

证明. 记 $\lambda_n=np_n$。由条件 $np_n\to\lambda$，得

$$\lambda_n\to\lambda, \qquad p_n=\frac{\lambda_n}{n}\to 0.$$

对任意固定的非负整数 k，将 $P(X_n=k)$ 分解为

$$\begin{aligned}P(X_n=k)&=\binom{n}{k}p_n^k(1-p_n)^{n-k}\\&=\frac{\lambda_n^k}{k!}\cdot\underbrace{\frac{n(n-1)\cdots(n-k+1)}{n^k}}_{A_n}\cdot\underbrace{\left(1-\frac{\lambda_n}{n}\right)^n}_{B_n}\cdot\underbrace{\left(1-\frac{\lambda_n}{n}\right)^{-k}}_{C_n}.\end{aligned}$$

分别求三个因子的极限。

(1) $A_n \to 1$。因为 k 固定，因子个数有限，且每项 $1-\dfrac{j}{n}\to 1$，故

$$A_n=\prod_{j=0}^{k-1}\left(1-\frac{j}{n}\right)\to 1.$$

(2) $B_n \to e^{-\lambda}$。由 $\lambda_n\to\lambda$ 及标准极限 $\left(1-\dfrac{x}{n}\right)^n\to e^{-x}$（$n\to\infty$），得

$$B_n=\left(1-\frac{\lambda_n}{n}\right)^n\to e^{-\lambda}.$$

(3) $C_n \to 1$。因为 $\lambda_n/n\to 0$，故 $\left(1-\dfrac{\lambda_n}{n}\right)^{-k}\to 1$。

又 $\lambda_n^k\to\lambda^k$，合并得

$$\lim_{n\to\infty}P(X_n=k)=\frac{\lambda^k}{k!}\cdot 1\cdot e^{-\lambda}\cdot 1=\frac{\lambda^k}{k!}e^{-\lambda}.$$

即 X_n 的极限分布为参数是 λ 的泊松分布。定理证毕。 □

注 2.6 (泊松近似的使用条件)**.** 泊松定理表明：当 n 很大、p 很小，而 $np=\lambda$ 保持适中时，二项分布 $B(n,p)$ 可以用泊松分布 $P(\lambda)$ 近似：

$$\binom{n}{k}p^k(1-p)^{n-k}\approx\frac{\lambda^k}{k!}e^{-\lambda},\qquad \lambda=np.$$

在实际应用中，通常当

$$n\ge 50,\qquad p\le 0.1$$

时，这一近似已经相当精确。当 n 更大、p 更小时，近似的效果更好。

例 2.8 (泊松近似的数值验证)**.** 设 $n=100, p=0.02$, 则 $\lambda=np=2$。比较二项分布 $B(100,0.02)$ 与泊松分布 $P(2)$ 在 $k=0,1,2,3$ 处的概率。

k	二项分布 $B(100,0.02)$	泊松分布 $P(2)$
0	$\binom{100}{0}(0.02)^0(0.98)^{100}\approx 0.1326$	$\dfrac{2^0}{0!}e^{-2}\approx 0.1353$
1	$\binom{100}{1}(0.02)^1(0.98)^{99}\approx 0.2707$	$\dfrac{2^1}{1!}e^{-2}\approx 0.2707$
2	$\binom{100}{2}(0.02)^2(0.98)^{98}\approx 0.2734$	$\dfrac{2^2}{2!}e^{-2}\approx 0.2707$
3	$\binom{100}{3}(0.02)^3(0.98)^{97}\approx 0.1823$	$\dfrac{2^3}{3!}e^{-2}\approx 0.1804$

从表中可以看出，即使在 $n=100$ 这样的中等规模下，二项分布与泊松分布的差异也已经很小。

例 2.9 (二项分布的泊松近似)**.** 某工厂产品的次品率为 $p=0.01$。现从产品中随机抽取 $n=200$ 件。求恰好抽到 2 件次品的概率。

解. 设 X 为 200 件中次品的件数，则 $X \sim B(200, 0.01)$。由二项分布公式，

$$P(X=2) = \binom{200}{2}(0.01)^2(0.99)^{198}.$$

直接计算较为繁琐。由于 $n=200$ 很大、$p=0.01$ 很小，而

$$\lambda = np = 200 \times 0.01 = 2$$

保持适中，故可用泊松分布 $P(2)$ 近似：

$$P(X=2) \approx \frac{2^2}{2!}e^{-2} = 2e^{-2} \approx 0.2707.$$

若用二项分布精确计算，结果为

$$P(X=2) = \binom{200}{2}(0.01)^2(0.99)^{198} \approx 0.2720,$$

与泊松近似的结果非常接近。这验证了泊松定理的实用性。 □

注 2.7. *泊松近似在 $n \geq 50$ 且 $p \leq 0.1$ 时已经相当精确。n 越大、p 越小，近似效果越好。*

2.5 本节小结

本节小结

(1) **离散型随机变量**：全部可能取值是有限个或可列无穷个，即

$$X \in \{x_1, x_2, \ldots, x_n\} \quad \text{或} \quad X \in \{x_1, x_2, \ldots\}.$$

(2) **分布律**：$p_k = P(X = x_k)$，$k = 1, 2, \ldots$，满足

$$p_k \geq 0, \qquad \sum_k p_k = 1.$$

(3) **分布律的三种表示**：表格表示、公式表示、图形表示。

(4) **与分布函数的关系**：

$$F(x) = P(X \leq x) = \sum_{x_k \leq x} p_k,$$

$F(x)$ 是右连续的阶梯函数，在每个可能取值 x_k 处有一个跳跃，跳跃高度恰好等于 p_k。反过来，

$$p_k = F(x_k) - F(x_{k-1}).$$

(5) **常见的离散型随机变量**：

- **退化分布**：$P(X = c) = 1$；
- **两点分布**：$X \sim B(1, p)$，$P(X = 1) = p$，$P(X = 0) = 1 - p$；
- **几何分布**：$X \sim G(p)$，$P(X = k) = (1-p)^{k-1}p$，$k = 1, 2, \ldots$；
- **二项分布**：$X \sim B(n, p)$，$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$；
- **泊松分布**：$X \sim P(\lambda)$，$P(X = k) = \dfrac{\lambda^k}{k!} e^{-\lambda}$。

(6) **重要性质**：

- 泊松定理：当 n 很大、p 很小、$np = \lambda$ 时，

$$\binom{n}{k} p^k (1-p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}.$$

- 几何分布的无记忆性：$P(X > m + n \mid X > m) = P(X > n)$。

2.6 习题

1. **（分布律的规范性）**

设随机变量 X 的分布律为

$$P(X = k) = c \cdot \frac{1}{2^k}, \qquad k = 1, 2, 3, \ldots$$

求常数 c 的值。

2. **（分布函数与概率）**

设随机变量 X 的分布函数为

$$F(x)=\begin{cases}0, & x<-1,\\ 0.2, & -1\le x<0,\\ 0.5, & 0\le x<1,\\ 1, & x\ge 1.\end{cases}$$

求 $P(X=0)$、$P(X<0)$、$P(0<X\le 1)$。

3. **（几何分布）**

某射手每次命中目标的概率为 $p=0.4$，独立射击直到首次命中。求：

(a) 恰好射击 3 次才命中的概率；

(b) 至多射击 3 次就命中的概率。

4. **（二项分布）**

某工厂产品的次品率为 $p=0.02$。现从产品中随机抽取 20 件，求：

(a) 恰好抽到 1 件次品的概率；

(b) 至少抽到 1 件次品的概率。

5. **（二项分布的可加性）**

甲、乙两台机器独立生产同一种产品，次品率均为 $p=0.05$。现从甲的产品中随机抽取 8 件，从乙的产品中随机抽取 12 件。求这 20 件产品中恰好有 2 件次品的概率。

6. **（泊松分布）**

某电话交换台每分钟接到的呼叫次数 X 服从参数为 $\lambda=4$ 的泊松分布。求：

(a) 一分钟内恰好接到 2 次呼叫的概率；

(b) 一分钟内接到不超过 1 次呼叫的概率。

7. **（负二项分布）**

某射手每次命中目标的概率为 $p=0.3$，独立射击直到第 3 次命中为止。求：

(a) 恰好射击 8 次才完成第 3 次命中的概率；

(b) 第 3 次命中所需的射击次数不超过 5 次的概率。

8. **（负二项分布与几何分布的关系）**

在独立重复的 Bernoulli 试验中，每次成功的概率为 p。设 X 为第 r 次成功所需的试验次数。

(a) 写出 X 的分布律；

(b) 说明当 $r=1$ 时，X 服从什么分布；

(c) 证明 X 可以表示为 r 个独立几何分布随机变量之和。

3 一维连续型随机变量

在上一节中，我们讨论了离散型随机变量，其取值是有限个或可列无限个。然而，在实际问题中，许多随机现象的可能取值是充满一个区间的，例如灯泡的寿命、某地区的气温、测量误差等。这类随机变量称为**连续型随机变量**。本节将系统介绍连续型随机变量的定义、性质以及常见的连续型分布。

3.1 连续型随机变量的定义

定义 3.1 (连续型随机变量). 设随机变量 X 的分布函数为 $F(x)$。如果存在一个非负可积函数 $f(x)$，使得对任意实数 x，有

$$F(x) = \int_{-\infty}^{x} f(t)\,dt,$$

则称 X 为**连续型随机变量**，并称 $f(x)$ 为 X 的**概率密度函数**（*Probability Density Function*，简称 *PDF*）。

注 3.1. 连续型随机变量具有以下三条基本特征：

(1) 分布函数 $F(x)$ 是连续函数；

(2) 对任意实数 a，有 $P(X = a) = 0$。这意味着连续型随机变量取单个值的概率为零。因此，概率为零的事件不一定是不可能事件；

(3) 对任意 $a < b$，有

$$P(a < X \le b) = P(a \le X \le b) = P(a < X < b) = \int_a^b f(x)\,dx.$$

几何解释：$f(x)$ 的图形称为密度曲线，X 落在区间 $[a, b]$ 内的概率等于密度曲线下从 a 到 b 的面积，见图 7。

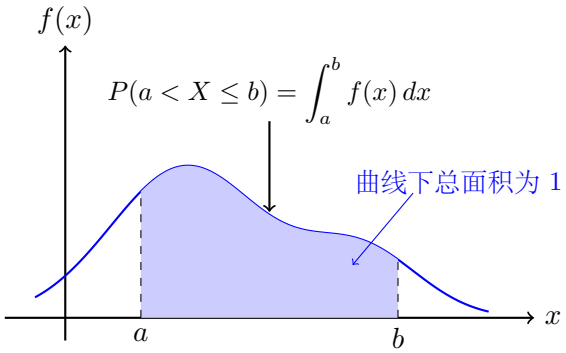


图 7: 连续型随机变量的概率密度函数 $f(x)$：曲线下总面积等于 1；X 落在区间 $(a, b]$ 内的概率等于阴影部分的面积。

3.2 概率密度函数的性质

命题 3.1. 概率密度函数 $f(x)$ 具有以下四条性质：

(1) **非负性**：$f(x) \geq 0$ 对所有 x 成立；

(2) **规范性**：$\displaystyle\int_{-\infty}^{+\infty} f(x)\,dx = 1$；

(3) **与分布函数的关系**：若 $f(x)$ 在点 x 处连续，则 $F'(x) = f(x)$；

(4) **区间概率公式**：对任意区间 G，有 $P(X \in G) = \displaystyle\int_G f(x)\,dx$。

例 3.1. 设连续型随机变量 X 的概率密度函数为

$$f(x) = \begin{cases} c(4x - 2x^2), & 0 < x < 2, \\ 0, & \text{其他}. \end{cases}$$

求：*(1)* 常数 c；*(2)* $P(X > 1)$；*(3)* 分布函数 $F(x)$。

解. (1) 由规范性条件 $\int_{-\infty}^{+\infty} f(x)\,dx = 1$，得

$$\int_0^2 c(4x - 2x^2)\,dx = c\left[2x^2 - \frac{2}{3}x^3\right]_0^2 = c \cdot \frac{8}{3} = 1,$$

故 $c = \dfrac{3}{8}$。

(2)

$$P(X > 1) = \int_1^2 \frac{3}{8}(4x - 2x^2)\,dx = \frac{3}{8}\left[2x^2 - \frac{2}{3}x^3\right]_1^2 = \frac{1}{2}.$$

(3) 分布函数 $F(x) = \int_{-\infty}^{x} f(t)\,dt$。分情况讨论：

- 当 $x \leq 0$ 时，$F(x) = 0$；
- 当 $0 < x < 2$ 时，

$$F(x) = \int_0^x \frac{3}{8}(4t - 2t^2)\,dt = \frac{3}{8}\left(2x^2 - \frac{2}{3}x^3\right) = \frac{3}{4}x^2 - \frac{1}{4}x^3;$$

- 当 $x \geq 2$ 时，$F(x) = 1$。

因此

$$F(x) = \begin{cases} 0, & x \leq 0, \\ \dfrac{3}{4}x^2 - \dfrac{1}{4}x^3, & 0 < x < 2, \\ 1, & x \geq 2. \end{cases}$$

□

3.3 常见的连续型分布

一、均匀分布

定义 3.2 (均匀分布)**.** 若随机变量 X 的概率密度函数为

$$f(x) = \begin{cases} \dfrac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{其他}, \end{cases}$$

则称 X 服从区间 $[a,b]$ 上的**均匀分布**，记作 $X \sim U[a,b]$。

分布函数：

$$F(x)=\begin{cases}0, & x<a,\\ \dfrac{x-a}{b-a}, & a\le x<b,\\ 1, & x\ge b.\end{cases}$$

几何意义：均匀分布意味着 X 落在 $[a,b]$ 内任意等长子区间的概率相等，且该概率仅与子区间长度有关，与位置无关。

例 3.2. 设 $X\sim U[0,10]$，求 $P(X<3)$，$P(X>6)$，$P(3<X<8)$。

解.

$$P(X<3)=\int_0^3\frac{1}{10}\,dx=\frac{3}{10},\quad P(X>6)=\int_6^{10}\frac{1}{10}\,dx=\frac{4}{10},\quad P(3<X<8)=\int_3^8\frac{1}{10}\,dx=\frac{1}{2}.$$

□

二、指数分布

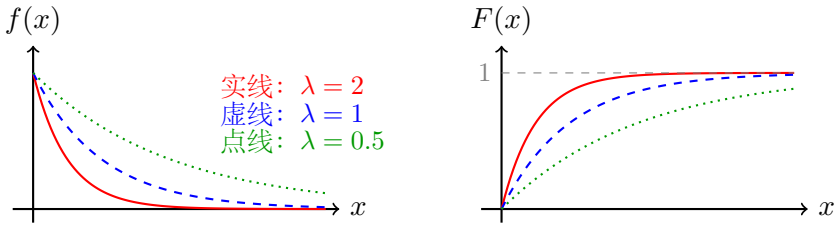
定义 3.3 (指数分布)**.** 若随机变量 X 的概率密度函数为

$$f(x)=\begin{cases}\lambda e^{-\lambda x}, & x\ge 0,\\ 0, & x<0,\end{cases}$$

其中 $\lambda>0$ 为参数，则称 X 服从参数为 λ 的**指数分布**，记作 $X\sim E(\lambda)$。

分布函数：

$$F(x)=\begin{cases}1-e^{-\lambda x}, & x\ge 0,\\ 0, & x<0.\end{cases}$$



(a) 密度函数 $f(x)=\lambda e^{-\lambda x}$　　(b) 分布函数 $F(x)=1-e^{-\lambda x}$

命题 3.2 (无记忆性)**.** 设 $X\sim E(\lambda)$，则对任意 $s,t>0$，

$$P(X>s+t\mid X>s)=P(X>t).$$

这一性质称为指数分布的**无记忆性**，是指数分布独有的重要特征。

证明. 由条件概率的定义，

$$P(X>s+t\mid X>s)=\frac{P(X>s+t)}{P(X>s)}=\frac{e^{-\lambda(s+t)}}{e^{-\lambda s}}=e^{-\lambda t}=P(X>t).$$

□

注 3.2. 无记忆性的直观含义是：已知元件已经使用了 s 小时，它还能再使用至少 t 小时的概率，与一个全新元件能使用至少 t 小时的概率相同。即“过去不影响未来”。指数分布常用于描述独立随机事件发生的时间间隔，如电话通话时间、元件的寿命、顾客到达的时间间隔等。

注 3.3 (指数分布的含义：连续状态下的”等待时间”)**.** 指数分布描述的是**连续状态**下的”等待时间”：系统持续处于某个状态（例如元件持续正常工作、顾客持续等待服务），直到状态发生改变（例如元件失效、顾客被服务）为止，这段连续时间 X 就服从指数分布。

换句话说：

- **持续**：系统在 $[0, X)$ 这段时间里一直保持同一状态；
- **一旦改变就停止**：在时刻 X，状态发生改变，过程随即停止。

参数 λ 可以理解为**状态改变的速率**：λ 越大，单位时间内状态改变的可能性越大，平均等待时间 $E(X) = 1/\lambda$ 就越短。

指数分布与第 *2* 节介绍的**几何分布**形成一对”离散—连续”的对应：

	几何分布	**指数分布**
状态	离散（每次试验两个状态）	连续（时间轴上的一个状态）
等待对象	试验次数 k	持续时间 x
参数	p（每次试验状态改变的概率）	λ（单位时间状态改变的速率）
分布律/密度	$(1-p)^{k-1}p$	$\lambda e^{-\lambda x}$
期望	$1/p$	$1/\lambda$
核心性质	无记忆性	无记忆性
典型例子	反复射击直到首次命中	灯泡的寿命、等待电话接通的时间

两分布都具有**无记忆性**：

$$\text{几何分布：}\quad P(X > m+n \mid X > m) = P(X > n);$$

$$\text{指数分布：}\quad P(X > s+t \mid X > s) = P(X > t).$$

这一性质正是”过去不影响未来”这一特征的精确刻画，也是这两种分布被广泛用于”寿命””等待时间”等模型的原因。

例 3.3. 设某电话通话时间 X（单位：分钟）服从参数 $\lambda = \frac{1}{10}$ 的指数分布。求：*(1)* 通话时间超过 *15* 分钟的概率；*(2)* 已知通话已持续 *10* 分钟，再持续超过 *15* 分钟的概率。

解. (1) $P(X > 15) = e^{-15\lambda} = e^{-1.5} \approx 0.2231$。

(2) 由无记忆性，

$$P(X > 15 \mid X > 10) = P(X > 5) = e^{-5\lambda} = e^{-0.5} \approx 0.6065.$$

□

定义 3.4 (失效率函数)**.** 设连续型随机变量 X 表示某元件的寿命，其概率密度函数为 $f(x)$，分布函数为 $F(x)$。定义

$$\lambda(x) = \frac{f(x)}{1 - F(x)}, \qquad x > 0 \text{ 且} F(x) < 1,$$

称 $\lambda(x)$ 为 X 的**失效率函数**（*hazard rate function*），也称**风险率函数**或**故障率函数**。

注 3.4 (失效率函数的直观含义)**.** 失效率函数 $\lambda(x)$ 刻画的是：**在元件已经存活到时刻 x 的条件下，它在时刻 x 附近单位时间内发生失效的条件概率强度**。

具体地说，对充分小的 $\Delta x > 0$，

$$P(x < X \le x + \Delta x \mid X > x) = \frac{P(x < X \le x + \Delta x)}{P(X > x)} \approx \frac{f(x)\Delta x}{1 - F(x)} = \lambda(x)\Delta x.$$

因此，$\lambda(x)\Delta x$ 近似等于"已存活到 x 的元件在下一小段时间 Δx 内失效"的概率。

命题 3.3 (指数分布的失效率为常数)**.** 设 $X \sim E(\lambda)$，则 X 的失效率函数为常数：

$$\lambda(x) = \lambda, \qquad x > 0.$$

反之，若某连续型非负随机变量的失效率函数为常数 λ，则它必服从指数分布 $E(\lambda)$。

证明. 设 $X \sim E(\lambda)$，则

$$f(x) = \lambda e^{-\lambda x}, \qquad 1 - F(x) = P(X > x) = e^{-\lambda x}, \qquad x > 0.$$

代入失效率函数的定义：

$$\lambda(x) = \frac{f(x)}{1 - F(x)} = \frac{\lambda e^{-\lambda x}}{e^{-\lambda x}} = \lambda, \qquad x > 0.$$

即指数分布的失效率函数为常数 λ，不随时间变化。

反之，若 $\lambda(x) \equiv \lambda$，则由

$$\lambda(x) = \frac{F'(x)}{1 - F(x)} = -\frac{d}{dx}\ln[1 - F(x)]$$

两边从 0 到 x 积分，得

$$\ln[1 - F(x)] = -\lambda x + C.$$

由 $F(0) = 0$，得 $C = 0$，故

$$1 - F(x) = e^{-\lambda x}, \qquad F(x) = 1 - e^{-\lambda x}, \qquad x \ge 0,$$

这正是指数分布 $E(\lambda)$ 的分布函数。 □

注 3.5 (失效率与无记忆性的关系)**.** 指数分布的失效率函数为常数，这与它的无记忆性是同一事实的两种表述：

- **无记忆性**：已知元件已使用 s 小时，其剩余寿命的分布与全新元件相同；
- **常数失效率**：无论元件已使用了多久，它在下一瞬间失效的条件概率强度始终保持为 λ。

因此，指数分布是唯一具有常数失效率的连续型分布。这也是它在可靠性理论中被广泛使用的原因：当元件的失效完全由随机因素引起、与"老化"无关时，指数分布是一个合适的模型。

例 3.4 (失效率函数随时间变化的情形). 设某元件的寿命 X 服从形状参数为 $\alpha = 2$、速率参数为 $\beta = 1$ 的伽马分布，即

$$f(x) = xe^{-x}, \qquad x > 0,$$

其分布函数为

$$F(x) = 1 - (1 + x)e^{-x}, \qquad x > 0.$$

求失效率函数 $\lambda(x)$，并说明它的变化趋势。

解. 由失效率函数的定义，

$$\lambda(x) = \frac{f(x)}{1 - F(x)} = \frac{xe^{-x}}{(1 + x)e^{-x}} = \frac{x}{1 + x}, \qquad x > 0.$$

对 $\lambda(x)$ 求导：

$$\lambda'(x) = \frac{(1 + x) - x}{(1 + x)^2} = \frac{1}{(1 + x)^2} > 0, \qquad x > 0.$$

所以 $\lambda(x)$ 关于 x 严格递增，且

$$\lim_{x \to 0^+} \lambda(x) = 0, \qquad \lim_{x \to +\infty} \lambda(x) = 1.$$

这说明该元件的失效率随时间增大：使用时间越长，越容易在下一瞬间失效，即具有明显的“老化”特征。这与指数分布的常数失效率形成对比。 □

注 3.6 (失效率函数的三种典型形态). 根据 $\lambda(x)$ 随 x 的变化趋势，可以将寿命分布分为三种典型类型：

(1) **递减型** ($\lambda'(x) < 0$)：失效率随时间下降，如早期失效阶段（“婴儿死亡率”），典型代表是形状参数 $\alpha < 1$ 的伽马分布或 *Weibull* 分布；

(2) **常数型** ($\lambda'(x) = 0$)：失效率保持恒定，无老化、无早期缺陷，典型代表是指数分布；

(3) **递增型** ($\lambda'(x) > 0$)：失效率随时间上升，如磨损、老化引起的后期失效，典型代表是形状参数 $\alpha > 1$ 的伽马分布或 *Weibull* 分布。

这里补充说明 *Weibull* 分布的定义，伽马分布较复杂，定义和性质见下。设 X 为某元件的寿命，若其概率密度函数为

$$f(x) = \begin{cases} \dfrac{\beta}{\eta} \left(\dfrac{x - \gamma}{\eta} \right)^{\beta - 1} \exp\left[- \left(\dfrac{x - \gamma}{\eta} \right)^{\beta} \right], & x > \gamma, \\ 0, & x \le \gamma, \end{cases}$$

则称 X 服从参数为 (γ, η, β) 的 ***Weibull* 分布**，记作 $X \sim Weibull(\gamma, \eta, \beta)$，其中

- $\gamma \in \mathbb{R}$ 为**位置参数**，也称门限参数，表示寿命的下界；
- $\eta > 0$ 为**尺度参数**，决定曲线的横向尺度；
- $\beta > 0$ 为**形状参数**，决定密度曲线的形状和失效率的变化趋势。

其分布函数为

$$F(x)=\begin{cases}1-\exp\left[-\left(\dfrac{x-\gamma}{\eta}\right)^{\beta}\right], & x>\gamma,\\ 0, & x\le\gamma.\end{cases}$$

对应的失效率函数为

$$\lambda(x)=\frac{f(x)}{1-F(x)}=\frac{\beta}{\eta}\left(\frac{x-\gamma}{\eta}\right)^{\beta-1},\qquad x>\gamma.$$

由此可见，*Weibull* 分布的失效率只由形状参数 β 决定：

- 当 $\beta<1$ 时，$\lambda(x)$ 严格递减，适合刻画早期失效；
- 当 $\beta=1$ 时，$\lambda(x)\equiv\dfrac{1}{\eta}$ 为常数，此时 *Weibull* 分布退化为指数分布 $E(1/\eta)$；
- 当 $\beta>1$ 时，$\lambda(x)$ 严格递增，适合刻画磨损、老化引起的后期失效。

在工程可靠性分析中，“浴盆曲线”(*bathtub curve*) 就是这三种形态在元件全寿命周期内的组合：早期递减、中期常数、后期递增，而 *Weibull* 分布因能通过形状参数 β 自由调节失效率趋势，成为寿命数据分析中最常用的分布之一。

三、正态分布

定义 3.5 (正态分布)**.** 若随机变量 X 的概率密度函数为

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}},\quad -\infty<x<+\infty,$$

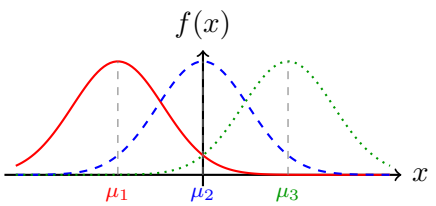
其中 $-\infty<\mu<+\infty$，$\sigma>0$ 为参数，则称 X 服从参数为 μ 和 σ^2 的**正态分布**，记作 $X\sim N(\mu,\sigma^2)$。

设 $X\sim N(\mu,\sigma^2)$，其分布函数为

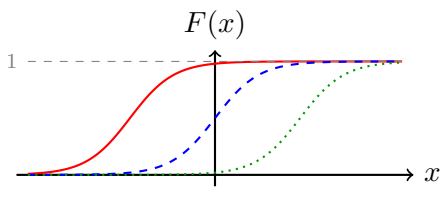
$$F(x)=P(X\le x)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(t-\mu)^2}{2\sigma^2}}\,dt,\quad -\infty<x<+\infty.$$

标准正态分布：当 $\mu=0$，$\sigma=1$ 时，称 X 服从**标准正态分布**，记作 $Z\sim N(0,1)$。其密度函数和分布函数分别记为

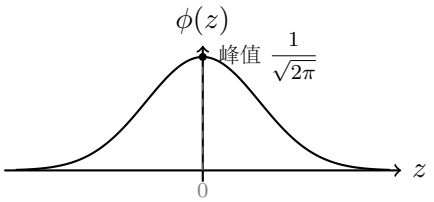
$$\phi(x)=\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}},\quad \Phi(x)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}\,dt.$$



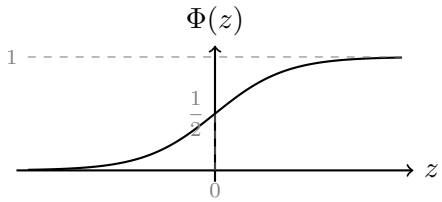
(a) 相同 σ，不同 μ 的密度 $f(x)$



(b) 相同 σ，不同 μ 的分布 $F(x)$



(c) 标准正态密度 $\phi(z)$

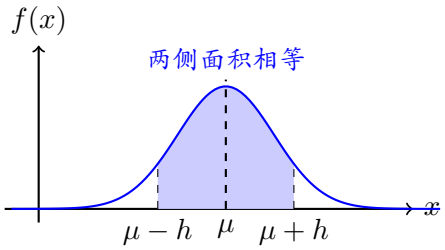


(d) 标准正态分布 $\Phi(z)$

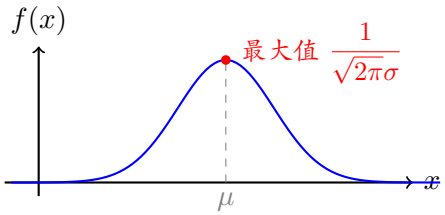
命题 3.4 (正态分布的性质)**.** 正态分布具有以下性质：

(1) **对称性**：密度曲线关于直线 $x=\mu$ 对称。即对任意 $h>0$，

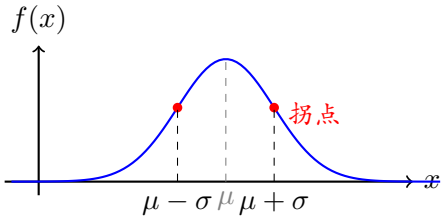
$$P(\mu-h<X\le\mu)=P(\mu<X\le\mu+h).$$



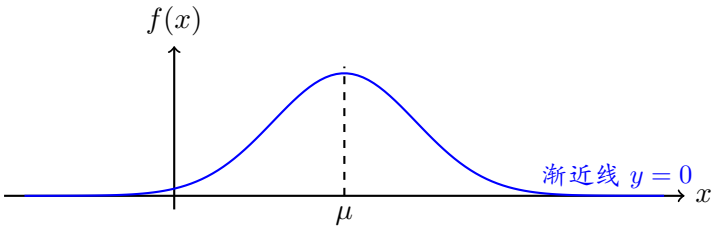
(2) **最大值**：在 $x=\mu$ 处，$f(x)$ 取得最大值 $\dfrac{1}{\sqrt{2\pi}\sigma}$。



(3) **拐点**：曲线在 $x=\mu\pm\sigma$ 处由向上凸变为向下凸（或反之），即拐点位于 $x=\mu\pm\sigma$。

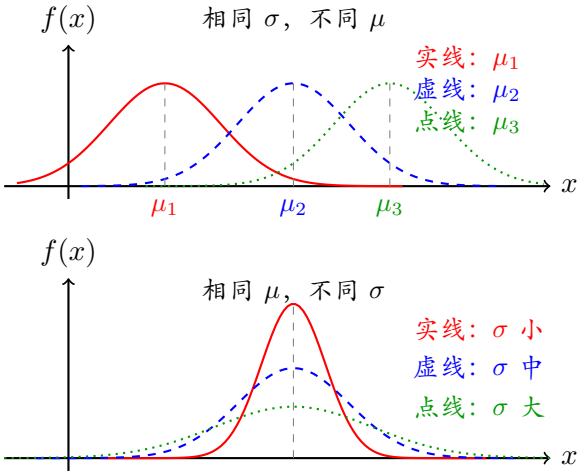


(4) **渐近线**：x 轴是密度曲线的水平渐近线，曲线向两侧无限延伸但永不与 x 轴相交。



(5) **参数影响**：

- μ 决定曲线的位置（对称中心），μ 增大曲线右移，μ 减小曲线左移。
- σ 决定曲线的形状（陡峭或平缓），σ 越小曲线越陡峭（数据越集中），σ 越大曲线越平缓（数据越分散）。

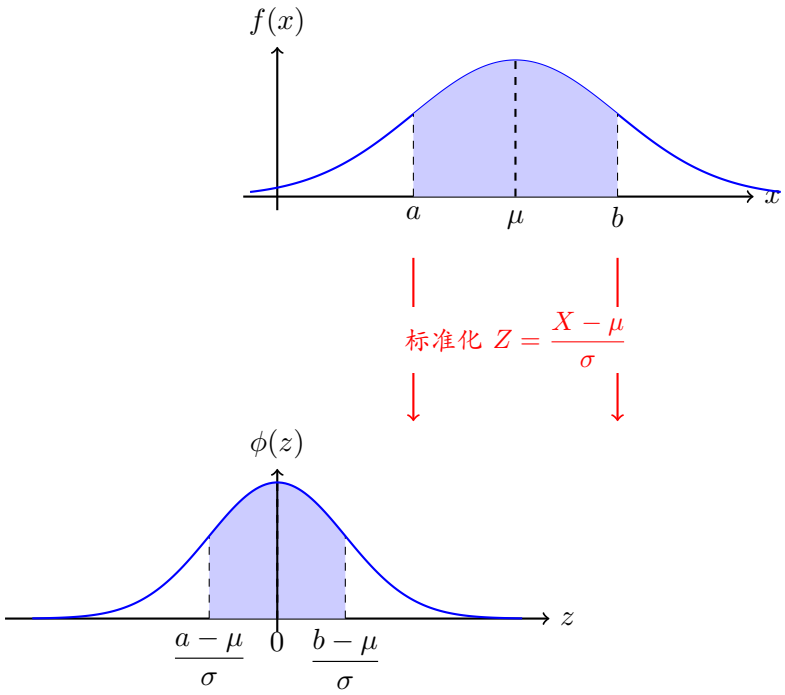


(6) **标准化**：若 $X \sim N(\mu, \sigma^2)$，则

$$Z = \frac{X-\mu}{\sigma} \sim N(0,1).$$

因此，

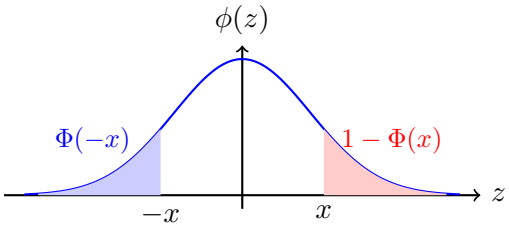
$$P(a < X \le b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right).$$



(7) **标准正态分布的对称性**：

$$\Phi(-x) = 1 - \Phi(x).$$

两块面积相等



(8) 3σ **原则**:

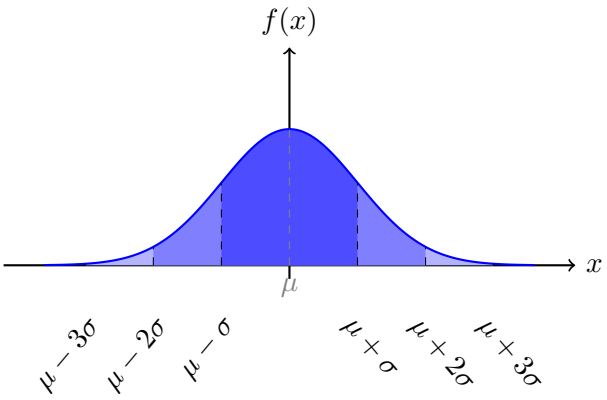
$$P(\mu-\sigma<X\le\mu+\sigma)\approx 68.26\%,$$

$$P(\mu-2\sigma<X\le\mu+2\sigma)\approx 95.44\%,$$

$$P(\mu-3\sigma<X\le\mu+3\sigma)\approx 99.74\%.$$

即几乎所有观测值都落在 $(\mu-3\sigma,\mu+3\sigma)$ 内。

3σ 原则：99.74% 的观测值落在 $(\mu-3\sigma,\mu+3\sigma)$ 内



分位点

在实际查表和计算中，我们经常遇到相反的问题：已知概率 α，要求出对应的 x，使得 $P(X>x)=\alpha$，或者 $P(X\le x)=\alpha$。这就需要引入分位点的概念。

定义 3.6 (上 α 分位点)**.** 设随机变量 X 的分布函数为 $F(x)=P(X\le x)$，$0<\alpha<1$。若实数 x_α 满足

$$P(X>x_\alpha)=\alpha,$$

则称 x_α 为 X 的**上 α 分位点**（*upper α-quantile*），简称**上分位点**或**右分位点**。

注 3.7 (以正态分布为例)**.** **（一）上 α 分位点的含义与等价定义**

上 α 分位点的含义是：随机变量 X 落在 x_α 右侧的概率恰好等于 α。也就是说，x_α 把整个概率分布“切”出一段右尾，其面积为 α。

由于 $P(X>x_\alpha)=\alpha$，等价地有

$$P(X\le x_\alpha)=1-\alpha,$$

即

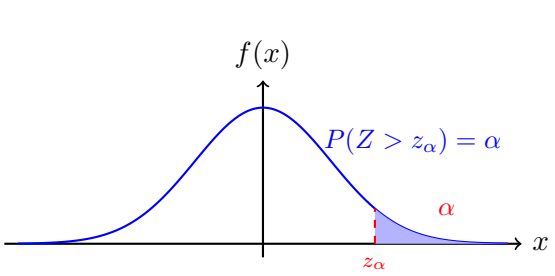
$$F(x_\alpha) = 1 - \alpha.$$

因此，上 α 分位点也可以定义为满足 $F(x_\alpha) = 1 - \alpha$ 的实数 x_α。

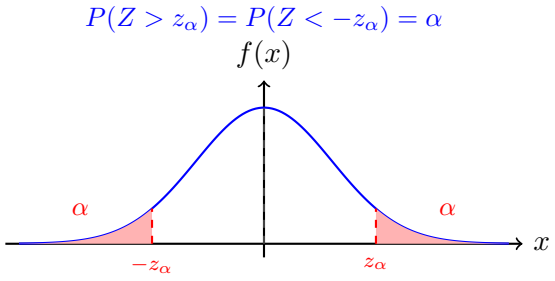
（二）几何直观

下面两幅图可以帮助理解上 α 分位点的几何含义：

- **左图**：z_α 把标准正态密度曲线右侧的尾部“切”出一块面积为 α 的区域，即 $P(Z > z_\alpha) = \alpha$；
- **右图**：由标准正态分布的对称性，左右两侧尾部面积相等，因此有 $P(Z > z_\alpha) = P(Z < -z_\alpha) = \alpha$，即 $z_{1-\alpha} = -z_\alpha$。



(a) 上 α 分位点 z_α：右尾面积为 α



(b) 对称性：$z_{1-\alpha} = -z_\alpha$

（三）由对称性得到的推论

由右图可见，标准正态分布关于 y 轴对称，因此左右两侧尾部面积相等。这给出上分位点的一个重要推论：

$$P(Z > z_\alpha) = P(Z < -z_\alpha) = \alpha,$$

即

$$z_{1-\alpha} = -z_\alpha.$$

这一关系式在许多计算中非常实用：当需要查表求 $z_{1-\alpha}$ 时，只需先查 z_α 再取相反数即可。

定义 3.7 (下 α 分位点)**.** 设随机变量 X 的分布函数为 $F(x) = P(X \le x)$，$0 < \alpha < 1$。若实数 $x_{(\alpha)}$ 满足

$$P(X \le x_{(\alpha)}) = \alpha,$$

则称 $x_{(\alpha)}$ 为 X 的**下 α 分位点** (*lower α-quantile*)，简称**下分位点**或**左分位点**。

注 3.8 (以正态分布为例)**.** **（一）下 α 分位点的含义与等价定义**

下 α 分位点的含义是：随机变量 X 落在 $x_{(\alpha)}$ 左侧的概率恰好等于 α。也就是说，$x_{(\alpha)}$ 把整个概率分布“切”出一段左尾，其面积为 α。

由于 $P(X \le x_{(\alpha)}) = \alpha$，等价地有

$$P(X > x_{(\alpha)}) = 1 - \alpha,$$

即

$$F(x_{(\alpha)}) = \alpha.$$

因此，下 α 分位点也可以定义为满足 $F(x_{(\alpha)}) = \alpha$ 的实数 $x_{(\alpha)}$。

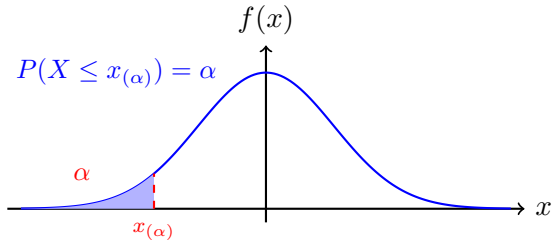
（二）几何直观

下面两幅图可以帮助理解下 α 分位点的几何含义：

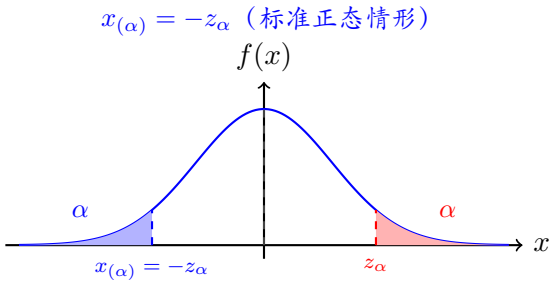
- **左图**：$x_{(\alpha)}$ 把标准正态密度曲线左侧的尾部“切”出一块面积为 α 的区域，即 $P(X \le x_{(\alpha)}) = \alpha$；
- **右图**：由标准正态分布的对称性，左侧尾部（蓝色）与右侧尾部（红色）面积相等，因此有

$$x_{(\alpha)} = -z_\alpha,$$

即下 α 分位点等于上 α 分位点的相反数。



(a) 下 α 分位点 $x_{(\alpha)}$：左尾面积为 α



(b) 上下分位点的对称关系

（三）下分位点与上分位点的关系

综合上述结论，下分位点与上分位点之间有如下对应关系：

$$x_{(\alpha)} = x_{1-\alpha},$$

即“下 α 分位点”等于“上 $(1-\alpha)$ 分位点”。在标准正态情形下，这一关系可以进一步写成

$$x_{(\alpha)} = -z_\alpha.$$

因此在许多教材中，只定义上分位点，下分位点通过上述关系式得到。

注 3.9. 上分位点和下分位点之间的关系是：

$$x_{(\alpha)} = x_{1-\alpha},$$

即”下 α 分位点”等于”上 $(1-\alpha)$ 分位点”。因此在许多教材中，只定义上分位点，下分位点通过上述关系式得到。

标准正态分布的分位点 对标准正态分布 $Z \sim N(0,1)$，记其上 α 分位点为 z_α，即

$$P(Z > z_\alpha) = \alpha, \qquad 0 < \alpha < 1.$$

等价地，

$$\Phi(z_\alpha) = 1 - \alpha, \qquad z_\alpha = \Phi^{-1}(1-\alpha).$$

这里的 Φ^{-1} 是标准正态分布函数 Φ 的反函数。

由标准正态分布的对称性，可以推出

$$z_{1-\alpha} = -z_\alpha,$$

即上 $1-\alpha$ 分位点与上 α 分位点互为相反数。

一些常用的上分位点数值如下：

α	0.10	0.05	0.025	0.01	0.005
z_α	1.282	1.645	1.960	2.326	2.576

例如，当 $\alpha = 0.05$ 时，

$$P(Z > 1.645) = 0.05, \qquad P(Z < -1.645) = 0.05.$$

注 3.10 (一般正态分布与上分位点)**.** 设 $X \sim N(\mu, \sigma^2)$，z_α 为标准正态分布的上 α 分位点。由标准化变换

$$Z = \frac{X-\mu}{\sigma} \sim N(0,1),$$

可得 X 的上 α 分位点为

$$x_\alpha = \mu + \sigma z_\alpha.$$

这是因为

$$P(X > \mu + \sigma z_\alpha) = P\left(\frac{X-\mu}{\sigma} > z_\alpha\right) = P(Z > z_\alpha) = \alpha.$$

即一般正态分布的上 α 分位点可以通过标准正态分布的上 α 分位点 z_α 线性变换得到。

注 3.11 (解题方法)**.** 对于正态分布的概率计算，核心步骤是**标准化**。即先将 X 转化为标准正态变量 $Z = \dfrac{X-\mu}{\sigma}$，然后查标准正态分布表或利用对称性计算。

例 3.5. 设 $X \sim N(2, 9)$，求 $P(1 \le X < 5)$。

解.

$$\begin{aligned} P(1 \le X < 5) &= \Phi\left(\frac{5-2}{3}\right) - \Phi\left(\frac{1-2}{3}\right) \\ &= \Phi(1) - \Phi\left(-\frac{1}{3}\right) \\ &= \Phi(1) + \Phi\left(\frac{1}{3}\right) - 1 \\ &\approx 0.8413 + 0.6293 - 1 = 0.4706. \end{aligned}$$

□

例 3.6. 某大学入学考试（*CEE*）成绩服从正态分布 $N(510, 60^2)$。某大学只考虑成绩超过 *650* 分的申请者。求所有考生中满足该大学要求的比例。

解. 设 X 为考生成绩，则 $X \sim N(510, 60^2)$。

$$P(X > 650) = 1 - \Phi\left(\frac{650-510}{60}\right) = 1 - \Phi(2.33) \approx 1 - 0.9901 = 0.0099.$$

即约 0.99% 的考生满足要求。 □

四、伽马分布 *

定义 3.8 (伽马分布)**.** 若随机变量 X 的概率密度函数为

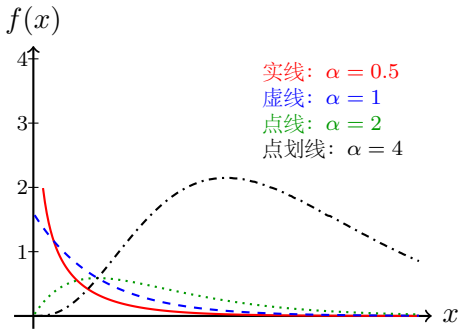
$$f(x)=\begin{cases}\dfrac{\beta^{\alpha}}{\Gamma(\alpha)}x^{\alpha-1}e^{-\beta x}, & x>0,\\ 0, & x\le 0,\end{cases}$$

其中 $\alpha>0$，$\beta>0$ 为参数，$\Gamma(\alpha)=\displaystyle\int_0^{+\infty}x^{\alpha-1}e^{-x}\,dx$ 为伽马函数，则称 X 服从参数为 α 和 β 的**伽马分布**，记作

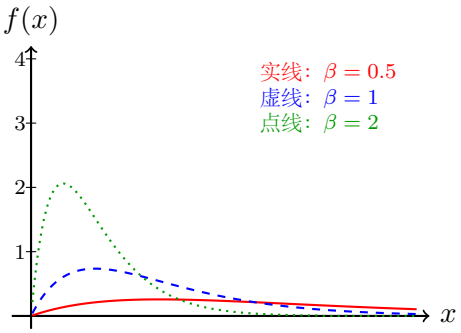
$$X\sim Gamma(\alpha,\beta).$$

注 3.12. 伽马分布中的两个参数各有明确的含义：

- α 称为**形状参数**，它决定密度曲线的形状；
- β 称为**速率参数**，它决定密度曲线的尺度；
- 当 β 固定而 α 变化时，密度曲线的形状发生改变；
- 当 α 固定而 β 变化时，密度曲线沿 x 轴方向被拉伸或压缩。



(a) 固定 $\beta=1$，不同 α



(b) 固定 $\alpha=2$，不同 β

注 3.13 (图形解读)**.** 上面两幅图分别展示了伽马分布的两个参数对密度曲线的影响：

- **左图**（固定 $\beta=1$，不同 α）：
  - $\alpha=0.5$（实线）在 $x\to 0^{+}$ 时趋于 $+\infty$，为便于观察，图中将其幅度适当压低（x 从 0.15 起画）；
  - $\alpha=1$（虚线）退化为指数分布，曲线从最高点单调下降；
  - $\alpha=2$（点线）在 $x=1$ 附近有峰值，曲线呈单峰右偏；
  - $\alpha=4$（点划线）峰值进一步右移，分布形态更趋对称。

  可见 α 越大，密度曲线的峰值越靠右，形状越趋于对称。
- **右图**（固定 $\alpha=2$，不同 β）：
  - $\beta=0.5$（实线）曲线最平缓，尾部延伸最长，分布最分散；

– $\beta = 1$（虚线）为中间形态；

– $\beta = 2$（点线）曲线最陡峭，尾部迅速衰减，分布最集中。

可见 β 越大，曲线越“瘦高”，即分布越集中；β 越小，曲线越“矮胖”，即分布越分散。

伽马函数的性质 伽马函数 $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1}e^{-x}\,dx$（$\alpha > 0$）具有以下性质：

(1) **递推公式**：$\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$，$\alpha > 0$；

(2) **初始值**：$\Gamma(1) = 1$；

(3) **半整数值**：$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$；

(4) **正整数值**：当 n 为正整数时，$\Gamma(n) = (n-1)!$。

递推公式的证明. 由伽马函数的定义，对 $\alpha > 0$，

$$\Gamma(\alpha+1) = \int_0^{+\infty} x^{\alpha}e^{-x}\,dx.$$

用分部积分法，令

$$u = x^{\alpha}, \qquad dv = e^{-x}\,dx,$$

则

$$du = \alpha x^{\alpha-1}\,dx, \qquad v = -e^{-x}.$$

于是

$$\Gamma(\alpha+1) = \left[-x^{\alpha}e^{-x}\right]_0^{+\infty} + \alpha\int_0^{+\infty} x^{\alpha-1}e^{-x}\,dx.$$

下面分别处理两项。第一项：

$$\left[-x^{\alpha}e^{-x}\right]_0^{+\infty} = \lim_{x\to+\infty}(-x^{\alpha}e^{-x}) - \lim_{x\to0^+}(-x^{\alpha}e^{-x}).$$

当 $x \to +\infty$ 时，指数衰减 e^{-x} 比多项式增长 x^{α} 更快，故 $x^{\alpha}e^{-x} \to 0$；当 $x \to 0^+$ 时，$x^{\alpha} \to 0$，故 $x^{\alpha}e^{-x} \to 0$。因此第一项为 0。

第二项正是 $\alpha\Gamma(\alpha)$。所以

$$\Gamma(\alpha+1) = \alpha\Gamma(\alpha).$$

□

$\Gamma(1) = 1$ 的证明.

$$\Gamma(1) = \int_0^{+\infty} x^{0}e^{-x}\,dx = \int_0^{+\infty} e^{-x}\,dx = \left[-e^{-x}\right]_0^{+\infty} = 1.$$

□

$\Gamma\left(\frac{1}{2}\right)=\sqrt{\pi}$ 的证明. 由定义，

$$\Gamma\left(\frac{1}{2}\right)=\int_0^{+\infty} x^{-1/2}e^{-x}\,dx.$$

作变量替换 $x=t^2/2$，则 $dx=t\,dt$，$x^{-1/2}=\sqrt{2}/t$。代入得

$$\Gamma\left(\frac{1}{2}\right)=\int_0^{+\infty}\frac{\sqrt{2}}{t}e^{-t^2/2}\cdot t\,dt=\sqrt{2}\int_0^{+\infty}e^{-t^2/2}\,dt.$$

由标准正态分布的规范性，

$$\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{+\infty}e^{-t^2/2}\,dt=1,$$

故

$$\int_0^{+\infty}e^{-t^2/2}\,dt=\frac{1}{2}\cdot\sqrt{2\pi}=\sqrt{\frac{\pi}{2}}.$$

所以

$$\Gamma\left(\frac{1}{2}\right)=\sqrt{2}\cdot\sqrt{\frac{\pi}{2}}=\sqrt{\pi}.$$

□

$\Gamma(n)=(n-1)!$ 的证明. 由递推公式 $\Gamma(\alpha+1)=\alpha\Gamma(\alpha)$，反复应用：

$$\begin{aligned}\Gamma(n)&=(n-1)\Gamma(n-1)\\&=(n-1)(n-2)\Gamma(n-2)\\&=\cdots\\&=(n-1)(n-2)\cdots2\cdot1\cdot\Gamma(1)\\&=(n-1)!.\end{aligned}$$

□

伽马分布的特例 伽马分布是一大类分布的统称，通过选取不同的参数 α 和 β，可以得到以下几个重要分布：

- **指数分布**：当 $\alpha=1$ 时，伽马分布的密度为

  $$f(x)=\beta e^{-\beta x},\qquad x>0,$$

  这正是参数为 β 的指数分布，即

  $$\mathrm{Gamma}(1,\beta)=E(\beta).$$

- **爱尔朗分布**：当 $\alpha=n$（n 为正整数）时，伽马分布称为 n 阶**爱尔朗分布**。爱尔朗分布在排队论、可靠性理论中有重要应用，它表示 n 个独立同分布的指数随机变量之和的分布。

- **χ^2 分布**：当 $\alpha=\frac{n}{2}$，$\beta=\frac{1}{2}$ 时，伽马分布称为自由度为 n 的 χ^2 分布，记作 $\chi^2(n)$。即

  $$\mathrm{Gamma}\left(\frac{n}{2},\frac{1}{2}\right)=\chi^2(n).$$

  χ^2 分布在数理统计中极为重要，它是正态样本方差分布的基础。

3.4 本节小结

本节小结

(1) **连续型随机变量**：取值充满一个区间，用概率密度函数描述其分布。连续型随机变量取单点值的概率为零。

(2) **概率密度函数**：非负、积分为 1，区间上的积分给出概率。

(3) **常见连续型分布**：

- **均匀分布** $U[a,b]$：区间内等可能，概率仅与子区间长度有关。
- **指数分布** $E(\lambda)$：具有无记忆性，常用于寿命模型和等待时间模型。
- **正态分布** $N(\mu,\sigma^2)$：最重要的分布，具有对称性、3σ 原则。解题核心是标准化。
- **伽马分布** $\mathrm{Gamma}(\alpha,\beta)$：指数分布的推广。

3.5 习题

1. 设连续型随机变量 X 的概率密度函数为

$$f(x)=\begin{cases} c(4x-2x^2), & 0<x<2,\\ 0, & \text{其他.}\end{cases}$$

求：(1) 常数 c；(2) $P(X>1)$；(3) 分布函数 $F(x)$。

2. 设 $X\sim U[0,10]$，求 $P(X<3)$，$P(X>6)$，$P(3<X<8)$。

3. 设某电话通话时间 X（单位：分钟）服从参数 $\lambda=\frac{1}{10}$ 的指数分布。求：

   (a) 通话时间超过 15 分钟的概率；

   (b) 已知通话已持续 10 分钟，再持续超过 15 分钟的概率。

4. 设 $X\sim N(2,9)$，求 $P(1\le X<5)$。

5. 某大学入学考试（CEE）成绩服从正态分布 $N(510,60^2)$。某大学只考虑成绩超过 650 分的申请者。求所有考生中满足该大学要求的比例。

6. 设 $X\sim\mathrm{Gamma}(\alpha,\beta)$，写出其概率密度函数，并说明当 $\alpha=1$ 时它退化为哪种分布。

4 一维随机变量的函数

在实际问题中，我们常常遇到这样的情形：已知随机变量 X 的分布，而所关心的却是 X 的某个函数 $Y=g(X)$ 的分布。例如，已知圆的半径 X 的分布，求圆面积 $Y=\pi X^2$ 的分布；已知电压 X 的分布，求功率 $Y=X^2/R$ 的分布。本节讨论如何由 X 的分布求 $Y=g(X)$ 的分布。

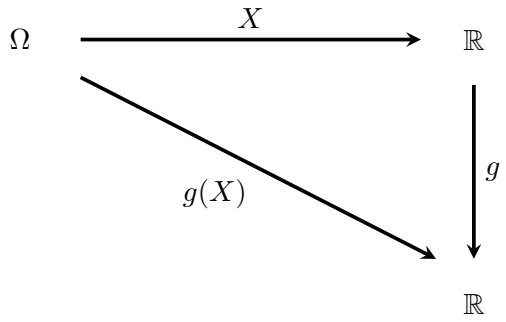
4.1 随机变量的函数

定义 4.1 (随机变量的函数). 设 X 是定义在样本空间 Ω 上的随机变量，$g(x)$ 是定义在 $\mathbb{R}$ 上的实值函数。令

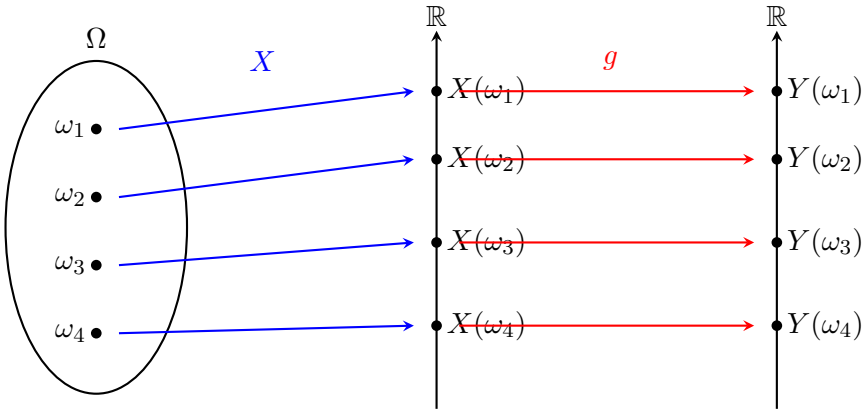
$$Y(\omega) = g\big(X(\omega)\big), \qquad \omega \in \Omega,$$

即 $Y = g(X)$。由于对每个 $\omega \in \Omega$，$X(\omega)$ 是一个确定的实数，$g(X(\omega))$ 也是一个确定的实数，因此 Y 仍然是定义在样本空间 Ω 上的实值函数，即 Y 是一个随机变量。称 Y 为**随机变量 X 的函数**，简称**随机变量的函数**。

注 4.1. 随机变量的函数 $Y = g(X)$ 仍然是随机变量，因为它本质上是一个“复合函数”:



样本点 ω 先被 X 映射为实数 $X(\omega)$，再被 g 映射为实数 $Y(\omega) = g(X(\omega))$。



复合映射: $Y = g(X)$，即 $\omega \xrightarrow{X} X(\omega) \xrightarrow{g} g(X(\omega)) = Y(\omega)$

注 4.2. 求 $Y = g(X)$ 的分布，核心思想是: **把 Y 取值的概率转化为 X 取值的概率**。具体地说，对任意实数 y，事件 $\{Y \le y\}$ 等价于 $\{g(X) \le y\}$，即

$$\{Y \le y\} = \{\omega \in \Omega : g(X(\omega)) \le y\} = X^{-1}\big(\{x \in \mathbb{R} : g(x) \le y\}\big).$$

也就是说，求 Y 的分布函数

$$F_Y(y) = P(Y \le y) = P(g(X) \le y)$$

就是把事件 $\{g(X) \le y\}$ 转化为关于 X 的事件，再用 X 的分布计算其概率。

根据 X 是离散型还是连续型，$Y = g(X)$ 的分布的求法有所不同。下面分别讨论。

4.2 离散型随机变量的函数

一、分布律的求法

设 X 是离散型随机变量，其分布律为

$$P(X=x_k)=p_k,\qquad k=1,2,\dots$$

$g(x)$ 是一个实值函数，令 $Y=g(X)$。则 Y 也是离散型随机变量，其所有可能取值为

$$\{y_j=g(x_k):k=1,2,\dots\}.$$

Y 的分布律为

$$P(Y=y_j)=P(g(X)=y_j)=\sum_{k:\,g(x_k)=y_j}P(X=x_k)=\sum_{k:\,g(x_k)=y_j}p_k.$$

注 4.3. 如果不同的 x_k 对应到相同的 y_j，则需要把这些 x_k 对应的概率全部相加，得到 $P(Y=y_j)$。这正是离散型随机变量函数求分布律的关键。

二、例题

例 4.1. 设 X 的分布律为

X	-1	0	1
P	$1/3$	$1/3$	$1/3$

求 $Y=X^2$ 的分布律。

解. X 的可能取值为 $-1,0,1$，因此 $Y=X^2$ 的可能取值为

$$g(-1)=1,\qquad g(0)=0,\qquad g(1)=1.$$

即 Y 的可能取值为 $\{0,1\}$。

计算 Y 取各值的概率:

$$P(Y=0)=P(X^2=0)=P(X=0)=\frac{1}{3},$$

$$P(Y=1)=P(X^2=1)=P(X=-1)+P(X=1)=\frac{1}{3}+\frac{1}{3}=\frac{2}{3}.$$

因此 $Y=X^2$ 的分布律为

Y	0	1
P	$1/3$	$2/3$

□

例 4.2. 设 X 的分布律为

X	1	2	3	4	5	6
P	$1/6$	$1/6$	$1/6$	$1/6$	$1/6$	$1/6$

求 $Y=(X-3)^2$ 的分布律。

解. X 的可能取值为 $1,2,3,4,5,6$，计算对应 Y 的值：

X	1	2	3	4	5	6
$Y=(X-3)^2$	4	1	0	1	4	9

可见 Y 的可能取值为 $\{0,1,4,9\}$。分别计算概率：

$$P(Y=0)=P(X=3)=\frac{1}{6},$$

$$P(Y=1)=P(X=2)+P(X=4)=\frac{1}{6}+\frac{1}{6}=\frac{1}{3},$$

$$P(Y=4)=P(X=1)+P(X=5)=\frac{1}{6}+\frac{1}{6}=\frac{1}{3},$$

$$P(Y=9)=P(X=6)=\frac{1}{6}.$$

因此 $Y=(X-3)^2$ 的分布律为

Y	0	1	4	9
P	1/6	1/3	1/3	1/6

□

例 4.3 (可加性的另一视角)**.** 设 $X\sim B(n,p)$，令 $Y=n-X$，求 Y 的分布律。

解. X 的可能取值为 $0,1,\ldots,n$，因此 $Y=n-X$ 的可能取值也是 $0,1,\ldots,n$。对任意 $k=0,1,\ldots,n$，

$$P(Y=k)=P(n-X=k)=P(X=n-k)=\binom{n}{n-k}p^{n-k}(1-p)^k.$$

利用组合恒等式 $\binom{n}{n-k}=\binom{n}{k}$，得

$$P(Y=k)=\binom{n}{k}p^{n-k}(1-p)^k=\binom{n}{k}(1-p)^kp^{n-k}.$$

这正是二项分布 $B(n,1-p)$ 的分布律，即

$$Y=n-X\sim B(n,1-p).$$

直观地看：X 是“成功次数”，$n-X$ 就是“失败次数”；每次试验成功的概率为 p，失败的概率为 $1-p$，因此失败次数 Y 服从参数为 n 和 $1-p$ 的二项分布。 □

4.3 连续型随机变量的函数

设 X 是连续型随机变量，其概率密度函数为 $f_X(x)$，$Y=g(X)$ 是 X 的函数。如果 g 是“性质良好”的函数（例如连续、分段单调等），则 Y 通常也是连续型随机变量。求 Y 的分布通常有两种方法：**分布函数法**和**公式法**。

一、分布函数法（通用方法）

分布函数法是求连续型随机变量函数分布的最通用方法，适用于 g 单调或非单调的各种情形。

基本步骤：

(1) 写出 Y 的分布函数：

$$F_Y(y) = P(Y \le y) = P(g(X) \le y).$$

(2) 将事件 $\{g(X) \le y\}$ 转化为关于 X 的等式或不等式，即求出集合

$$I_y = \{x \in \mathbb{R} : g(x) \le y\}.$$

于是

$$F_Y(y) = P(X \in I_y) = \int_{I_y} f_X(x)\,dx.$$

(3) 对 $F_Y(y)$ 求导，得到 Y 的概率密度函数：

$$f_Y(y) = F_Y'(y).$$

例 4.4. 设 $X \sim U[-1,1]$，求 $Y = X^2$ 的概率密度函数。

解. X 的密度函数为

$$f_X(x) = \begin{cases} \dfrac{1}{2}, & -1 \le x \le 1, \\ 0, & \text{其他}. \end{cases}$$

由于 $X \in [-1,1]$，故 $Y = X^2 \in [0,1]$。

(1) 当 $y < 0$ 时，$\{X^2 \le y\} = \varnothing$，故

$$F_Y(y) = 0.$$

(2) 当 $y \ge 1$ 时，$\{X^2 \le y\} = \Omega$，故

$$F_Y(y) = 1.$$

(3) 当 $0 \le y < 1$ 时，

$$F_Y(y) = P(X^2 \le y) = P(-\sqrt{y} \le X \le \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \frac{1}{2}\,dx = \sqrt{y}.$$

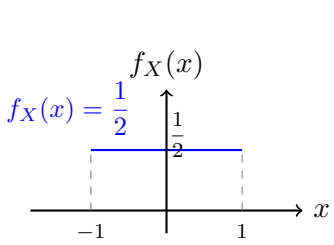
因此

$$F_Y(y) = \begin{cases} 0, & y < 0, \\ \sqrt{y}, & 0 \le y < 1, \\ 1, & y \ge 1. \end{cases}$$

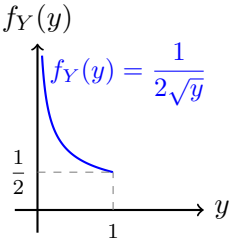
对 $F_Y(y)$ 求导，得 Y 的密度函数：

$$f_Y(y) = F_Y'(y) = \begin{cases} \dfrac{1}{2\sqrt{y}}, & 0 < y < 1, \\ 0, & \text{其他}. \end{cases}$$

□



(a) $X \sim U[-1,1]$ 的密度函数



(b) $Y = X^2$ 的密度函数

注 4.4 (图形对比)**.** 从上面两幅图可以直观看到：

- **左图**：$X \sim U[-1,1]$ 的密度函数在 $[-1,1]$ 上是**一条水平线段**，高度为 $\dfrac{1}{2}$；
- **右图**：$Y = X^2$ 的密度函数 $f_Y(y) = \dfrac{1}{2\sqrt{y}}$ 在 $(0,1)$ 上**单调递减且趋于无穷**（当 $y \to 0^+$ 时），在 $y = 1$ 处取值为 $\dfrac{1}{2}$。

  这说明 X 的均匀分布经过 $g(x) = x^2$ 变换后，概率质量被”压缩”到 y 靠近 0 的区域——这正是”两个反函数点”贡献叠加的效果：x 接近 0 的区域对应 y 接近 0，而 x 在 $[-1,1]$ 上取值等可能，故 y 越靠近 0，累积的概率密度越大。

例 4.5. 设 $X \sim N(0,1)$，求 $Y = X^2$ 的概率密度函数。

解. X 的密度函数为

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \qquad -\infty < x < +\infty.$$

$Y = X^2$ 的取值范围为 $[0, +\infty)$。

(1) 当 $y < 0$ 时，$F_Y(y) = 0$。

(2) 当 $y \geq 0$ 时，

$$F_Y(y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(x)\, dx.$$

对 $F_Y(y)$ 求导，利用变限积分求导法则（复合函数 + 上下限求导）：

$$f_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} - \phi(-\sqrt{y}) \cdot \left(-\frac{1}{2\sqrt{y}}\right) = \frac{1}{2\sqrt{y}} \left[\phi(\sqrt{y}) + \phi(-\sqrt{y})\right].$$

由于 ϕ 是偶函数，$\phi(-\sqrt{y}) = \phi(\sqrt{y})$，故

$$f_Y(y) = \frac{1}{\sqrt{y}} \phi(\sqrt{y}) = \frac{1}{\sqrt{2\pi y}} e^{-y/2}, \qquad y > 0.$$

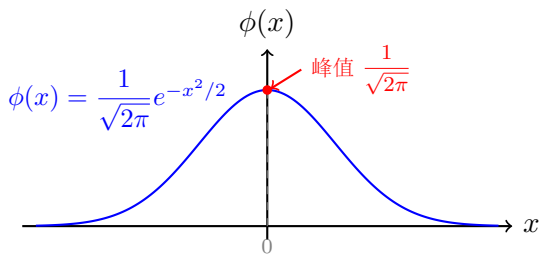
因此

$$f_Y(y) = \begin{cases} \dfrac{1}{\sqrt{2\pi y}} e^{-y/2}, & y > 0, \\ 0, & y \leq 0. \end{cases}$$

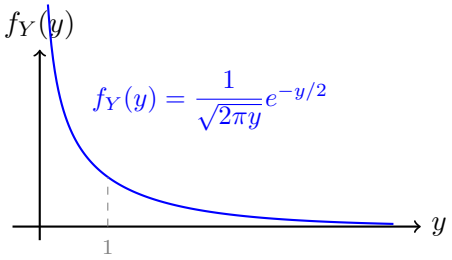
□

注 4.5. $Y = X^2$ 的密度函数正是自由度为 1 的 χ^2 分布的密度函数，即

$$Y = X^2 \sim \chi^2(1).$$



(a) $X \sim N(0,1)$ 的密度函数



(b) $Y = X^2 \sim \chi^2(1)$ 的密度函数

注 4.6 (图形对比)**.** 从上面两幅图可以直观看到：

- **左图**：$X \sim N(0,1)$ 的密度函数 $\phi(x)$ 关于原点对称，在 $x = 0$ 处取峰值 $\dfrac{1}{\sqrt{2\pi}}$，两侧向 0 单调衰减；
- **右图**：$Y = X^2$ 的密度函数 $f_Y(y) = \dfrac{1}{\sqrt{2\pi y}} e^{-y/2}$ 在 $(0, +\infty)$ 上单峰右偏，$y \to 0^+$ 时趋近于 $+\infty$，随着 y 增大迅速衰减。

  这说明 X 的对称钟形分布经过 $g(x) = x^2$ 变换后，概率质量被”折叠”到 $[0, +\infty)$ 上——左半轴和右半轴的概率被叠加到一起，所以 y 靠近 0 处密度很大。这正是”两个反函数点贡献叠加”的直观体现。

注 4.7. 这正是一个自由度为 *1* 的 χ^2 分布的密度函数，即

$$Y = X^2 \sim \chi^2(1).$$

这验证了我们在伽马分布一节中提到的事实：$\chi^2(1) = Gamma(1/2, 1/2)$。

例 4.6. 设 $X \sim N(\mu, \sigma^2)$，求 $Y = e^X$ 的概率密度函数。

解. X 的密度函数为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \qquad -\infty < x < +\infty.$$

$Y = e^X$ 的取值范围为 $(0, +\infty)$。

(1) 当 $y \le 0$ 时，$F_Y(y) = P(e^X \le y) = 0$。

(2) 当 $y > 0$ 时，

$$F_Y(y) = P(e^X \le y) = P(X \le \ln y) = \int_{-\infty}^{\ln y} f_X(x)\, dx.$$

对 $F_Y(y)$ 求导：

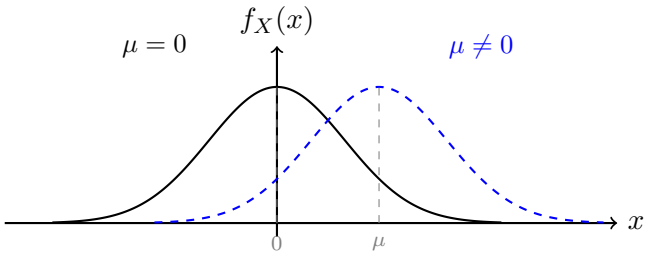
$$f_Y(y) = f_X(\ln y) \cdot \frac{1}{y} = \frac{1}{\sqrt{2\pi}\sigma y} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}, \qquad y > 0.$$

因此

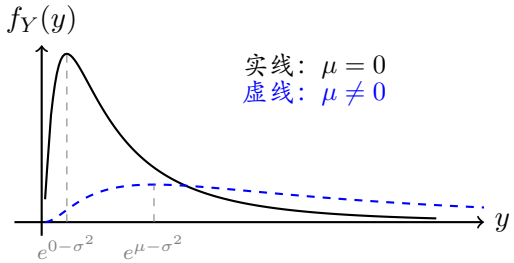
$$f_Y(y) = \begin{cases} \dfrac{1}{\sqrt{2\pi}\sigma y} \exp\left[-\dfrac{(\ln y - \mu)^2}{2\sigma^2}\right], & y > 0, \\ 0, & y \le 0. \end{cases}$$

□

注 4.8. 这个分布称为**对数正态分布**，记作 $Y \sim \mathrm{LN}(\mu, \sigma^2)$。它在经济学（收入分布）、生物学、可靠性工程中有广泛应用。上例中的两个密度函数曲线图形为：



(a) $X \sim N(\mu, \sigma^2)$ 的密度函数



(b) $Y = e^X \sim \mathrm{LN}(\mu, \sigma^2)$ 的密度函数

从上面两幅图可以直观看到：

- **左图**：正态密度 $f_X(x)$ 关于 $x = \mu$ 对称。当 μ 从 0 增大到 1.5 时，整条曲线向右平移，但形状不变；
- **右图**：对数正态密度 $f_Y(y)$ 因 μ 的平移而被”放大”。$\mu = 0$ 时峰值较小、位置偏左；$\mu = 1.5$ 时峰值右移且曲线整体被拉长、右尾更重。这是因为 $y = e^x$ 变换对较大的 x 是指数放大的，故 μ 增大会使 Y 的分布向右延伸得更明显。

  这说明对数正态分布的 μ（对数尺度上的均值）不仅决定分布的峰值位置，还通过指数变换”放大”其尺度效应，使分布形态随 μ 变化更加显著。

二、公式法（g 严格单调的情形）

当 g 是严格单调函数（严格递增或严格递减）时，可以用下面的**公式法**直接求 $f_Y(y)$，无需经过分布函数。

定理 4.1 (单调变换公式)**.** 设 X 是连续型随机变量，其密度函数为 $f_X(x)$，且 $P(a < X < b) = 1$（a, b 可以是 $\pm\infty$）。设 $Y = g(X)$，$g(x)$ 在 (a, b) 上**严格单调且可导**。令 (α, β) 为 g 在 (a, b) 上的值域，$g^{-1}(y)$ 为 g 的反函数，则 Y 的密度函数为

$$f_Y(y) = \begin{cases} f_X\big(g^{-1}(y)\big) \left| \dfrac{d}{dy} g^{-1}(y) \right|, & \alpha < y < \beta, \\ 0, & \text{其他.} \end{cases}$$

证明. 设 g 在 (a, b) 上严格递增，则 g^{-1} 也在 (α, β) 上严格递增。

- 当 $y \le \alpha$ 时，$F_Y(y) = 0$；- 当 $y \ge \beta$ 时，$F_Y(y) = 1$；- 当 $\alpha < y < \beta$ 时，

$$F_Y(y) = P(g(X) \le y) = P\big(X \le g^{-1}(y)\big) = \int_a^{g^{-1}(y)} f_X(x)\,dx.$$

对 y 求导，得

$$f_Y(y) = f_X\big(g^{-1}(y)\big) \cdot \frac{d}{dy} g^{-1}(y).$$

由于 g^{-1} 递增，$\dfrac{d}{dy} g^{-1}(y) > 0$，故可以写成 $\left|\dfrac{d}{dy} g^{-1}(y)\right|$。

若 g 严格递减，则 g^{-1} 也严格递减，$\dfrac{d}{dy} g^{-1}(y) < 0$。此时由分布函数求导得

$$f_Y(y) = f_X\big(g^{-1}(y)\big) \cdot \left(-\frac{d}{dy} g^{-1}(y)\right) = f_X\big(g^{-1}(y)\big) \left|\frac{d}{dy} g^{-1}(y)\right|.$$

两者合并，即得所证公式。 □

例 4.7 (用公式法重做上例)**.** 设 $X \sim N(\mu, \sigma^2)$，求 $Y = e^X$ 的密度函数。

解. $g(x) = e^x$ 在 $(-\infty, +\infty)$ 上严格递增、可导，其反函数为

$$g^{-1}(y) = \ln y, \qquad y > 0.$$

值域为 $(\alpha, \beta) = (0, +\infty)$。计算导数：

$$\frac{d}{dy} g^{-1}(y) = \frac{1}{y}.$$

由公式法，

$$f_Y(y) = f_X(\ln y) \cdot \frac{1}{y} = \frac{1}{\sqrt{2\pi}\sigma y} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}, \qquad y > 0.$$

与上例用分布函数法得到的结果一致。 □

例 4.8 (线性变换)**.** 设 X 是连续型随机变量，密度函数为 $f_X(x)$，令

$$Y = aX + b, \qquad a \ne 0.$$

求 Y 的密度函数。

解. $g(x) = ax + b$ 严格单调。反函数为

$$g^{-1}(y) = \frac{y - b}{a}, \qquad \frac{d}{dy} g^{-1}(y) = \frac{1}{a}.$$

由公式法，

$$f_Y(y) = f_X\left(\frac{y - b}{a}\right) \cdot \left|\frac{1}{a}\right| = \frac{1}{|a|} f_X\left(\frac{y - b}{a}\right).$$

特例（正态分布的标准化）：设 $X \sim N(\mu, \sigma^2)$，取 $a = \dfrac{1}{\sigma}$，$b = -\dfrac{\mu}{\sigma}$，则

$$Y = \frac{X - \mu}{\sigma}.$$

此时由上式，

$$f_Y(y) = \frac{1}{1/\sigma} \cdot f_X(\sigma y + \mu) = \sigma \cdot \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(\sigma y+\mu-\mu)^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}} e^{-y^2/2}.$$

即

$$Y = \frac{X-\mu}{\sigma} \sim N(0,1).$$

这正是正态分布的**标准化公式**。 □

注 4.9 (线性变换保持正态性)**.** 上述特例说明了一个重要事实：**正态分布经线性变换后仍然是正态分布**。

更一般地，若 $X \sim N(\mu, \sigma^2)$，则对任意常数 $a \neq 0$ 和 b，

$$Y = aX + b \sim N(a\mu + b,\ a^2\sigma^2).$$

这一性质称为正态分布的**线性变换不变性**（或**封闭性**），是正态分布在统计推断中被广泛使用的重要原因之一：

- 线性变换不改变分布类型——变换前后都是正态分布；
- 均值按 $a\mu + b$ 变换，方差按 $a^2\sigma^2$ 变换；
- 特别地，当 $a = 1/\sigma$、$b = -\mu/\sigma$ 时，得到标准正态分布 $N(0,1)$。

三、分段单调函数的处理

当 g 不是单调函数，但可以分成若干个单调区间时，用分布函数法或对每个单调段分别用公式法，然后求和。

定理 4.2 (分段单调变换公式)**.** 设 X 是连续型随机变量，密度函数为 $f_X(x)$，$P(a < X < b) = 1$。设 $Y = g(X)$，g 在 (a,b) 上可以分解为 n 个互不重叠的子区间 $I_1, I_2, \ldots, I_n$，在每一个 I_k 上 g 严格单调且可导，$g_k^{-1}(y)$ 为 g 在 I_k 上的反函数，则 Y 的密度函数为

$$f_Y(y) = \sum_{k=1}^{n} f_X\big(g_k^{-1}(y)\big) \left| \frac{d}{dy} g_k^{-1}(y) \right|,$$

其中约定：如果 y 不在 $g(I_k)$ 的值域内，对应的项为 0。

例 4.9 (用分段单调公式重做前面的例子)**.** 设 $X \sim U[-1,1]$，求 $Y = X^2$ 的密度函数。

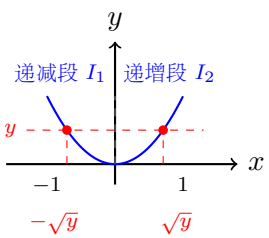
解. $g(x) = x^2$ 在 $[-1,1]$ 上可以分成两个单调区间：

- $I_1 = [-1,0]$，g 在此严格递减，反函数为 $g_1^{-1}(y) = -\sqrt{y}$；
- $I_2 = [0,1]$，g 在此严格递增，反函数为 $g_2^{-1}(y) = \sqrt{y}$。

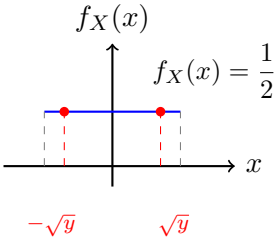
对 $0 < y < 1$，两段都贡献：

$$f_Y(y) = f_X(-\sqrt{y}) \left| \frac{d}{dy}(-\sqrt{y}) \right| + f_X(\sqrt{y}) \left| \frac{d}{dy}(\sqrt{y}) \right| = \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} + \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{2\sqrt{y}}.$$

对 $y \leq 0$ 或 $y \geq 1$，$f_Y(y) = 0$。结果与前面分布函数法的结果一致。 □



(a) $y = x^2$ 在 $[-1, 1]$ 上分段单调



(b) 密度 $f_X(x)$ 与两个反函数点

注 4.10 (图形解读)**.** 本例的求解过程可以用上图直观解释:

(1) **左图**: $y = x^2$ 在 $[-1, 1]$ 上不是单调函数，但在 $I_1 = [-1, 0]$ 上严格递减、在 $I_2 = [0, 1]$ 上严格递增。给定 $y \in (0, 1)$，水平线 y 与曲线有两个交点，对应两个 x 值: $x_1 = -\sqrt{y}$ 和 $x_2 = \sqrt{y}$。

(2) **右图**: $X \sim U[-1, 1]$ 的密度 $f_X(x) = \dfrac{1}{2}$ 在 $[-1, 1]$ 上是常值函数。两个交点 x_1, x_2 对应的密度值都是 $\dfrac{1}{2}$，分别被贡献到 $f_Y(y)$ 中。

(3) **公式含义**: 分段单调公式

$$f_Y(y) = f_X(-\sqrt{y}) \left| \frac{d}{dy}(-\sqrt{y}) \right| + f_X(\sqrt{y}) \left| \frac{d}{dy}(\sqrt{y}) \right|$$

正是把两个反函数点处的贡献相加。其中 $\left| \dfrac{d}{dy}(\pm\sqrt{y}) \right| = \dfrac{1}{2\sqrt{y}}$，两段贡献相同。

(4) **化简**: 将 $f_X(x) = \dfrac{1}{2}$ 代入，得

$$f_Y(y) = \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} + \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{2\sqrt{y}}, \qquad 0 < y < 1,$$

即 $Y = X^2$ 在 $(0, 1)$ 上服从参数为 $\left(\dfrac{1}{2}, 1\right)$ 的 *Beta* 分布。

例 4.10. 设 X 的密度函数为

$$f_X(x) = \begin{cases} \dfrac{2x}{\pi^2}, & 0 < x < \pi, \\ 0, & \text{其他.} \end{cases}$$

求 $Y = \sin X$ 的密度函数。

解. $g(x) = \sin x$ 在 $(0, \pi)$ 上分为两个单调区间:

- $I_1 = (0, \pi/2]$，g 严格递增，反函数为 $g_1^{-1}(y) = \arcsin y$;
- $I_2 = (\pi/2, \pi)$，g 严格递减，反函数为 $g_2^{-1}(y) = \pi - \arcsin y$。

Y 的取值范围为 $(0, 1)$。对 $0 < y < 1$，两段都贡献:

$$\frac{d}{dy} g_1^{-1}(y) = \frac{1}{\sqrt{1 - y^2}}, \qquad \frac{d}{dy} g_2^{-1}(y) = -\frac{1}{\sqrt{1 - y^2}}.$$

故

$$f_Y(y) = f_X(\arcsin y) \cdot \frac{1}{\sqrt{1-y^2}} + f_X(\pi - \arcsin y) \cdot \frac{1}{\sqrt{1-y^2}}.$$

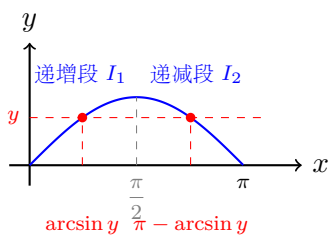
代入 $f_X(x) = \dfrac{2x}{\pi^2}$：

$$f_Y(y) = \frac{2\arcsin y}{\pi^2\sqrt{1-y^2}} + \frac{2(\pi - \arcsin y)}{\pi^2\sqrt{1-y^2}} = \frac{2\pi}{\pi^2\sqrt{1-y^2}} = \frac{2}{\pi\sqrt{1-y^2}}.$$

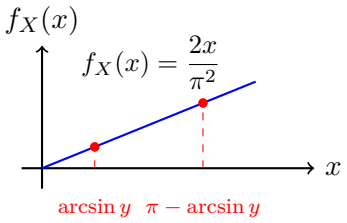
因此

$$f_Y(y) = \begin{cases} \dfrac{2}{\pi\sqrt{1-y^2}}, & 0 < y < 1, \\ 0, & \text{其他}. \end{cases}$$

□



(a) $y = \sin x$ 在 $(0, \pi)$ 上分段单调



(b) 密度 $f_X(x)$ 与两个反函数点

注 4.11 (图形解读)**.** 本例的求解过程可以用上图直观解释：

(1) **左图**：$y = \sin x$ 在 $(0, \pi)$ 上不是单调函数，但在 $I_1 = (0, \pi/2]$ 上严格递增、在 $I_2 = (\pi/2, \pi)$ 上严格递减。给定 $y \in (0, 1)$，水平线 y 与曲线有两个交点，对应两个 x 值：$x_1 = \arcsin y$ 和 $x_2 = \pi - \arcsin y$。

(2) **右图**：X 的密度 $f_X(x) = \dfrac{2x}{\pi^2}$ 在 $(0, \pi)$ 上线性递增。两个交点 x_1, x_2 对应的密度值 $f_X(x_1)$ 和 $f_X(x_2)$ 分别被贡献到 $f_Y(y)$ 中。

(3) **公式含义**：分段单调公式

$$f_Y(y) = f_X(\arcsin y) \cdot \frac{1}{\sqrt{1-y^2}} + f_X(\pi - \arcsin y) \cdot \frac{1}{\sqrt{1-y^2}}$$

正是把两个反函数点处的贡献相加。其中 $\dfrac{1}{\sqrt{1-y^2}}$ 是反函数 $\arcsin y$ 的导数绝对值（两段分别贡献同样的因子）。

(4) **化简的巧思**：将 $f_X(x) = \dfrac{2x}{\pi^2}$ 代入后，两个 x 项恰好互补：

$$x_1 + x_2 = \arcsin y + (\pi - \arcsin y) = \pi,$$

因此 $f_Y(y) = \dfrac{2(x_1 + x_2)}{\pi^2\sqrt{1-y^2}} = \dfrac{2\pi}{\pi^2\sqrt{1-y^2}} = \dfrac{2}{\pi\sqrt{1-y^2}}$，与 y 的具体取值无关，形式非常简洁。

四、一个重要的例子：分布函数与随机变量的复合

在模拟（Simulation）中，有一个非常常用的结论：设 X 是连续型随机变量，其分布函数为 $F(x)$，则

$$Y = F(X)$$

服从区间 $[0,1]$ 上的均匀分布。这个结论是**逆变换采样法**（inverse transform sampling）的理论基础，本质上也是" 随机变量的函数" 的一个重要应用。

例 4.11 (分布函数与随机变量的复合)**.** 设 X 是连续型随机变量，分布函数为 $F(x) = P(X \le x)$。令

$$Y = F(X),$$

证明 $Y \sim U[0,1]$。

解. 对任意实数 y，由分布函数 F 的取值可知 $0 \le F(x) \le 1$，因此 $Y = F(X) \in [0,1]$，即：

- 当 $y < 0$ 时，$\{Y \le y\} = \varnothing$，故 $F_Y(y) = 0$；
- 当 $y \ge 1$ 时，$\{Y \le y\} = \Omega$，故 $F_Y(y) = 1$。

  下面讨论 $0 \le y < 1$ 的情形。
  由于 F 是分布函数，F 单调非减。定义 F 的**广义反函数**

$$F^{-1}(y) = \inf\{x \in \mathbb{R} : F(x) \ge y\}, \qquad 0 < y < 1.$$

对 $0 \le y < 1$，有

$$F_Y(y) = P(Y \le y) = P\big(F(X) \le y\big) = P\big(X \le F^{-1}(y)\big) = F\big(F^{-1}(y)\big) = y.$$

最后一步之所以成立，是因为在 F 的连续点上 $F(F^{-1}(y)) = y$；若 $F^{-1}(y)$ 处 F 有跳跃，则可取 $F^{-1}(y)$ 的右极限，使得 $F(F^{-1}(y)) \ge y$，结合 F^{-1} 的定义仍可得上式。

综合三种情形：

$$F_Y(y) = \begin{cases} 0, & y < 0, \\ y, & 0 \le y < 1, \\ 1, & y \ge 1. \end{cases}$$

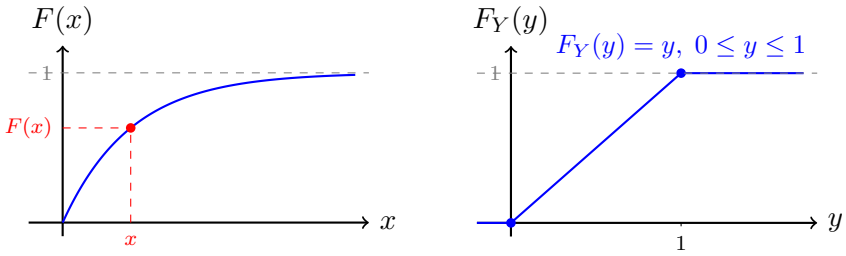
这恰好是区间 $[0,1]$ 上均匀分布的分布函数，故

$$Y = F(X) \sim U[0,1].$$

□

注 4.12. 这个结论是"逆变换采样法"的核心。由 $Y = F(X) \sim U[0,1]$ 可知，如果我们能够生成均匀分布 $U[0,1]$ 的随机数 U，则 $X = F^{-1}(U)$ 就是服从分布 F 的随机变量。这正是后续模拟部分"逆变换法"的原理。

从图形上看，本结论的实质是：分布函数 F 把 X 上的概率分布"拉平"成均匀分布，而反函数 F^{-1} 则把均匀分布"还原"为原分布。



(a) 分布函数 F：$x \mapsto F(x)$　　(b) $Y = F(X) \sim U[0,1]$

注 4.13 (图形解读)**.** 从上面两幅图可以直观理解 $Y = F(X) \sim U[0,1]$ 这一结论：

- **左图**：$F(x)$ 是单调递增的 S 形曲线，把 x 轴上的概率分布压缩到 $[0,1]$ 区间上；
- **右图**：$Y = F(X)$ 的分布函数是一条从左下到右上的**直线段**（斜率为 1），即

$$F_Y(y) = y, \qquad 0 \le y \le 1,$$

  这正是 $[0,1]$ 上均匀分布的分布函数；
- **直观含义**：分布函数 F 把 X 的分布“摊平”成均匀分布——不论 X 原本服从什么分布，只要代入它自己的分布函数 F，就得到 $[0,1]$ 上的均匀分布。这正是逆变换采样法利用此性质进行模拟的原因。

4.4 本节小结

本节小结

(1) **随机变量的函数**：设 X 是随机变量，$g(x)$ 是实值函数，则 $Y=g(X)$ 仍然是随机变量，本质上是“复合函数”$\Omega \xrightarrow{X} \mathbb{R} \xrightarrow{g} \mathbb{R}$。

(2) **求 $Y=g(X)$ 的分布的核心思想**：把 Y 取值的概率转化为 X 取值的概率，即

$$\{Y \le y\} = \{g(X) \le y\} \xrightarrow{\text{转化为}X\text{ 的集合}} X^{-1}(\{x : g(x) \le y\}).$$

(3) **离散型随机变量的函数**：

- $Y=g(X)$ 仍是离散型，其可能取值为 $\{g(x_k)\}$；
- 分布律为
$$P(Y=y_j) = \sum_{k:\, g(x_k)=y_j} P(X=x_k);$$
- 不同的 x_k 对应相同的 y_j 时，需把对应的概率相加。

(4) **连续型随机变量的函数**：

- **分布函数法**（通用）：先求 $F_Y(y)=P(g(X)\le y)$，再求导得 $f_Y(y)=F_Y'(y)$；
- **公式法**（g 严格单调）：$f_Y(y)=f_X\big(g^{-1}(y)\big)\left|\dfrac{d}{dy}g^{-1}(y)\right|$；
- **分段单调**：把 g 分成若干单调段，每段用公式法后求和。

(5) **常见变换及结果**：

- 线性变换：$Y=aX+b$，则 $f_Y(y)=\dfrac{1}{|a|}f_X\left(\dfrac{y-b}{a}\right)$；
- 标准化：$X\sim N(\mu,\sigma^2)$，则 $\dfrac{X-\mu}{\sigma}\sim N(0,1)$；
- 平方：$X\sim N(0,1)$，则 $X^2\sim \chi^2(1)$；
- 指数变换：$X\sim N(\mu,\sigma^2)$，则 $e^X\sim \mathrm{LN}(\mu,\sigma^2)$（对数正态分布）。

4.5 习题

1. 设 X 的分布律为

X	-2	-1	0	1	2
P	0.1	0.2	0.4	0.2	0.1

求 $Y=2X+1$ 与 $Z=X^2$ 的分布律。

2. 设 $X\sim B(3,1/2)$，求 $Y=3-X$ 的分布律，并指出 Y 服从什么分布。

3. 设 $X\sim U[0,1]$，求 $Y=-\ln X$ 的概率密度函数，并指出 Y 服从什么分布。

4. 设 $X \sim N(0,1)$，求 $Y = 2X + 1$ 的概率密度函数。

5. 设 X 的密度函数为

$$f_X(x) = \begin{cases} 2x, & 0 < x < 1, \\ 0, & \text{其他}, \end{cases}$$

求 $Y = X^2$ 的概率密度函数。

6. 设 $X \sim E(\lambda)$，求 $Y = \sqrt{X}$ 的概率密度函数。

7. 设 X 的密度函数为

$$f_X(x) = \frac{1}{\pi(1+x^2)}, \qquad -\infty < x < +\infty \text{ (柯西分布)},$$

求 $Y = \arctan X$ 的概率密度函数。