Chapter 3

多维随机变量

3.1 二维随机变量

3.1.1 二维随机变量的定义

在许多实际问题中，我们往往需要同时研究两个或两个以上的随机变量。例如：

- 测量一个人的身高 X 和体重 Y；
- 记录某地区一天的最高气温 X 和最低气温 Y；
- 抛两枚硬币，分别记录正面出现的次数 X 和 Y；
- 考察一个家庭中父亲身高 X 与儿子身高 Y 的关系。

这些问题的共同特点是：同一个样本空间上定义了多个随机变量，而且它们之间往往存在某种联系。要研究这种“多个随机变量一起取值”的概率规律，就需要引入**二维随机变量**。

定义 3.1 (二维随机变量)**.** 设 X 和 Y 是定义在同一样本空间 Ω 上的两个随机变量。称有序对

$$(X, Y)$$

为**二维随机变量**，也称**二维随机向量**。

一般地，设 $X_1, X_2, \ldots, X_n$ 是定义在同一样本空间 Ω 上的 n 个随机变量，称

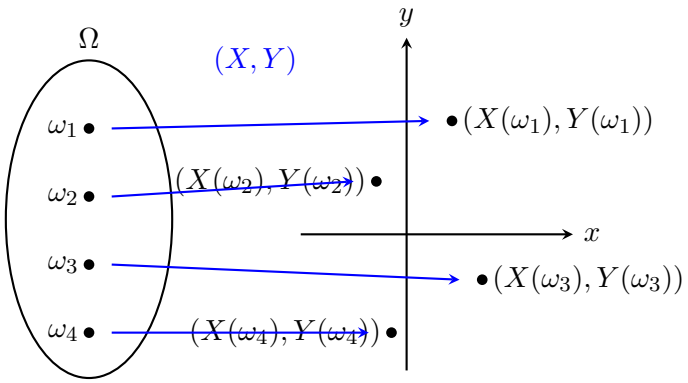
$$(X_1, X_2, \ldots, X_n)$$

为 n **维随机变量**，也称 n **维随机向量**。

注 3.1. 二维随机变量 (X, Y) 可以看成从样本空间 Ω 到平面 $\mathbb{R}^2$ 的映射：

$$\omega \mapsto (X(\omega), Y(\omega)).$$

因此，二维随机变量本质上是一个“向量值函数”。研究 (X, Y) 的分布，就是要研究它落在平面上各种区域的概率。



二维随机变量把每个样本点 ω 映射为平面上的点 $(X(\omega), Y(\omega))$

3.1.2 分布函数的定义

和一维情形一样，描述二维随机变量概率规律的最基本工具是分布函数。

定义 3.2 (联合分布函数)**.** 设 (X, Y) 是二维随机变量。对任意实数 x, y，称

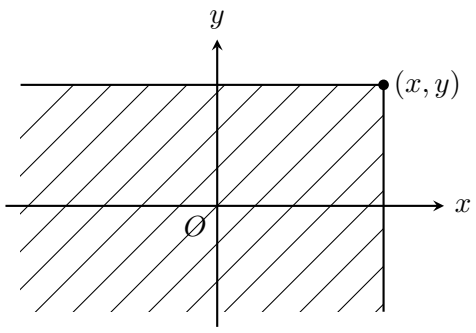
$$F(x, y) = P(X \le x,\ Y \le y)$$

为 (X, Y) 的**分布函数**，或者称作 X 和 Y 的**联合分布函数**，简称**分布函数**。

联合分布函数 $F(x, y)$ 表示随机点 (X, Y) 落在平面区域

$$(-\infty, x] \times (-\infty, y]$$

中的概率，图解如下。



$F(x, y) = P(X \le x,\ Y \le y)$ 的图解

注 3.2 (用逆映射理解二维随机变量)**.** 设 (X, Y) 是定义在样本空间 Ω 上、取值于平面 $\mathbb{R}^2$ 的映射，即

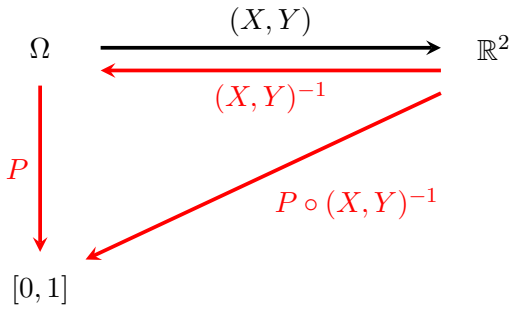
$$(X, Y) : \Omega \to \mathbb{R}^2.$$

与一维情形类似，我们要求：**对平面上任意集合 $B \subset \mathbb{R}^2$，它的原像**

$$(X, Y)^{-1}(B) = \{\omega \in \Omega : (X(\omega), Y(\omega)) \in B\}$$

都必须是事件（即属于事件域 $\mathcal{F}$）。满足这一要求的映射 (X, Y) 才称为二维随机变量。

用逆映射的语言说，二维随机变量 (X,Y) 的作用就是把平面上的任意集合 B “拉回”到样本空间，得到事件 $(X,Y)^{-1}(B)$。这样，原本定义在样本空间上的随机现象，就可以借助平面上的集合运算和分析工具来研究，这正是引入二维随机变量的核心意义。



$$P\circ(X,Y)^{-1}\big(B\big)=P\big\{\omega:(X(\omega),Y(\omega))\in B\big\}$$

特别地，取平面上的集合

$$B=(-\infty,x]\times(-\infty,y],$$

则由逆映射得到事件

$$(X,Y)^{-1}(B)=\{\omega\in\Omega:X(\omega)\le x,\ Y(\omega)\le y\}=\{X\le x,\ Y\le y\}.$$

于是，联合分布函数

$$F(x,y)=P(X\le x,\ Y\le y)$$

就可以写成

$$F(x,y)=P\big((X,Y)^{-1}((-\infty,x]\times(-\infty,y])\big).$$

这说明：**联合分布函数本质上就是“平面集合 $(-\infty,x]\times(-\infty,y]$ 的逆像的概率”**

命题 3.1 (联合分布函数的性质)**.** *设 $F(x,y)$ 是二维随机变量 (X,Y) 的联合分布函数，则：*

(1) **单调性**：*$F(x,y)$ 关于 x 和关于 y 都单调非减。即若 $x_1<x_2$，则*

$$F(x_1,y)\le F(x_2,y);$$

若 $y_1<y_2$，则

$$F(x,y_1)\le F(x,y_2).$$

(2) **有界性**：*对任意 x,y，*

$$0\le F(x,y)\le 1,$$

且

$$\lim_{x\to-\infty}F(x,y)=0,\qquad\lim_{y\to-\infty}F(x,y)=0,$$

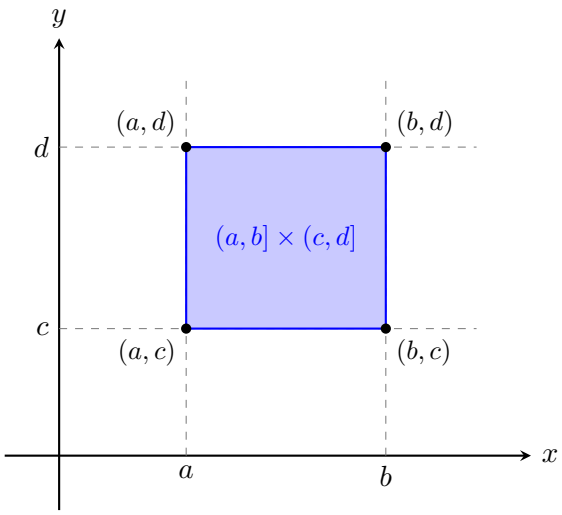
$$\lim_{x\to+\infty,\ y\to+\infty}F(x,y)=1.$$

(3) **右连续性**：$F(x,y)$ 关于 x 右连续，关于 y 也右连续，即

$$\lim_{u\to x^+} F(u,y) = F(x,y), \qquad \lim_{v\to y^+} F(x,v) = F(x,y).$$

(4) **矩形概率公式**：对任意 $a<b$，$c<d$，

$$P(a<X\le b,\ c<Y\le d) = F(b,d) - F(a,d) - F(b,c) + F(a,c).$$



$P(a<X\le b,\ c<Y\le d) = F(b,d) - F(a,d) - F(b,c) + F(a,c)$ 的图解

证明. (1)、(2)、(3) 与一维情形类似，证明略。

下面证明 (4)。事件

$$\{a<X\le b,\ c<Y\le d\}$$

可以看成矩形 $(a,b]\times(c,d]$。利用分布函数的定义，

$$P(a<X\le b,\, c<Y\le d) = P(X\le b,\, Y\le d) - P(X\le a,\, Y\le d) - P(X\le b,\, Y\le c) + P(X\le a,\, Y\le c).$$

即

$$P(a<X\le b,\ c<Y\le d) = F(b,d) - F(a,d) - F(b,c) + F(a,c).$$

□

注 3.3. 矩形概率公式是二维分布函数最重要的性质之一。它说明：**由联合分布函数可以计算随机点落在任意矩形中的概率**。这也是一维情形

$$P(a<X\le b) = F(b) - F(a)$$

在二维情形的推广。

3.1.3 例子

例 3.1 (二维离散型随机变量的分布函数)**.** 抛两枚均匀硬币，设

$$X = \{\text{第一枚硬币正面出现的次数}\}, \qquad Y = \{\text{第二枚硬币正面出现的次数}\}.$$

由前面的例子，(X,Y) 的联合分布律为

$$P(X=0,Y=0) = P(X=0,Y=1) = P(X=1,Y=0) = P(X=1,Y=1) = \frac{1}{4}.$$

求 (X,Y) 的联合分布函数 $F(x,y)$。

解. (X,Y) 的所有可能取值为 $(0,0),(0,1),(1,0),(1,1)$，每个取值的概率都是 $\frac{1}{4}$。

由定义

$$F(x,y) = P(X \le x,\ Y \le y).$$

它等于所有满足

$$x_i \le x, \qquad y_j \le y$$

的可能取值 (x_i,y_j) 的概率之和。

由于 X 和 Y 都只取 0 和 1，平面被直线

$$x=0, \quad x=1, \quad y=0, \quad y=1$$

分成若干区域。下面分区域计算 $F(x,y)$。

- 若 $x<0$ 或 $y<0$，则没有满足条件的取值，故

$$F(x,y) = 0;$$

- 若 $0 \le x < 1$ 且 $0 \le y < 1$，则只有 $(0,0)$ 满足条件，故

$$F(x,y) = P(X=0,\ Y=0) = \frac{1}{4};$$

- 若 $0 \le x < 1$ 且 $y \ge 1$，则满足条件的取值为 $(0,0),(0,1)$，故

$$F(x,y) = P(X=0,\ Y=0) + P(X=0,\ Y=1) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2};$$

- 若 $x \ge 1$ 且 $0 \le y < 1$，则满足条件的取值为 $(0,0),(1,0)$，故

$$F(x,y) = P(X=0,\ Y=0) + P(X=1,\ Y=0) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2};$$

- 若 $x \ge 1$ 且 $y \ge 1$，则所有取值都满足条件，故

$$F(x,y) = 1.$$

综上，(X,Y) 的联合分布函数为

$$F(x,y)=\begin{cases}0, & x<0 \text{ 或} y<0,\\ \dfrac{1}{4}, & 0\le x<1,\ 0\le y<1,\\ \dfrac{1}{2}, & 0\le x<1,\ y\ge 1,\\ \dfrac{1}{2}, & x\ge 1,\ 0\le y<1,\\ 1, & x\ge 1,\ y\ge 1.\end{cases}$$

这个分布函数在 $(0,0),(0,1),(1,0),(1,1)$ 四个点处发生跳跃，跳跃高度恰好等于对应的概率 $\frac{1}{4}$。它是一个**右连续的二维阶梯函数**，这与一维离散型随机变量的分布函数完全类似。 □

注 3.4. 由本例可以看出：

- 离散型二维随机变量的联合分布函数是**阶梯函数**；
- 跳跃点恰好是 (X,Y) 的所有可能取值；
- 每个跳跃点处的跳跃高度恰好等于该取值的概率；
- 分布函数在每个区域内部取常数值，只在边界处发生跳跃，且保持**右连续**。

这与一维离散型随机变量的分布函数形状完全平行。

例 3.2 (正方形上的二维均匀分布)**.** 设 (X,Y) 在正方形区域

$$D=[0,2]\times[0,2]$$

上服从均匀分布，即 (X,Y) 落在 D 中任意区域 A 的概率与 A 的面积成正比：

$$P\big((X,Y)\in A\big)=\frac{m(A)}{m(D)},\qquad A\subset D.$$

求 (X,Y) 的联合分布函数。

解. 正方形区域 D 的面积为

$$m(D)=2\times 2=4.$$

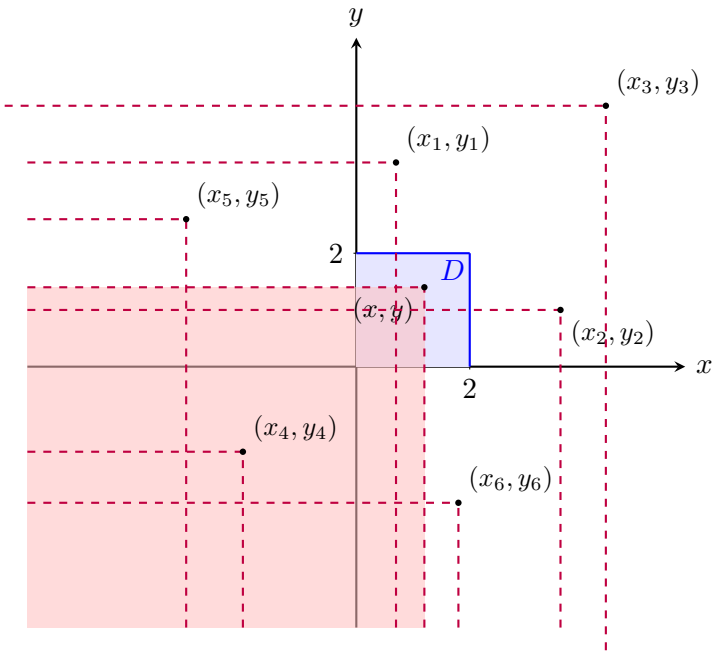
对任意 x,y，联合分布函数为

$$F(x,y)=P(X\le x,\ Y\le y).$$

它等于矩形

$$(-\infty,x]\times(-\infty,y]$$

与 D 的交集面积除以 $m(D)$。



分情况讨论：

- 若 $x < 0$ 或 $y < 0$，则交集为空，故 $F(x, y) = 0$；
- 若 $0 \le x \le 2$，$0 \le y \le 2$，则交集为矩形 $[0, x] \times [0, y]$，面积为 xy，故

$$F(x, y) = \frac{xy}{4};$$

- 若 $x > 2$，$0 \le y \le 2$，则交集为 $[0, 2] \times [0, y]$，面积为 $2y$，故

$$F(x, y) = \frac{2y}{4} = \frac{y}{2};$$

- 若 $0 \le x \le 2$，$y > 2$，则交集为 $[0, x] \times [0, 2]$，面积为 $2x$，故

$$F(x, y) = \frac{2x}{4} = \frac{x}{2};$$

- 若 $x > 2$，$y > 2$，则 $F(x, y) = 1$。

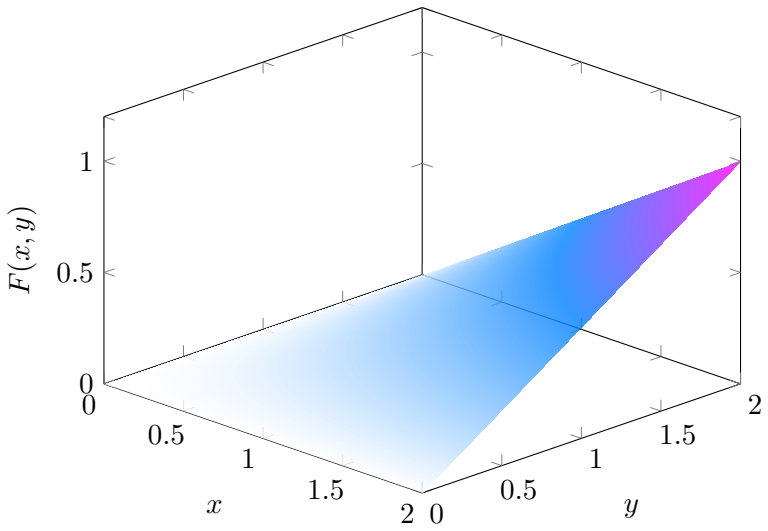
  综上，(X, Y) 的联合分布函数为

$$F(x, y) = \begin{cases} 0, & x < 0 \text{ 或} y < 0, \\ \dfrac{xy}{4}, & 0 \le x \le 2,\ 0 \le y \le 2, \\ \dfrac{y}{2}, & x > 2,\ 0 \le y \le 2, \\ \dfrac{x}{2}, & 0 \le x \le 2,\ y > 2, \\ 1, & x > 2,\ y > 2. \end{cases}$$

特别地，当 $0 \le x \le 2$，$0 \le y \le 2$ 时，

$$F(x,y) = \frac{xy}{4}.$$

在正方形 $D = [0,2] \times [0,2]$ 内，$F(x,y)$ 是一个双线性函数，其曲面如下图。



□

3.1.4 二维离散型随机变量

定义 3.3 (二维离散型随机变量)**.** 设 (X,Y) 是二维随机变量。若 X 和 Y 都是离散型随机变量，则称 (X,Y) 为**二维离散型随机变量**。

定义 3.4 (联合分布律)**.** 设 (X,Y) 是二维离散型随机变量，其所有可能取值为

$$(x_i, y_j), \qquad i = 1,2,\ldots, \quad j = 1,2,\ldots$$

称

$$p_{ij} = P(X = x_i,\ Y = y_j)$$

为 (X,Y) 的**联合分布律**，简称**分布律**。

联合分布律满足：

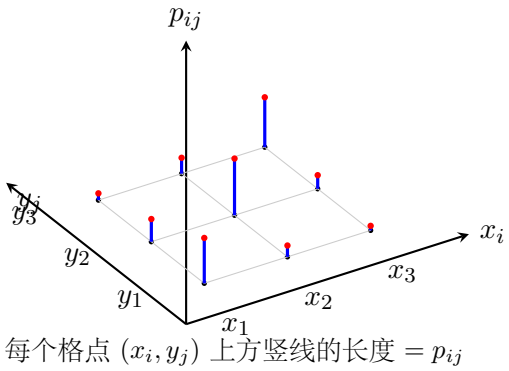
(1) **非负性**：$p_{ij} \ge 0$；

(2) **规范性**：$\sum_{i=1}^{\infty}\sum_{j=1}^{\infty} p_{ij} = 1$。

联合分布律通常用表格表示：

$X\backslash Y$	y_1	y_2	$\cdots$	y_j	$\cdots$
x_1	p_{11}	p_{12}	$\cdots$	p_{1j}	$\cdots$
x_2	p_{21}	p_{22}	$\cdots$	p_{2j}	$\cdots$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	
x_i	p_{i1}	p_{i2}	$\cdots$	p_{ij}	$\cdots$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	

或者，用竖线图表示，



每个格点 (x_i, y_j) 上方竖线的长度 $= p_{ij}$

二维离散型联合分布律：竖直线段长度表示 p_{ij}，所有线段长度之和 $= 1$

3.1.5 例子

例 3.3 (抛两枚硬币)**.** 抛两枚均匀硬币。设

$$X = \{\text{第一枚硬币正面出现的次数}\}, \qquad Y = \{\text{第二枚硬币正面出现的次数}\}.$$

求 (X, Y) 的联合分布律。

解. X 和 Y 都只取 0 和 1，且相互独立。由独立性，

$$P(X = i,\ Y = j) = P(X = i)P(Y = j), \qquad i, j = 0, 1.$$

而

$$P(X = 1) = P(X = 0) = \frac{1}{2}, \qquad P(Y = 1) = P(Y = 0) = \frac{1}{2}.$$

因此

$$P(X = 0, Y = 0) = \frac{1}{4}, \quad P(X = 0, Y = 1) = \frac{1}{4}, \quad P(X = 1, Y = 0) = \frac{1}{4}, \quad P(X = 1, Y = 1) = \frac{1}{4}.$$

联合分布律表为

$X\backslash Y$	0	1
0	$\frac{1}{4}$	$\frac{1}{4}$
1	$\frac{1}{4}$	$\frac{1}{4}$

□

例 3.4 (不放回摸球)**.** 袋中有 2 个红球和 3 个白球。现从袋中不放回地依次摸出两个球。设

$$X=\begin{cases}1, & \text{第一次摸到红球},\\ 0, & \text{第一次摸到白球},\end{cases}\qquad Y=\begin{cases}1, & \text{第二次摸到红球},\\ 0, & \text{第二次摸到白球}.\end{cases}$$

求 (X,Y) 的联合分布律。

解. 所有可能取值为 $(0,0),(0,1),(1,0),(1,1)$。

计算各概率:

$$P(X=1,Y=1)=P(\text{两次都摸到红球})=\frac{2}{5}\cdot\frac{1}{4}=\frac{1}{10},$$

$$P(X=1,Y=0)=P(\text{第一次红球，第二次白球})=\frac{2}{5}\cdot\frac{3}{4}=\frac{3}{10},$$

$$P(X=0,Y=1)=P(\text{第一次白球，第二次红球})=\frac{3}{5}\cdot\frac{2}{4}=\frac{3}{10},$$

$$P(X=0,Y=0)=P(\text{两次都摸到白球})=\frac{3}{5}\cdot\frac{2}{4}=\frac{3}{10}.$$

联合分布律表为

$X\backslash Y$	0	1
0	$\frac{3}{10}$	$\frac{3}{10}$
1	$\frac{3}{10}$	$\frac{1}{10}$

□

3.1.6 二维连续型随机变量

定义 3.5 (二维连续型随机变量)**.** 设 (X,Y) 是二维随机变量，其联合分布函数为 $F(x,y)$。若存在非负可积函数 $f(x,y)$，使得对任意实数 x,y，

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}f(u,v)\,dv\,du,$$

则称 (X,Y) 为**二维连续型随机变量**，并称 $f(x,y)$ 为 (X,Y) 的**联合概率密度函数**，简称**联合密度函数**。

联合密度函数 $f(x,y)$ 具有以下性质:

(1) **非负性**: $f(x,y)\geq 0$;

(2) **规范性**:

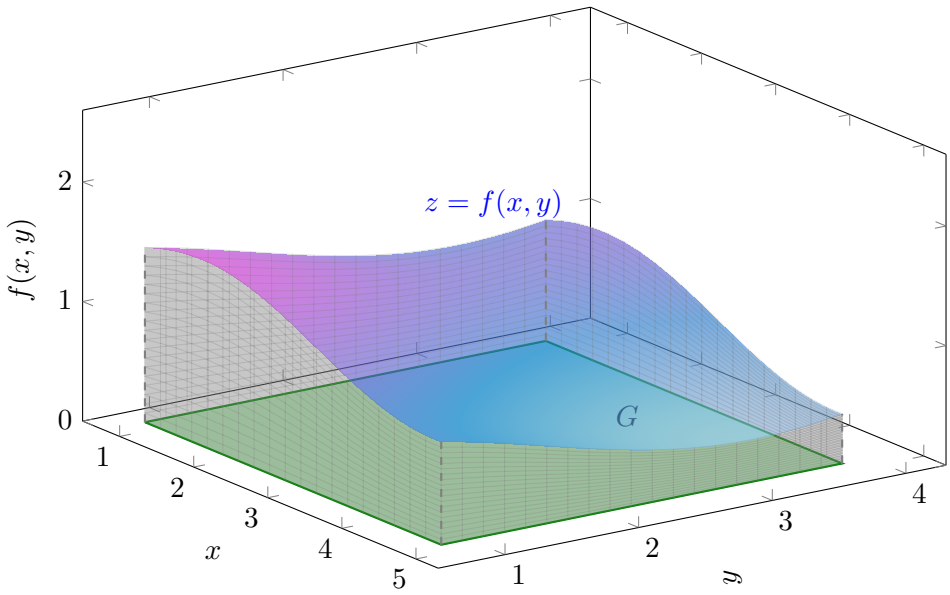
$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}f(x,y)\,dx\,dy=1;$$

(3) **区域概率公式**：对平面上任意区域 G，

$$P\big((X,Y)\in G\big)=\iint_G f(x,y)\,dx\,dy;$$

(4) **与分布函数的关系**：在 f 的连续点处，

$$\frac{\partial^2 F(x,y)}{\partial x\partial y}=f(x,y).$$



$$P((X,Y)\in G)=\iint_G f(x,y)\,dx\,dy$$

3.1.7 均匀分布

例 3.5 (二维均匀分布)**.** 设 (X,Y) 在矩形区域

$$D=[a,b]\times[c,d]$$

上服从均匀分布，求联合密度函数。

解. 由于 (X,Y) 在 D 上均匀分布，故密度函数在 D 上为常数，在 D 外为 0。设

$$f(x,y)=\begin{cases}C, & (x,y)\in D,\\ 0, & \text{其他}.\end{cases}$$

由规范性，

$$\iint_D C\,dx\,dy=C\cdot m(D)=1.$$

故

$$C=\frac{1}{m(D)}=\frac{1}{(b-a)(d-c)}.$$

因此

$$f(x,y)=\begin{cases}\dfrac{1}{(b-a)(d-c)}, & a\le x\le b,\ c\le y\le d,\\ 0, & \text{其他.}\end{cases}$$

□

注 3.5. 更一般地，若 (X,Y) 在平面区域 D 上服从均匀分布，则其联合密度函数为

$$f(x,y)=\begin{cases}\dfrac{1}{m(D)}, & (x,y)\in D,\\ 0, & \text{其他.}\end{cases}$$

其中 $m(D)$ 表示区域 D 的面积。

3.1.8 正态分布

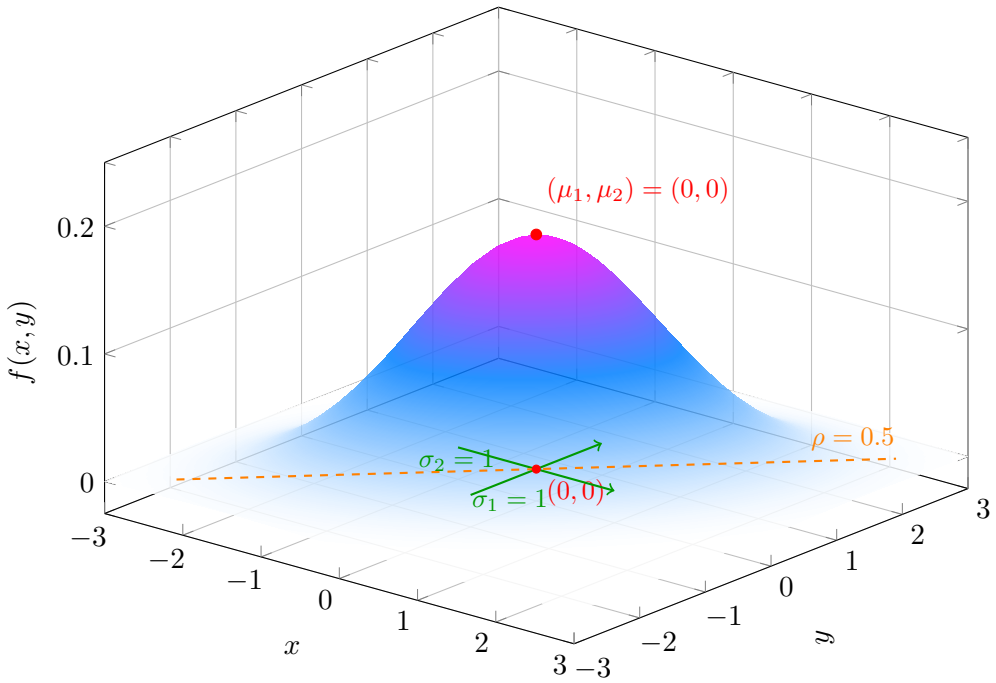
定义 3.6 (二元正态分布)**.** 若 (X,Y) 的联合密度函数为

$$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\},$$

其中 $\mu_1,\mu_2\in\mathbb{R}$，$\sigma_1,\sigma_2>0$，$-1<\rho<1$，则称 (X,Y) 服从**二元正态分布**，记作

$$(X,Y)\sim N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho).$$

注 3.6. 二元正态分布是最重要的二维连续型分布。参数 ρ 称为**相关系数**，它刻画 X 与 Y 之间的线性相关程度。当 $\rho=0$ 时，X 与 Y 不相关；在二元正态情形下，$\rho=0$ 还等价于 X 与 Y 相互独立。



二元正态分布 $N(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)$ 的密度曲面：$\mu_1=\mu_2=0$，$\sigma_1=\sigma_2=1$，$\rho=0.5$

注 3.7. 二元正态分布的密度函数图形像一顶“帽子”,其等高线是一族椭圆。椭圆的中心是 (μ_1, μ_2)，椭圆的形状由 σ_1, σ_2 和 ρ 共同决定。

3.2 边缘分布与条件分布

3.2.1 边缘分布

定义 3.7 (边缘分布函数)**.** 设 (X, Y) 的联合分布函数为 $F(x, y)$，则称

$$F_X(x) = P(X \le x) = F(x, +\infty) = \lim_{y \to +\infty} F(x, y)$$

为 X 的**边缘分布函数**；同理，

$$F_Y(y) = P(Y \le y) = F(+\infty, y) = \lim_{x \to +\infty} F(x, y)$$

为 Y 的边缘分布函数。

注 3.8. 边缘分布完全由联合分布决定，但反过来，由边缘分布一般**不能**确定联合分布。也就是说，联合分布包含的信息比两个边缘分布加起来还要多。

离散型情形

若 (X, Y) 的联合分布律为

$$p_{ij} = P(X = x_i,\ Y = y_j), \qquad i, j = 1, 2, \dots$$

则 X 和 Y 的边缘分布律分别为

$$p_{i\cdot} = P(X = x_i) = \sum_{j=1}^{\infty} p_{ij}, \qquad p_{\cdot j} = P(Y = y_j) = \sum_{i=1}^{\infty} p_{ij}.$$

在联合分布律的表格中，边缘分布律就是” 行和” 与” 列和”。在二维离散随机变量的分布律表格的最后一列可以补上 X 的边缘分布律 $p_{i\cdot}$，最后一行是 Y 的边缘分布律 $p_{\cdot j}$：

$X \backslash Y$	y_1	y_2	$\cdots$	y_j	$p_{i\cdot}$
x_1	p_{11}	p_{12}	$\cdots$	p_{1j}	$p_{1\cdot}$
x_2	p_{21}	p_{22}	$\cdots$	p_{2j}	$p_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
x_i	p_{i1}	p_{i2}	$\cdots$	p_{ij}	$p_{i\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
$p_{\cdot j}$	$p_{\cdot 1}$	$p_{\cdot 2}$	$\cdots$	$p_{\cdot j}$	1

其中

$$p_{i\cdot} = P(X = x_i) = \sum_{j=1}^{\infty} p_{ij}, \qquad p_{\cdot j} = P(Y = y_j) = \sum_{i=1}^{\infty} p_{ij}.$$

例 3.6 (离散型随机变量的边缘分布律)**.** 设二维离散型随机变量 (X,Y) 的联合分布律如下表所示，求 X 与 Y 的边缘分布律。

$X\backslash Y$	0	1	2	$p_{i\cdot}$
0	0.10	0.15	0.05	0.30
1	0.20	0.25	0.10	0.55
2	0.05	0.05	0.05	0.15
$p_{\cdot j}$	0.35	0.45	0.20	1.00

解. 边缘分布律由联合分布律的**行和**与**列和**得到。

按" 行和" 得到 X 的边缘分布律：

$$P(X=0)=0.10+0.15+0.05=0.30,$$

$$P(X=1)=0.20+0.25+0.10=0.55,$$

$$P(X=2)=0.05+0.05+0.05=0.15.$$

即

X	0	1	2
P	0.30	0.55	0.15

按" 列和" 得到 Y 的边缘分布律：

$$P(Y=0)=0.10+0.20+0.05=0.35,$$

$$P(Y=1)=0.15+0.25+0.05=0.45,$$

$$P(Y=2)=0.05+0.10+0.05=0.20.$$

即

Y	0	1	2
P	0.35	0.45	0.20

可以验证：

$$0.30+0.55+0.15=1,\qquad 0.35+0.45+0.20=1,$$

均满足规范性。 □

注 3.9. 本例中 X 与 Y 的边缘分布律均由联合分布律" 求和" 得到。边缘分布完全由联合分布决定；反之，仅由边缘分布一般**不能**唯一确定联合分布。

连续型情形

命题 3.2 (边缘密度公式)**.** *若 (X,Y) 的联合密度为 $f(x,y)$，则 X 和 Y 的边缘密度分别为*

$$f_X(x)=\int_{-\infty}^{+\infty} f(x,y)\,dy,\qquad f_Y(y)=\int_{-\infty}^{+\infty} f(x,y)\,dx.$$

证明. 设 (X,Y) 的联合分布函数为

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y} f(u,v)\,dv\,du.$$

X 的边缘分布函数为

$$F_X(x)=P(X\le x)=P(X\le x,\ Y<+\infty).$$

在联合分布函数中令 $y\to+\infty$，得

$$F_X(x)=\lim_{y\to+\infty}F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{+\infty} f(u,v)\,dv\,du.$$

两边对 x 求导，由微积分基本定理，得

$$f_X(x)=\frac{d}{dx}F_X(x)=\int_{-\infty}^{+\infty} f(x,y)\,dy.$$

同理，令 $x\to+\infty$ 得

$$F_Y(y)=\int_{-\infty}^{y}\int_{-\infty}^{+\infty} f(u,v)\,du\,dv,$$

两边对 y 求导，得

$$f_Y(y)=\int_{-\infty}^{+\infty} f(x,y)\,dx.$$

证毕。 □

例 3.7 (单位正方形上的均匀分布)**.** 设 (X,Y) 的联合密度为

$$f(x,y)=\begin{cases}1, & 0\le x\le 1,\ 0\le y\le 1,\\ 0, & \text{其他.}\end{cases}$$

求 X 与 Y 的边缘密度 $f_X(x)$ 与 $f_Y(y)$。

解. 当 $0\le x\le 1$ 时，

$$f_X(x)=\int_{-\infty}^{+\infty} f(x,y)\,dy=\int_0^1 1\,dy=1.$$

当 $x<0$ 或 $x>1$ 时，$f_X(x)=0$。故

$$f_X(x)=\begin{cases}1, & 0\le x\le 1,\\ 0, & \text{其他.}\end{cases}$$

同理

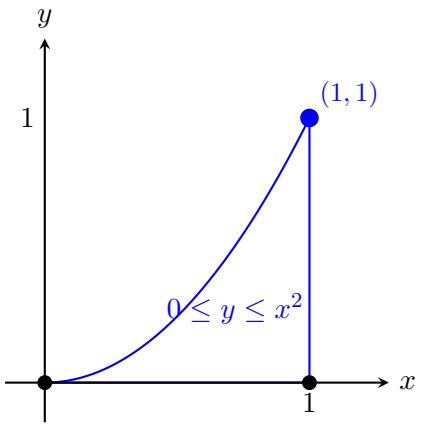
$$f_Y(y)=\begin{cases}1, & 0\le y\le 1,\\ 0, & \text{其他.}\end{cases}$$

可见 $X\sim U(0,1)$，$Y\sim U(0,1)$。 □

例 3.8 (连续型随机变量的边缘分布)**.** 设 (X,Y) 的联合密度为

$$f(x,y)=\begin{cases} c\,x, & 0\le x\le 1,\ 0\le y\le x^2,\\ 0, & \text{其他,}\end{cases}$$

其中 $c>0$ 为常数。求常数 c，并求 X 与 Y 的边缘密度 $f_X(x)$ 与 $f_Y(y)$。



联合密度的支撑区域

解. 由规范性条件 $\iint_{\mathbb{R}^2} f(x,y)\,dx\,dy=1$，得

$$\int_0^1\int_0^{x^2} c\,x\,dy\,dx = c\int_0^1 x^3\,dx=\frac{c}{4}=1,$$

故 $c=4$，即

$$f(x,y)=\begin{cases} 4x, & 0\le x\le 1,\ 0\le y\le x^2,\\ 0, & \text{其他.}\end{cases}$$

当 $0\le x\le 1$ 时，

$$f_X(x)=\int_{-\infty}^{+\infty} f(x,y)\,dy=\int_0^{x^2} 4x\,dy=4x^3.$$

当 $x<0$ 或 $x>1$ 时 $f_X(x)=0$，所以

$$f_X(x)=\begin{cases} 4x^3, & 0\le x\le 1,\\ 0, & \text{其他.}\end{cases}$$

当 $0\le y\le 1$ 时，由 $y\le x^2$ 得 $x\ge\sqrt{y}$，因此

$$f_Y(y)=\int_{-\infty}^{+\infty} f(x,y)\,dx=\int_{\sqrt{y}}^1 4x\,dx=2(1-y).$$

当 $y<0$ 或 $y>1$ 时 $f_Y(y)=0$，所以

$$f_Y(y)=\begin{cases} 2(1-y), & 0\le y\le 1,\\ 0, & \text{其他.}\end{cases}$$

□

注 3.10. 本例中联合密度的支撑区域 $0 \le y \le x^2$ 是**非矩形区域**，因此求 $f_Y(y)$ 时的积分下限不是 0 而是 $\sqrt{y}$。这说明边缘密度的积分限必须由联合密度的支撑区域来确定。

3.2.2 条件分布

定义 3.8 (条件分布律)**.** 对离散型随机变量 (X, Y)，若 $P(Y = y_j) > 0$，则称

$$P(X = x_i \mid Y = y_j) = \frac{P(X = x_i,\ Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_{\cdot j}}$$

为在 $Y = y_j$ 条件下 X 的**条件分布律**。同理，若 $P(X = x_i) > 0$，则

$$P(Y = y_j \mid X = x_i) = \frac{p_{ij}}{p_{i\cdot}}$$

为在 $X = x_i$ 条件下 Y 的条件分布律。

例 3.9 (离散型随机变量的条件分布律)**.** 设二维离散型随机变量 (X, Y) 的联合分布律如下表所示，求 $Y = 1$ 条件下 X 的条件分布律，以及 $X = 1$ 条件下 Y 的条件分布律。

$X \backslash Y$	0	1	2	$p_{i\cdot}$
0	0.10	0.15	0.05	0.30
1	0.20	0.25	0.10	0.55
2	0.05	0.05	0.05	0.15
$p_{\cdot j}$	0.35	0.45	0.20	1.00

解. 由表可得 Y 的边缘分布律为

$$P(Y = 0) = 0.35, \quad P(Y = 1) = 0.45, \quad P(Y = 2) = 0.20.$$

在 $Y = 1$ 条件下，X 的条件分布律为

$$P(X = x_i \mid Y = 1) = \frac{P(X = x_i,\ Y = 1)}{P(Y = 1)}, \qquad i = 0, 1, 2.$$

逐项计算：

$$P(X = 0 \mid Y = 1) = \frac{0.15}{0.45} = \frac{1}{3},$$
$$P(X = 1 \mid Y = 1) = \frac{0.25}{0.45} = \frac{5}{9},$$
$$P(X = 2 \mid Y = 1) = \frac{0.05}{0.45} = \frac{1}{9}.$$

即

$X \mid Y = 1$	0	1	2
P	$\frac{1}{3}$	$\frac{5}{9}$	$\frac{1}{9}$

可以验证：

$$\frac{1}{3} + \frac{5}{9} + \frac{1}{9} = 1.$$

同理，由 X 的边缘分布律

$$P(X=0)=0.30,\quad P(X=1)=0.55,\quad P(X=2)=0.15,$$

在 $X=1$ 条件下，Y 的条件分布律为

$$P(Y=y_j\mid X=1)=\frac{P(X=1,\ Y=y_j)}{P(X=1)},\qquad j=0,1,2.$$

逐项计算：

$$P(Y=0\mid X=1)=\frac{0.20}{0.55}=\frac{4}{11},$$
$$P(Y=1\mid X=1)=\frac{0.25}{0.55}=\frac{5}{11},$$
$$P(Y=2\mid X=1)=\frac{0.10}{0.55}=\frac{2}{11}.$$

即

$Y\mid X=1$	0	1	2
P	$\frac{4}{11}$	$\frac{5}{11}$	$\frac{2}{11}$

可以验证：

$$\frac{4}{11}+\frac{5}{11}+\frac{2}{11}=1.$$

□

注 3.11. 条件分布律的计算步骤为：

(1) 先由联合分布律求出作为” 条件” 的那个变量的边缘分布律；

(2) 用联合分布律的对应项除以该边缘概率；

(3) 结果应满足规范性（各条件概率之和为 1）。

本例中，$Y=1$ 条件下 X 的条件分布与 X 的边缘分布不同，说明 X 与 Y 不独立。

定义 3.9 (条件密度)**.** 对连续型随机变量 (X,Y)，若边缘密度 $f_Y(y)>0$，则称

$$f_{X|Y}(x\mid y)=\frac{f(x,y)}{f_Y(y)}$$

为在 $Y=y$ 条件下 X 的**条件密度**。同理，若 $f_X(x)>0$，则

$$f_{Y|X}(y\mid x)=\frac{f(x,y)}{f_X(x)}$$

为在 $X=x$ 条件下 Y 的条件密度。

注 3.12. 条件密度的定义式可以从条件分布函数自然导出。以 $f_{X|Y}(x\mid y)$ 为例：

对任意 x，考虑条件分布函数

$$F_{X|Y}(x\mid y)=P(X\le x\mid Y=y).$$

由于 Y 是连续型随机变量，$P(Y=y)=0$，不能直接用条件概率公式，因此改用极限

$$P(X \le x \mid Y=y)=\lim_{h\to 0^+} P(X \le x \mid y<Y\le y+h).$$

由条件概率的定义，

$$P(X \le x \mid y<Y\le y+h)=\frac{P(X\le x,\ y<Y\le y+h)}{P(y<Y\le y+h)}.$$

分子、分母都用联合密度和边缘密度表示：

$$P(X\le x,\ y<Y\le y+h)=\int_{-\infty}^{x}\int_{y}^{y+h} f(u,v)\,dv\,du,$$

$$P(y<Y\le y+h)=\int_{y}^{y+h} f_Y(v)\,dv.$$

代入并取极限，由积分中值定理（当 $h\to 0^+$ 时），得

$$P(X\le x \mid Y=y)=\frac{\displaystyle\int_{-\infty}^{x} f(u,y)\,du}{f_Y(y)}=\int_{-\infty}^{x}\frac{f(u,y)}{f_Y(y)}\,du.$$

这说明 $X \mid Y=y$ 的分布函数可以写成某个密度的积分形式，而这个密度正是

$$f_{X|Y}(x \mid y)=\frac{f(x,y)}{f_Y(y)}.$$

同理可得

$$f_{Y|X}(y \mid x)=\frac{f(x,y)}{f_X(x)}.$$

例 3.10 (单位正方形上均匀分布的条件密度)**.** 设 (X,Y) 的联合密度为

$$f(x,y)=\begin{cases}1, & 0\le x\le 1,\ 0\le y\le 1,\\ 0, & \text{其他}.\end{cases}$$

求在 $Y=y$（$0\le y\le 1$）条件下 X 的条件密度 $f_{X|Y}(x \mid y)$，以及在 $X=x$（$0\le x\le 1$）条件下 Y 的条件密度 $f_{Y|X}(y \mid x)$。

解. 由前面例题，知边缘密度

$$f_Y(y)=\begin{cases}1, & 0\le y\le 1,\\ 0, & \text{其他}.\end{cases}$$

对 $0\le y\le 1$，由条件密度公式

$$f_{X|Y}(x \mid y)=\frac{f(x,y)}{f_Y(y)}.$$

当 $0\le x\le 1$ 时，$f(x,y)=1$，$f_Y(y)=1$，故

$$f_{X|Y}(x \mid y)=1;$$

当 $x<0$ 或 $x>1$ 时 $f_{X|Y}(x\mid y)=0$。所以，对于 $0\le y\le 1$，

$$f_{X|Y}(x\mid y)=\begin{cases}1, & 0\le x\le 1,\\ 0, & \text{其他.}\end{cases}$$

即在 $Y=y$ 条件下，$X\sim U(0,1)$。

同理，当 $0\le x\le 1$ 时，

$$f_X(x)=\int_{-\infty}^{+\infty} f(x,y)\,dy=\int_0^1 1\,dy=1,$$

故，对于 $0\le x\le 1$，

$$f_{Y|X}(y\mid x)=\frac{f(x,y)}{f_X(x)}=1.$$

即在 $X=x$ 条件下，$Y\sim U(0,1)$。 □

例 3.11 (连续型随机变量的条件密度)**.** 设 (X,Y) 的联合密度为

$$f(x,y)=\begin{cases}4x, & 0\le x\le 1,\ 0\le y\le x^2,\\ 0, & \text{其他.}\end{cases}$$

求在 $Y=y$（$0\le y\le 1$）条件下 X 的条件密度 $f_{X|Y}(x\mid y)$。

解. 前面已求出 X 与 Y 的边缘密度分别为

$$f_X(x)=\begin{cases}4x^3, & 0\le x\le 1,\\ 0, & \text{其他,}\end{cases}\qquad f_Y(y)=\begin{cases}2(1-y), & 0\le y\le 1,\\ 0, & \text{其他.}\end{cases}$$

对 $0\le y\le 1$，由条件密度公式

$$f_{X|Y}(x\mid y)=\frac{f(x,y)}{f_Y(y)}.$$

当 $y\le x^2$ 且 $0\le x\le 1$ 时，$f(x,y)=4x$；在此条件下 $x\ge\sqrt{y}$。因此，

$$f_{X|Y}(x\mid y)=\frac{4x}{2(1-y)}=\frac{2x}{1-y},\qquad \sqrt{y}\le x\le 1.$$

当 $x<\sqrt{y}$ 或 $x>1$ 时，$f_{X|Y}(x\mid y)=0$。所以，对于 $\sqrt{y}\le x\le 1$，

$$f_{X|Y}(x\mid y)=\begin{cases}\dfrac{2x}{1-y}, & \sqrt{y}\le x\le 1,\\ 0, & \text{其他.}\end{cases}$$

可以验证该条件密度的积分为 1：

$$\int_{\sqrt{y}}^1 \frac{2x}{1-y}\,dx=\frac{1}{1-y}\cdot x^2\Big|_{\sqrt{y}}^1=\frac{1-y}{1-y}=1.$$

□

注 3.13. 本例中条件密度 $f_{X|Y}(x \mid y)$ 的支撑区间是 $[\sqrt{y}, 1]$，随 y 变化而变化，说明 X 与 Y 不独立。条件密度的积分下限由联合密度的支撑区域确定，这是计算条件密度时最容易出错的地方。

例 3.12 (已知边缘密度与条件密度求反向条件密度)**.** 设随机变量 Y 的边缘密度为

$$f_Y(y) = \begin{cases} 3y^2, & 0 \le y \le 1, \\ 0, & \text{其他.} \end{cases}$$

且在给定 $Y = y$（$0 < y \le 1$）的条件下，X 的条件密度为

$$f_{X|Y}(x \mid y) = \begin{cases} \dfrac{2x}{y^2}, & 0 \le x \le y, \\ 0, & \text{其他.} \end{cases}$$

求在 $X = x$（$0 < x \le 1$）条件下 Y 的条件密度 $f_{Y|X}(y \mid x)$。

解. 首先，根据条件密度的乘法公式

$$f(x, y) = f_Y(y)\, f_{X|Y}(x \mid y),$$

将已知的边缘密度和条件密度代入。当 $0 \le y \le 1$ 且 $0 \le x \le y$ 时，联合密度为

$$f(x, y) = (3y^2) \cdot \left(\frac{2x}{y^2}\right) = 6x.$$

在其他区域，$f(x, y) = 0$。

接下来求 X 的边缘密度。由于支撑区域满足 $0 \le x \le y \le 1$，对于给定的 $x \in (0, 1]$，y 的积分下限为 x，上限为 1。因此：

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y)\, dy = \int_x^1 6x\, dy = 6x(1 - x), \qquad 0 \le x \le 1.$$

当 $x \notin [0, 1]$ 时，$f_X(x) = 0$。

最后，利用条件密度的定义式求反向条件密度。对于给定的 $x \in (0, 1]$，由于联合密度的支撑区域要求 $y \ge x$，所以 Y 的有效取值范围是 $x \le y \le 1$。因此：

$$f_{Y|X}(y \mid x) = \frac{f(x, y)}{f_X(x)} = \frac{6x}{6x(1 - x)} = \frac{1}{1 - x}, \qquad x \le y \le 1.$$

当 $y \notin [x, 1]$ 时，$f_{Y|X}(y \mid x) = 0$。 □

注 3.14. 本题的解题逻辑可以总结为以下三步：

(1) **构造联合密度**：利用乘法公式 $f(x, y) = f_Y(y) f_{X|Y}(x \mid y)$，将已知信息相乘，得到 $f(x, y) = 6x$。

(2) **求另一边缘密度**：对 y 积分得到 $f_X(x)$。此处需特别注意支撑区域是 $0 \le x \le y \le 1$，因此 y 的积分下限由 $y \ge x$ 决定。

(3) **求反向条件密度**：利用除法 $f_{Y|X}(y \mid x) = \dfrac{f(x,y)}{f_X(x)}$。此步骤的关键是明确 Y 的取值范围已经被 $X = x$ 锁定为 $[x, 1]$。

从结果 $f_{Y|X}(y \mid x) = \dfrac{1}{1-x}$（依赖于 x）可以看出，X 与 Y 显然是不独立的。

例 3.13 (二元正态分布的条件分布)**.** 设 $(X,Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$，则给定 $Y = y$ 时，X 的条件分布为

$$X \mid Y = y \ \sim \ N\!\left(\mu_1 + \rho\frac{\sigma_1}{\sigma_2}(y-\mu_2),\ \sigma_1^2(1-\rho^2)\right).$$

类似地，给定 $X = x$ 时，

$$Y \mid X = x \ \sim \ N\!\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x-\mu_1),\ \sigma_2^2(1-\rho^2)\right).$$

解. 只给出 $Y \mid X = x$ 的求解。首先给出 (X,Y) 的联合密度函数

$$f(x,y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

记

$$u = \frac{x-\mu_1}{\sigma_1}, \qquad v = \frac{y-\mu_2}{\sigma_2},$$

则联合密度的指数部分可以写成

$$Q(x,y) = u^2 - 2\rho uv + v^2.$$

对 v 配方，得

$$Q(x,y) = (v-\rho u)^2 + (1-\rho^2)u^2.$$

代回 u, v，有

$$\frac{Q(x,y)}{2(1-\rho^2)} = \frac{1}{2(1-\rho^2)}\left(\frac{y-\mu_2}{\sigma_2} - \rho\frac{x-\mu_1}{\sigma_1}\right)^2 + \frac{(x-\mu_1)^2}{2\sigma_1^2}.$$

于是联合密度可以分解为

$$f(x,y) = \underbrace{\frac{1}{\sqrt{2\pi}\,\sigma_1}\exp\left\{-\frac{(x-\mu_1)^2}{2\sigma_1^2}\right\}}_{f_X(x)} \cdot \underbrace{\frac{1}{\sqrt{2\pi}\,\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{y-\mu_2}{\sigma_2} - \rho\frac{x-\mu_1}{\sigma_1}\right)^2\right\}}_{f_{Y|X}(y|x)}.$$

由于第二个因子对 y 积分等于 1，故第一个因子就是 X 的边缘密度 $f_X(x)$，第二个因子即为条件密度 $f_{Y|X}(y \mid x)$。

将条件密度整理成标准正态密度的形式：

$$f_{Y|X}(y \mid x) = \frac{1}{\sqrt{2\pi}\,\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{\left(y-\mu_2-\rho\dfrac{\sigma_2}{\sigma_1}(x-\mu_1)\right)^2}{2\sigma_2^2(1-\rho^2)}\right\}.$$

对照正态密度

$$\frac{1}{\sqrt{2\pi}\,\sigma}\exp\left\{-\frac{(y-\mu)^2}{2\sigma^2}\right\},$$

即得

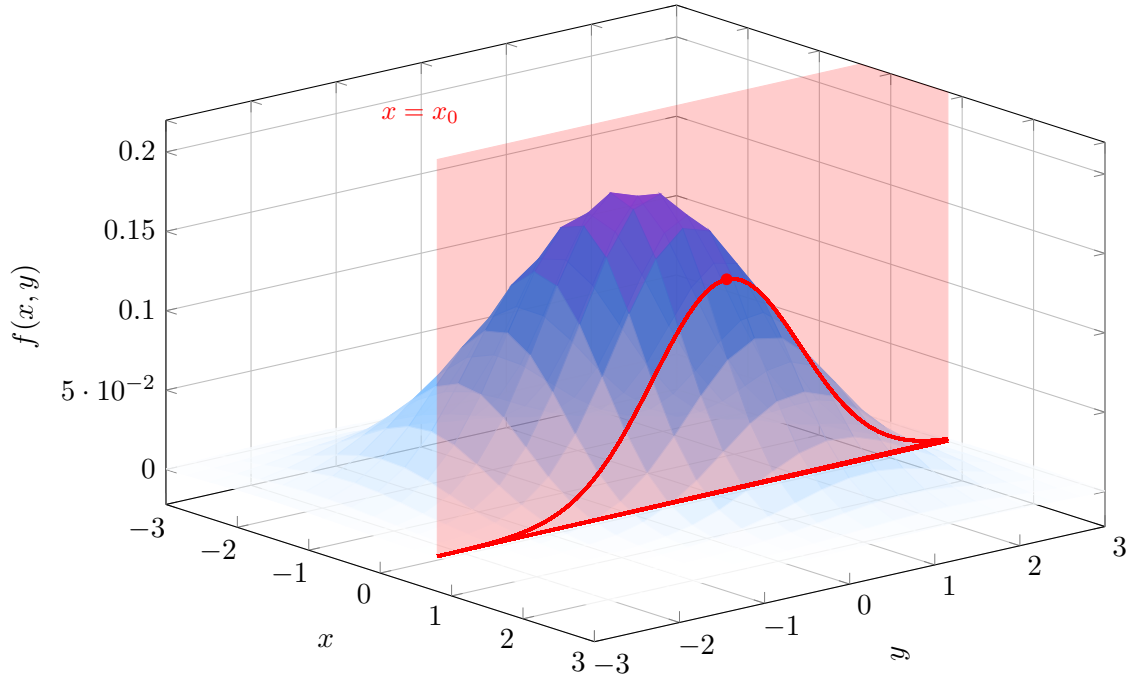
$$\mu = \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x-\mu_1), \qquad \sigma^2 = \sigma_2^2(1-\rho^2).$$

因此

$$Y \mid X = x \ \sim \ N\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x-\mu_1),\ \sigma_2^2(1-\rho^2)\right).$$

□

下面给出 $Y \mid X = x_0$ 的图解。



用竖直平面 $x = x_0$ 截二元正态密度曲面，交线是条件密度曲线：$Y \mid X = x_0 \sim N\big(\rho x_0,\ 1-\rho^2\big)$
$(\mu_1 = \mu_2 = 0,\ \sigma_1 = \sigma_2 = 1,\ \rho = 0.5)$

用平行于 yOz 平面的竖直平面 $x = x_0$ 切割二元正态密度曲面，截面上得到的曲线仍是正态密度：

$$Y \mid X = x_0 \sim N\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_0-\mu_1),\ \sigma_2^2(1-\rho^2)\right)$$

用竖直平面 $x = x_0$ 切割二元正态密度曲面，截面上的曲线仍是正态密度：

$$Y \mid X = x_0 \sim N\left(\mu_2 + \rho\tfrac{\sigma_2}{\sigma_1}(x_0-\mu_1),\ \sigma_2^2(1-\rho^2)\right)$$

注 3.15. 二元正态分布的条件分布仍是正态分布，且条件密度的中心随 y 线性变化，这正是“线性回归”的理论基础。

上图中：

- 中间隆起的曲面是联合密度 $f(x,y)$ 的图形，最外层的等高线到最内层的等高线，对应密度由低到高；
- 垂直于 x 轴的竖直平面是 $x = x_0$，它与密度曲面的交线用粗实线画出；
- 该交线正是给定 $X = x_0$ 时 Y 的条件密度曲线，其形状仍为正态密度曲线；
- 交线的最高点对应条件密度的中心，它在底面上的投影随 x_0 线性变化，其轨迹即回归直线。

3.3 随机变量的独立性

3.3.1 从条件分布到独立性

前面讨论了条件分布。条件分布刻画的是" 在已知某个随机变量取值的条件下，另一个随机变量的分布"。自然要问：是否存在一种情形，使得**条件分布与条件本身无关**?

离散型情形

设 (X,Y) 是二维离散型随机变量，联合分布律为

$$p_{ij} = P(X = x_i,\ Y = y_j).$$

在 $Y = y_j$ 条件下 X 的条件分布律为

$$P(X = x_i \mid Y = y_j) = \frac{p_{ij}}{p_{\cdot j}}, \qquad p_{\cdot j} = P(Y = y_j) > 0.$$

如果条件分布与条件 $Y = y_j$ 无关，即

$$P(X = x_i \mid Y = y_j) = P(X = x_i), \qquad \text{对所有} i, j,$$

那么代入条件分布律公式，得

$$\frac{p_{ij}}{p_{\cdot j}} = p_{i\cdot},$$

即

$$p_{ij} = p_{i\cdot}\, p_{\cdot j}, \qquad \text{对所有} i, j.$$

这说明：**联合分布律等于两个边缘分布律的乘积**。

连续型情形

设 (X,Y) 是二维连续型随机变量，联合密度为 $f(x,y)$，边缘密度为 $f_X(x), f_Y(y)$。在 $Y = y$ 条件下 X 的条件密度为

$$f_{X|Y}(x \mid y) = \frac{f(x,y)}{f_Y(y)}, \qquad f_Y(y) > 0.$$

如果条件密度与条件 $Y = y$ 无关，即

$$f_{X|Y}(x \mid y) = f_X(x), \qquad \text{对所有} x, y,$$

那么代入条件密度公式，得

$$\frac{f(x,y)}{f_Y(y)} = f_X(x),$$

即

$$f(x,y) = f_X(x)\, f_Y(y), \qquad \text{对所有} x, y.$$

同样地，**联合密度等于两个边缘密度的乘积**。

由此可见，" 条件分布不起作用" 这一情形，正好对应" 联合分布等于边缘分布的乘积"。这是二维随机变量中一种非常特殊、也非常重要的情形，我们把它单独命名。

3.3.2 独立性的定义

定义 3.10 (随机变量的独立性)**.** 设 (X,Y) 是二维随机变量，$F(x,y)$ 为其联合分布函数，$F_X(x)$、$F_Y(y)$ 分别为 X、Y 的边缘分布函数。若对任意实数 x,y，都有

$$F(x,y)=F_X(x)\,F_Y(y),$$

则称 X 与 Y **相互独立**。

由前面的讨论可知，独立性条件等价于：

- **离散型**：对任意 i,j，
$$p_{ij}=p_{i\cdot}\,p_{\cdot j};$$
- **连续型**：对任意 x,y，
$$f(x,y)=f_X(x)\,f_Y(y).$$

3.3.3 例子

例 3.14 (离散型：独立的例子——两次独立射击)**.** 某射手进行两次独立射击，每次命中目标的概率为 $p=\dfrac{1}{2}$。设

$$X=\begin{cases}1, & \text{第一次命中},\\ 0, & \text{第一次未命中},\end{cases}\qquad Y=\begin{cases}1, & \text{第二次命中},\\ 0, & \text{第二次未命中}.\end{cases}$$

求 (X,Y) 的联合分布律，并判断 X 与 Y 是否独立。

解. 由于两次射击相互独立，

$$P(X=i,\ Y=j)=P(X=i)\,P(Y=j),\qquad i,j=0,1.$$

而

$$P(X=1)=P(Y=1)=\frac{1}{2},\qquad P(X=0)=P(Y=0)=\frac{1}{2}.$$

故

$$P(X=0,Y=0)=\frac{1}{4},\quad P(X=0,Y=1)=\frac{1}{4},\quad P(X=1,Y=0)=\frac{1}{4},\quad P(X=1,Y=1)=\frac{1}{4}.$$

联合分布律表为

$X\backslash Y$	0	1	$p_{i\cdot}$
0	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
1	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{2}$
$p_{\cdot j}$	$\frac{1}{2}$	$\frac{1}{2}$	1

由表可见 $p_{ij}=p_{i\cdot}\,p_{\cdot j}$ 对一切 i,j 都成立，故 X 与 Y 相互独立。 □

注 3.16. 本例中 X 与 Y 独立，其根本原因是两次射击在物理上互不影响。一般地，**若两个随机变量分别由两次互不影响的试验产生，则它们独立**。

例 3.15 (离散型：不独立的例子——不放回摸球)**.** 袋中有 2 个红球和 3 个白球。现从袋中不放回地依次摸出两个球。设

$$X=\begin{cases}1, & \text{第一次摸到红球},\\ 0, & \text{第一次摸到白球},\end{cases}\qquad Y=\begin{cases}1, & \text{第二次摸到红球},\\ 0, & \text{第二次摸到白球}.\end{cases}$$

求 (X,Y) 的联合分布律，并判断 X 与 Y 是否独立。

解. 所有可能取值为 $(0,0),(0,1),(1,0),(1,1)$。计算各概率：

$$P(X=1,Y=1)=\frac{2}{5}\cdot\frac{1}{4}=\frac{1}{10},$$
$$P(X=1,Y=0)=\frac{2}{5}\cdot\frac{3}{4}=\frac{3}{10},$$
$$P(X=0,Y=1)=\frac{3}{5}\cdot\frac{2}{4}=\frac{3}{10},$$
$$P(X=0,Y=0)=\frac{3}{5}\cdot\frac{2}{4}=\frac{3}{10}.$$

联合分布律表为

$X\backslash Y$	0	1	$p_{i\cdot}$
0	$\frac{3}{10}$	$\frac{3}{10}$	$\frac{3}{5}$
1	$\frac{3}{10}$	$\frac{1}{10}$	$\frac{2}{5}$
$p_{\cdot j}$	$\frac{3}{5}$	$\frac{2}{5}$	1

检验：$p_{1\cdot}\,p_{\cdot 1}=\dfrac{2}{5}\cdot\dfrac{2}{5}=\dfrac{4}{25}$，而 $p_{11}=\dfrac{1}{10}$，两者不等，故 X 与 Y 不相互独立。 □

例 3.16 (连续型：独立的例子)**.** 设 (X,Y) 的联合密度为

$$f(x,y)=\begin{cases}e^{-(x+y)}, & x>0,\ y>0,\\ 0, & \text{其他}.\end{cases}$$

试判断 X 与 Y 是否相互独立。

解. 先求边缘密度。当 $x>0$ 时，

$$f_X(x)=\int_0^{+\infty}e^{-(x+y)}\,dy=e^{-x};$$

当 $x\le 0$ 时 $f_X(x)=0$，即

$$f_X(x)=\begin{cases}e^{-x}, & x>0,\\ 0, & x\le 0.\end{cases}$$

同理

$$f_Y(y)=\begin{cases}e^{-y}, & y>0,\\ 0, & y\le 0.\end{cases}$$

于是

$$f_X(x)\,f_Y(y)=\begin{cases}e^{-(x+y)}, & x>0,\ y>0,\\ 0, & \text{其他},\end{cases}$$

与 $f(x,y)$ 完全相同，故 X 与 Y 相互独立。 □

例 3.17 (连续型：不独立的例子——三角形区域上的均匀分布)**.** 设 (X,Y) 在区域 $D=\{(x,y):0\le x\le 1,\ 0\le y\le x\}$ 上服从均匀分布，即

$$f(x,y)=\begin{cases}2, & 0\le x\le 1,\ 0\le y\le x,\\ 0, & \text{其他}.\end{cases}$$

试判断 X 与 Y 是否相互独立。

解. 先求边缘密度。当 $0\le x\le 1$ 时，

$$f_X(x)=\int_0^x 2\,dy=2x;$$

当 $x<0$ 或 $x>1$ 时 $f_X(x)=0$。即

$$f_X(x)=\begin{cases}2x, & 0\le x\le 1,\\ 0, & \text{其他}.\end{cases}$$

当 $0\le y\le 1$ 时，由 $y\le x\le 1$ 得

$$f_Y(y)=\int_y^1 2\,dx=2(1-y);$$

当 $y<0$ 或 $y>1$ 时 $f_Y(y)=0$。即

$$f_Y(y)=\begin{cases}2(1-y), & 0\le y\le 1,\\ 0, & \text{其他}.\end{cases}$$

于是

$$f_X(x)\,f_Y(y)=\begin{cases}4x(1-y), & 0\le x\le 1,\ 0\le y\le 1,\\ 0, & \text{其他},\end{cases}$$

而 $f(x,y)=2$（当 $0\le y\le x\le 1$），两者不相等，故 X 与 Y 不相互独立。 □

注 3.17. 从上面的例子可以看出，独立性判断的关键在于：

- 若联合密度（或分布律）可以分解成” 只含 x 的因子 × 只含 y 的因子”，且因子乘积在整个平面上都等于联合密度，则独立；
- 若支撑区域不是” 矩形”，则必然不独立；
- 即使联合密度的表达式看起来像是可以分离的，也要检查支撑区域，支撑区域不是矩形就一定不独立。

3.3.4 连续型随机变量独立性的快速判定法

对于连续型随机变量 (X,Y)，要验证 $f(x,y)=f_X(x)f_Y(y)$ 往往需要先求两个边缘密度，过程较为繁琐。根据独立性的本质，我们可以得到一个非常实用的**快速判定定理**：

命题 3.3 (连续型独立性的快速判定)**.** *设二维连续型随机变量 (X,Y) 的联合密度函数为 $f(x,y)$。若满足以下两个条件：*

(1) **支撑区域为“矩形”** *使 $f(x,y)>0$ 的区域是形如 $a\le x\le b,\ c\le y\le d$ 的矩形（允许边界取 $-\infty$ 或 $+\infty$）；*

(2) **变量可分离**：*在支撑区域上，$f(x,y)$ 可以分解为只含 x 的函数与只含 y 的函数的乘积，即*

$$f(x,y)=g(x)h(y),\qquad (x,y)\in \text{矩形区域},$$

则 X 与 Y 相互独立。

证明. 设支撑区域为 $D=(a,b)\times(c,d)$（这里 a,b,c,d 可以是 $\pm\infty$）。在 D 上，联合密度为

$$f(x,y)=g(x)h(y).$$

我们只需证明 $f_X(x)f_Y(y)=f(x,y)$。

首先求 X 的边缘密度。当 $a<x<b$ 时，

$$f_X(x)=\int_{-\infty}^{+\infty}f(x,y)\,dy=\int_c^d g(x)h(y)\,dy=g(x)\int_c^d h(y)\,dy.$$

当 $x\le a$ 或 $x\ge b$ 时，$f_X(x)=0$。

同理，当 $c<y<d$ 时，

$$f_Y(y)=\int_{-\infty}^{+\infty}f(x,y)\,dx=\int_a^b g(x)h(y)\,dx=h(y)\int_a^b g(x)\,dx.$$

当 $y\le c$ 或 $y\ge d$ 时，$f_Y(y)=0$。

由于 $f(x,y)$ 是联合密度，其在整个平面上的积分必须为 1，即

$$\int_a^b\int_c^d g(x)h(y)\,dy\,dx=\left(\int_a^b g(x)\,dx\right)\left(\int_c^d h(y)\,dy\right)=1.$$

现在考察 $f_X(x)f_Y(y)$：当 $a<x<b$ 且 $c<y<d$ 时，

$$f_X(x)f_Y(y)=\left(g(x)\int_c^d h(y)\,dy\right)\left(h(y)\int_a^b g(x)\,dx\right)=g(x)h(y)\left(\int_a^b g(x)\,dx\right)\left(\int_c^d h(y)\,dy\right).$$

根据规范性条件，括号内两项的乘积为 1，故

$$f_X(x)f_Y(y)=g(x)h(y)=f(x,y).$$

而在矩形区域 D 之外，$f(x,y)=0$，且至少有一个边缘密度为 0，从而 $f_X(x)f_Y(y)=0=f(x,y)$。

因此在整个平面上都有 $f(x,y)=f_X(x)f_Y(y)$，故 X 与 Y 相互独立。证毕。 □

注 3.18 (解题方法：一看区域，二看分离)**.** 在实际解题中，判断连续型随机变量是否独立，可以按以下两步进行：

第 1 步： 看支撑区域：

- 画出使联合密度 $f(x,y)>0$ 的区域 D；
- 若 D 是一个**矩形**（例如 $0<x<1,\ 0<y<2$），则继续第 2 步；
- 若 D 的边界包含斜线或曲线（例如三角形区域 $0<y<x<1$ 或 $0<y<x^2$），则**直接判定不独立**，无需再算边缘密度。

第 2 步： 看能否分离：

- 在矩形区域内，观察 $f(x,y)$ 的表达式；
- 若 $f(x,y)$ 能写成 $g(x)h(y)$ 的形式（例如 x^2y、$e^{-(x+y)}$），则**判定相互独立**；
- 若 $f(x,y)$ 中含有 x,y 的“交叉项”（例如 $e^{-(x+y)^2}$、$x+y$），无法分离，则**判定不独立**。

例 3.18 (快速判定的应用)**.** 判断下列联合密度对应的 X 与 Y 是否独立：

(a) $f(x,y)=6xy^2,\quad 0<x<1,\ 0<y<1$；

(b) $f(x,y)=2,\quad 0<x<1,\ 0<y<x$；

(c) $f(x,y)=e^{-(x+y)},\quad x>0,\ y>0$；

(d) $f(x,y)=c(x+y),\quad 0<x<1,\ 0<y<1$。

解. 直接使用“一看区域，二看分离”法则：

(a) 支撑区域 $0<x<1,\ 0<y<1$ 是 ** 矩形 **；表达式 $6xy^2$ 可分离为 $6x$ 与 y^2 的乘积，故**独立**。

(b) 支撑区域 $0<y<x<1$ 是 ** 三角形 **，不是矩形。故**直接判定不独立**。（无需计算边缘密度，因为求 $f_Y(y)$ 时积分限会含有 y，导致无法分离。）

(c) 支撑区域 $x>0,\ y>0$ 是 ** 无界矩形 **；表达式 $e^{-(x+y)}=e^{-x}e^{-y}$ 可分离，故**独立**。

(d) 支撑区域是 ** 矩形 **；但表达式 $c(x+y)$ 含有 $x+y$ 这种不可分离的加法结构，故**不独立**。 □

3.3.5 更一般的定义：用事件独立性刻画

在前面，我们用分布函数或密度函数定义了随机变量的独立性。这一节从事件独立性的角度，给出一个更本质、更一般的定义。

回忆事件独立性的定义：若事件 A,B 满足

$$P(A\cap B)=P(A)\,P(B),$$

则称 A 与 B 相互独立。

对随机变量 X，把所有**与 X 有关的事件**组成的集合记作 $\sigma(X)$。由随机变量的定义，X 是样本空间 Ω 到实数集 $\mathbb{R}$ 的映射，即

$$X : \Omega \to \mathbb{R}, \qquad \omega \mapsto X(\omega).$$

对任意实数集合 $B \subset \mathbb{R}$，其原像

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}$$

是样本空间中的一个事件，表示"X 的取值落在 B 中"。把所有这些事件收集起来，就得到

$$\sigma(X) = \{X^{-1}(B) : B \subset \mathbb{R}\}.$$

这就是**所有与 X 有关的事件组成的集合**。

类似地，对随机变量 Y，相应地有

$$\sigma(Y) = \{Y^{-1}(B) : B \subset \mathbb{R}\}.$$

定义 3.11 (随机变量独立性的最一般定义)**.** 设 X, Y 是同一概率空间上的两个随机变量。若对任意 $A \in \sigma(X)$、$B \in \sigma(Y)$，都有

$$P(A \cap B) = P(A)\,P(B),$$

则称 X 与 Y **相互独立**。

这个定义可以这样理解：独立性就是**" 与 X 有关的事件" 和" 与 Y 有关的事件" 这两个事件族相互独立**——从每个事件族中各取出一个事件，它们都满足" 乘积事件的概率等于概率的乘积"。

注 3.19. 若在上面定义中取特殊的事件

$$A = X^{-1}\big((-\infty, x]\big) = \{X \le x\}, \qquad B = Y^{-1}\big((-\infty, y]\big) = \{Y \le y\},$$

则由独立性条件

$$P(X \le x,\ Y \le y) = P(X \le x)\,P(Y \le y),$$

即

$$F(x, y) = F_X(x)\,F_Y(y),$$

这正是前面用分布函数给出的独立性定义。

由于形如 $\{X \le x\}$ 的事件能生成 $\sigma(X)$ 中的其它事件，因此，只要对这类特殊事件验证独立性，就等价于对 $\sigma(X)$ 中所有事件都验证独立性。所以分布函数形式的定义与这里的一般定义是等价的。

注 3.20. 用事件集合的方式定义独立性，可以自然地推广到多个随机变量：

- 若对任意 $A \in \sigma(X_1),\ B \in \sigma(X_2), \ldots,\ Z \in \sigma(X_n)$ 都有

$$P(A \cap B \cap \cdots \cap Z) = P(A)\,P(B) \cdots P(Z),$$

则称 $X_1, X_2, \ldots, X_n$ 相互独立；

- 它与用联合分布函数
$$F(x_1,\dots,x_n)=F_{X_1}(x_1)\cdots F_{X_n}(x_n)$$
给出的定义也是等价的。

注 3.21. 用事件集合的方式定义独立性，可以自然地推广到多个乃至无穷多个随机变量的情形。

- 设 $X_1,X_2,\dots,X_n$ 是同一概率空间上的随机变量。若对任意 $A_1\in\sigma(X_1)$, $A_2\in\sigma(X_2),\dots,$ $A_n\in\sigma(X_n)$ 都有
$$P(A_1\cap A_2\cap\cdots\cap A_n)=P(A_1)\,P(A_2)\cdots P(A_n),$$
则称 $X_1,X_2,\dots,X_n$ 相互独立。它与用联合分布函数
$$F(x_1,\dots,x_n)=F_{X_1}(x_1)\cdots F_{X_n}(x_n)$$
给出的定义等价。

- 设 $\{X_t:t\in T\}$ 是一族随机变量（T 可以是有限集、可列集，也可以是不可列集）。若对任意有限个指标 $t_1,t_2,\dots,t_n\in T$，随机变量 $X_{t_1},X_{t_2},\dots,X_{t_n}$ 都相互独立，则称这族随机变量**相互独立**。

  换句话说，**无穷多个随机变量的独立性，归结为其中任意有限个随机变量的独立性**。这样定义可以避免” 无穷多个事件同时发生” 所带来的技术困难，也保证了独立性的定义在有限与无穷情形下是统一的。

3.4 两个随机变量的函数

在实际问题中，我们经常遇到这样的情况：已知二维随机变量 (X,Y) 的分布，需要求其函数 $Z=g(X,Y)$ 的分布。例如，求两个随机变量之和 $Z=X+Y$、之积 $Z=XY$、之商 $Z=X/Y$ 的分布等。本节分别讨论离散型和连续型随机变量的函数的分布。

3.4.1 离散型随机变量函数的分布

设 (X,Y) 是二维离散型随机变量，其联合分布律为
$$p_{ij}=P(X=x_i,\ Y=y_j).$$
设 $Z=g(X,Y)$，则 Z 也是离散型随机变量，其可能取值为 $z_k=g(x_i,y_j)$。Z 的分布律为
$$P(Z=z_k)=\sum_{g(x_i,y_j)=z_k}P(X=x_i,\ Y=y_j),$$
即把所有使 $g(x_i,y_j)=z_k$ 的概率相加。

例 3.19 (离散型随机变量之和)**.** 设 X 与 Y 相互独立，且
$$P(X=0)=P(X=1)=\frac{1}{2},\qquad P(Y=0)=P(Y=1)=\frac{1}{2}.$$
求 $Z=X+Y$ 的分布律。

解. (X,Y) 的可能取值为 $(0,0),(0,1),(1,0),(1,1)$，概率均为 $\dfrac{1}{4}$。计算 $Z=X+Y$ 的取值：

(X,Y)	$(0,0)$	$(0,1)$	$(1,0)$	$(1,1)$
$Z=X+Y$	0	1	1	2
概率	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$

因此

$$P(Z=0)=\frac{1}{4},\qquad P(Z=1)=\frac{1}{4}+\frac{1}{4}=\frac{1}{2},\qquad P(Z=2)=\frac{1}{4}.$$

即

Z	0	1	2
P	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

□

和的分布与卷积

如果 X 与 Y 相互独立，且都是取非负整数的离散型随机变量，其分布律分别为

$$P(X=i)=p_i,\qquad P(Y=j)=q_j,\qquad i,j=0,1,2,\dots$$

则 $Z=X+Y$ 的分布律为

$$P(Z=k)=\sum_{i=0}^{k}P(X=i,\ Y=k-i)=\sum_{i=0}^{k}p_iq_{k-i},\qquad k=0,1,2,\dots$$

这一公式称为离散情形下的**卷积公式**。下面通过三个重要分布的卷积，展示这一方法的应用。

例 3.20 (二项分布的可加性)**.** 设 $X\sim B(n_1,p)$，$Y\sim B(n_2,p)$，且 X 与 Y 相互独立。证明：

$$X+Y\sim B(n_1+n_2,p).$$

解. 由卷积公式，

$$P(X+Y=k)=\sum_{i=0}^{k}P(X=i)P(Y=k-i)=\sum_{i=0}^{k}\binom{n_1}{i}p^i(1-p)^{n_1-i}\binom{n_2}{k-i}p^{k-i}(1-p)^{n_2-k+i}.$$

合并同类项：

$$P(X+Y=k)=p^k(1-p)^{n_1+n_2-k}\sum_{i=0}^{k}\binom{n_1}{i}\binom{n_2}{k-i}.$$

由组合恒等式（Vandermonde 卷积）：

$$\sum_{i=0}^{k}\binom{n_1}{i}\binom{n_2}{k-i}=\binom{n_1+n_2}{k}.$$

故

$$P(X+Y=k)=\binom{n_1+n_2}{k}p^k(1-p)^{n_1+n_2-k},\qquad k=0,1,\dots,n_1+n_2.$$

即 $X+Y\sim B(n_1+n_2,p)$。 □

例 3.21 (泊松分布的可加性)**.** 设 $X \sim P(\lambda_1)$，$Y \sim P(\lambda_2)$，且 X 与 Y 相互独立。证明：

$$X + Y \sim P(\lambda_1 + \lambda_2).$$

解. 由卷积公式，当 $k = 0, 1, 2, \ldots$ 时，

$$P(X + Y = k) = \sum_{i=0}^{k} P(X = i)P(Y = k - i) = \sum_{i=0}^{k} \frac{\lambda_1^i}{i!} e^{-\lambda_1} \cdot \frac{\lambda_2^{k-i}}{(k-i)!} e^{-\lambda_2}.$$

提出与 i 无关的因子：

$$P(X + Y = k) = e^{-(\lambda_1+\lambda_2)} \sum_{i=0}^{k} \frac{\lambda_1^i \lambda_2^{k-i}}{i!(k-i)!}.$$

将求和项乘以 $k!$ 并除以 $k!$，得

$$P(X + Y = k) = \frac{e^{-(\lambda_1+\lambda_2)}}{k!} \sum_{i=0}^{k} \frac{k!}{i!(k-i)!} \lambda_1^i \lambda_2^{k-i}.$$

由二项式定理，

$$\sum_{i=0}^{k} \binom{k}{i} \lambda_1^i \lambda_2^{k-i} = (\lambda_1 + \lambda_2)^k.$$

故

$$P(X + Y = k) = \frac{(\lambda_1 + \lambda_2)^k}{k!} e^{-(\lambda_1+\lambda_2)}, \qquad k = 0, 1, 2, \ldots$$

即 $X + Y \sim P(\lambda_1 + \lambda_2)$。 □

例 3.22 (几何分布的卷积)**.** 设 $X \sim G(p)$，$Y \sim G(p)$，且 X 与 Y 相互独立。求 $Z = X + Y$ 的分布律。

解. 注意几何分布 $G(p)$ 的取值从 1 开始：

$$P(X = i) = (1-p)^{i-1}p, \qquad P(Y = j) = (1-p)^{j-1}p, \qquad i, j = 1, 2, \ldots$$

当 $k \geq 2$ 时，由卷积公式，

$$P(X + Y = k) = \sum_{i=1}^{k-1} P(X = i)P(Y = k - i) = \sum_{i=1}^{k-1} (1-p)^{i-1}p \cdot (1-p)^{k-i-1}p.$$

合并同类项：

$$P(X + Y = k) = p^2 \sum_{i=1}^{k-1} (1-p)^{k-2} = (k-1)p^2(1-p)^{k-2}, \qquad k = 2, 3, \ldots$$

这就是参数为 $r = 2, p$ 的负二项分布。 □

注 3.22. 从上述三个例子可以看出：

- 两个独立的同参数二项分布之和仍为二项分布（参数 n 相加）；
- 两个独立的泊松分布之和仍为泊松分布（参数 λ 相加）；

- 两个独立的几何分布之和为负二项分布（即“等到第 2 次成功所需的试验次数”）。

这些结论体现了离散型随机变量在“加法”运算下的封闭性，是后续讨论独立同分布随机变量和的分布的基础。

特别地，二项分布的可加性可以与两点分布（$B(1,p)$）联系起来。设 $X_1, X_2, \ldots, X_n$ 是 n 个相互独立的随机变量，且都服从参数为 p 的两点分布，即

$$X_i \sim B(1,p), \qquad i = 1, 2, \ldots, n.$$

由二项分布的可加性，反复应用即可得到

$$X_1 + X_2 + \cdots + X_n \sim B(n,p).$$

这说明：**参数为 n, p 的二项分布，正是 n 个相互独立的参数为 p 的两点分布之和**。这不仅从“加法”的角度解释了二项分布的形成机制，也揭示了两点分布与二项分布之间的本质联系——**两点分布是 $n = 1$ 时的二项分布，而二项分布则是多个两点分布的叠加**。

3.4.2 连续型随机变量函数的分布

设 (X, Y) 是二维连续型随机变量，联合密度为 $f(x, y)$。求 $Z = g(X, Y)$ 的分布，通常采用**分布函数法**，具体步骤如下：

(1) 写出 Z 的分布函数

$$F_Z(z) = P(Z \le z) = P(g(X,Y) \le z);$$

(2) 在平面上找出区域

$$D_z = \{(x, y) : g(x, y) \le z\};$$

(3) 将概率转化为联合密度在区域 D_z 上的二重积分：

$$F_Z(z) = \iint_{D_z} f(x, y)\, dx\, dy;$$

(4) 对 $F_Z(z)$ 关于 z 求导，得 $f_Z(z) = F_Z'(z)$。

和的分布与卷积公式

设 $Z = X + Y$，求 $f_Z(z)$。

由分布函数法，

$$F_Z(z) = P(X + Y \le z) = \iint_{x+y \le z} f(x, y)\, dx\, dy.$$

积分区域 $x + y \le z$ 是一个半平面，可以用变换 $y = u - x$ 将积分写成

$$F_Z(z) = \int_{-\infty}^{+\infty} \int_{-\infty}^{z-x} f(x, y)\, dy\, dx.$$

对 z 求导，得

$$f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x)\,dx.$$

由对称性，也可写成

$$f_Z(z) = \int_{-\infty}^{+\infty} f(z-y, y)\,dy.$$

这两个公式称为**卷积公式**。

特别地，**若 X 与 Y 相互独立**，则 $f(x,y) = f_X(x)f_Y(y)$，此时

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x)f_Y(z-x)\,dx = \int_{-\infty}^{+\infty} f_X(z-y)f_Y(y)\,dy.$$

即两个独立随机变量之和的密度等于它们边缘密度的卷积。

下面通过两个经典的例子展示卷积公式的应用：一个是正态分布的卷积，另一个是指数分布的卷积。

例 3.23 (独立正态分布之和)**.** 设 $X \sim N(\mu_1, \sigma_1^2)$，$Y \sim N(\mu_2, \sigma_2^2)$，且 X 与 Y 相互独立。求 $Z = X + Y$ 的分布。

解. 由卷积公式，

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x)f_Y(z-x)\,dx.$$

代入正态密度：

$$f_Z(z) = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(z-x-\mu_2)^2}{2\sigma_2^2}}\,dx.$$

这是一个关于 x 的积分，可以通过配方化简。化简结果为

$$f_Z(z) = \frac{1}{\sqrt{2\pi}\sqrt{\sigma_1^2+\sigma_2^2}} e^{-\frac{(z-(\mu_1+\mu_2))^2}{2(\sigma_1^2+\sigma_2^2)}}.$$

因此

$$Z = X + Y \sim N(\mu_1 + \mu_2,\ \sigma_1^2 + \sigma_2^2).$$

这说明：**两个独立正态随机变量之和仍服从正态分布，且参数相加。** □

注 3.23 (正态分布的可加性)**.** 本例说明：两个相互独立的正态随机变量之和仍服从正态分布，且参数相加。这一结论称为正态分布的**可加性**。

可以进一步推广：若 $X_1, X_2, \ldots, X_n$ 相互独立，且 $X_i \sim N(\mu_i, \sigma_i^2)$，则它们的线性组合

$$\sum_{i=1}^{n} a_i X_i \sim N\left(\sum_{i=1}^{n} a_i\mu_i,\ \sum_{i=1}^{n} a_i^2\sigma_i^2\right),$$

其中 a_i 为常数。特别地，取 $a_i = 1$，得到

$$\sum_{i=1}^{n} X_i \sim N\left(\sum_{i=1}^{n} \mu_i,\ \sum_{i=1}^{n} \sigma_i^2\right).$$

这说明：**独立正态随机变量的线性组合仍服从正态分布**。正态分布的这一良好性质，使得它在数理统计中扮演着核心角色。

例 3.24 (独立指数分布之和)**.** 设 $X \sim \mathrm{Exp}(\lambda)$，$Y \sim \mathrm{Exp}(\mu)$，且 X 与 Y 相互独立。

(1) 求 $Z = X + Y$ 的密度；

(2) 当 $\mu = \lambda$ 时，求 Z 的密度；

(3) 当 $\mu = 2\lambda$ 时，求 Z 的密度。

解. 指数分布的密度为

$$f_X(x) = \lambda e^{-\lambda x}, \quad x > 0; \qquad f_Y(y) = \mu e^{-\mu y}, \quad y > 0.$$

由卷积公式，当 $z > 0$ 时，

$$f_Z(z) = \int_0^z f_X(x) f_Y(z-x)\,dx = \int_0^z \lambda e^{-\lambda x} \cdot \mu e^{-\mu(z-x)}\,dx.$$

将被积函数中的指数部分合并：

$$\lambda\mu e^{-\lambda x - \mu z + \mu x} = \lambda\mu e^{-\mu z} e^{(\mu-\lambda)x}.$$

提出与 x 无关的项 $\lambda\mu e^{-\mu z}$，得

$$f_Z(z) = \lambda\mu e^{-\mu z} \int_0^z e^{(\mu-\lambda)x}\,dx.$$

下面分情况讨论：

(1) 当 $\lambda \neq \mu$ 时：

$$\int_0^z e^{(\mu-\lambda)x}\,dx = \frac{e^{(\mu-\lambda)z} - 1}{\mu - \lambda}.$$

代回原式：

$$f_Z(z) = \lambda\mu e^{-\mu z} \frac{e^{(\mu-\lambda)z} - 1}{\mu - \lambda} = \frac{\lambda\mu}{\mu - \lambda}\left(e^{-\lambda z} - e^{-\mu z}\right).$$

故当 $z > 0$ 时，

$$f_Z(z) = \begin{cases} \dfrac{\lambda\mu}{\mu - \lambda}\left(e^{-\lambda z} - e^{-\mu z}\right), & z > 0, \\ 0, & z \leq 0. \end{cases}$$

(2) 当 $\mu = \lambda$ 时：

$$\int_0^z e^0\,dx = \int_0^z 1\,dx = z.$$

代回原式：

$$f_Z(z) = \lambda^2 e^{-\lambda z} \cdot z = \lambda^2 z e^{-\lambda z}.$$

故当 $z > 0$ 时，

$$f_Z(z) = \begin{cases} \lambda^2 z e^{-\lambda z}, & z > 0, \\ 0, & z \leq 0. \end{cases}$$

这时的结果即为 Erlang 分布（参数为 $n = 2, \lambda$）。

(3) 当 $\mu = 2\lambda$ 时：代入 (1) 中 $\lambda \neq \mu$ 的结果，此时 $\mu - \lambda = 2\lambda - \lambda = \lambda$：

$$f_Z(z) = \frac{\lambda \cdot 2\lambda}{2\lambda - \lambda}\left(e^{-\lambda z} - e^{-2\lambda z}\right) = 2\lambda\left(e^{-\lambda z} - e^{-2\lambda z}\right).$$

故当 $z > 0$ 时，

$$f_Z(z) = \begin{cases} 2\lambda\left(e^{-\lambda z} - e^{-2\lambda z}\right), & z > 0, \\ 0, & z \leq 0. \end{cases}$$

□

注 3.24 (Erlang 分布与 Gamma 分布)**.** 上例中 $Z = X + Y$ 的密度为

$$f_Z(z) = \frac{\lambda^2 z^{2-1} e^{-\lambda z}}{(2-1)!}, \qquad z > 0.$$

这正是参数为 $(r = 2, \lambda)$ 的 **Erlang 分布**。

一般地，若 $X_1, X_2, \ldots, X_r$ 是 r 个相互独立且均服从 Exp(λ) 的随机变量，则它们的和

$$Z = X_1 + X_2 + \cdots + X_r$$

服从参数为 (r, λ) 的 Erlang 分布，其密度为

$$f_Z(z) = \frac{\lambda^r z^{r-1} e^{-\lambda z}}{(r-1)!}, \qquad z > 0.$$

这个分布通常用来描述“r 个独立同分布的指数等待时间之和”，例如排队系统中第 r 个顾客到达的时间。

进一步，把阶乘 $(r-1)!$ 推广为 Gamma 函数 $\Gamma(r)$，就得到更一般的 **Gamma 分布**：

$$f_Z(z) = \frac{\lambda^r z^{r-1} e^{-\lambda z}}{\Gamma(r)}, \qquad z > 0,\ r > 0.$$

当 r 取正整数时，$\Gamma(r) = (r-1)!$，Gamma 分布即退化为 Erlang 分布；当 $r = 1$ 时，Gamma 分布退化为指数分布。因此，**Erlang 分布是 Gamma 分布在参数 r 取正整数时的特例**，而指数分布又是 Erlang 分布在 $r = 1$ 时的特例。

乘法的分布

设 $Z = XY$，求 $f_Z(z)$。

由分布函数法，

$$F_Z(z) = P(XY \leq z).$$

当 $z > 0$ 时，区域 $xy \leq z$ 可写为 $\{x > 0,\ y \leq z/x\} \cup \{x < 0,\ y \geq z/x\}$；当 $z < 0$ 时情况类似。为了直接求出密度，更方便的方法是使用变量代换。

引入变量代换

$$u = x, \qquad v = xy,$$

则 $x=u,\ y=v/u$，且雅可比行列式为

$$J=\left|\frac{\partial(x,y)}{\partial(u,v)}\right|=\begin{vmatrix}1 & 0\\ -v/u^2 & 1/u\end{vmatrix}=\frac{1}{|u|}.$$

于是 $(U,V)=(X,XY)$ 的联合密度为

$$f_{U,V}(u,v)=f\left(u,\frac{v}{u}\right)\frac{1}{|u|}.$$

对 u 积分，得 $Z=V=XY$ 的密度：

$$f_Z(z)=\int_{-\infty}^{+\infty}f\left(u,\frac{z}{u}\right)\frac{1}{|u|}\,du.$$

若 X 与 Y 相互独立，则

$$f_Z(z)=\int_{-\infty}^{+\infty}f_X(u)f_Y\left(\frac{z}{u}\right)\frac{1}{|u|}\,du.$$

例 3.25 (两个独立均匀分布之积)**.** 设 X,Y 相互独立，均服从 $[0,1]$ 上的均匀分布。求 $Z=XY$ 的密度。

解. 当 $0\le z\le 1$ 时，由乘法密度公式，

$$f_Z(z)=\int_{-\infty}^{+\infty}f_X(u)f_Y\left(\frac{z}{u}\right)\frac{1}{|u|}\,du.$$

由于 $0\le u\le 1$ 且 $0\le z/u\le 1$，即 $u\ge z$，故积分区间为 $z\le u\le 1$：

$$f_Z(z)=\int_z^1 1\cdot 1\cdot\frac{1}{u}\,du=\ln u\Big|_z^1=-\ln z.$$

当 $z<0$ 或 $z>1$ 时 $f_Z(z)=0$。故

$$f_Z(z)=\begin{cases}-\ln z, & 0<z\le 1,\\ 0, & \text{其他.}\end{cases}$$

□

除法的分布

设 $Z=\dfrac{X}{Y}$，求 $f_Z(z)$。

由分布函数法，

$$F_Z(z)=P\left(\frac{X}{Y}\le z\right).$$

当 $Y>0$ 时，条件 $X/Y\le z$ 等价于 $X\le zY$；当 $Y<0$ 时，等价于 $X\ge zY$。因此

$$F_Z(z)=\int_0^{+\infty}\int_{-\infty}^{zy}f(x,y)\,dx\,dy+\int_{-\infty}^{0}\int_{zy}^{+\infty}f(x,y)\,dx\,dy.$$

对 z 求导，得

$$f_Z(z)=\int_0^{+\infty}yf(zy,y)\,dy-\int_{-\infty}^{0}yf(zy,y)\,dy=\int_{-\infty}^{+\infty}|y|f(zy,y)\,dy.$$

若 X 与 Y 相互独立，则

$$f_Z(z)=\int_{-\infty}^{+\infty}|y|f_X(zy)f_Y(y)\,dy.$$

例 3.26 (两个独立指数分布之比)**.** 设 $X \sim \mathrm{Exp}(\lambda_1)$，$Y \sim \mathrm{Exp}(\lambda_2)$，且 X 与 Y 相互独立。求 $Z = X/Y$ 的密度。

解. 当 $z > 0$ 时，由商的密度公式，

$$f_Z(z) = \int_0^{+\infty} y f_X(zy) f_Y(y)\, dy = \int_0^{+\infty} y \cdot \lambda_1 e^{-\lambda_1 zy} \cdot \lambda_2 e^{-\lambda_2 y}\, dy.$$

合并指数项：

$$f_Z(z) = \lambda_1\lambda_2 \int_0^{+\infty} y e^{-(\lambda_1 z + \lambda_2)y}\, dy.$$

由积分公式 $\displaystyle\int_0^{+\infty} y e^{-ay}\, dy = \frac{1}{a^2}$（$a > 0$），得

$$f_Z(z) = \frac{\lambda_1\lambda_2}{(\lambda_1 z + \lambda_2)^2}, \qquad z > 0.$$

当 $z \le 0$ 时，$f_Z(z) = 0$。 □

最大值与最小值的分布

在实际问题中，我们经常会遇到求 n 个随机变量中最大值或最小值的分布的情况，例如在可靠性分析中，串联系统的寿命是各元件寿命的**最小值**，而并联系统的寿命则是各元件寿命的**最大值**。

设 X 与 Y 相互独立，分布函数分别为 $F_X(x)$ 和 $F_Y(y)$，密度函数分别为 $f_X(x)$ 和 $f_Y(y)$。令

$$M = \max(X, Y), \qquad N = \min(X, Y).$$

先求 M 的分布函数：

$$F_M(z) = P(\max(X, Y) \le z) = P(X \le z,\ Y \le z).$$

由独立性，

$$F_M(z) = P(X \le z)P(Y \le z) = F_X(z)F_Y(z).$$

若 X, Y 均为连续型随机变量，对 $F_M(z)$ 求导，可得 M 的密度：

$$f_M(z) = f_X(z)F_Y(z) + F_X(z)f_Y(z).$$

同理，求 N 的分布函数：

$$F_N(z) = P(\min(X, Y) \le z) = 1 - P(\min(X, Y) > z) = 1 - P(X > z,\ Y > z).$$

由独立性，

$$F_N(z) = 1 - \big[1 - F_X(z)\big]\big[1 - F_Y(z)\big].$$

例 3.27 (最大值与最小值的分布)**.** 设随机变量 X 和 Y 相互独立，且都服从参数为 λ 的指数分布。求 $M = \max(X, Y)$ 和 $N = \min(X, Y)$ 的密度函数。

解. 指数分布的分布函数和密度函数分别为

$$F(x) = 1 - e^{-\lambda x}, \qquad f(x) = \lambda e^{-\lambda x}, \qquad x > 0.$$

对于最大值 $M = \max(X, Y)$:

$$F_M(z) = F_X(z)F_Y(z) = (1 - e^{-\lambda z})^2, \qquad z > 0.$$

求导得密度函数:

$$f_M(z) = 2\lambda e^{-\lambda z}(1 - e^{-\lambda z}), \qquad z > 0.$$

对于最小值 $N = \min(X, Y)$:

$$F_N(z) = 1 - \big[1 - F_X(z)\big]\big[1 - F_Y(z)\big] = 1 - \big(e^{-\lambda z}\big)\big(e^{-\lambda z}\big) = 1 - e^{-2\lambda z}, \qquad z > 0.$$

求导得密度函数:

$$f_N(z) = 2\lambda e^{-2\lambda z}, \qquad z > 0.$$

□

注 3.25. 从上面的结果可以看到，当 X, Y 独立同分布于 $\mathrm{Exp}(\lambda)$ 时:

- 最小值 $N = \min(X, Y)$ 服从参数为 2λ 的指数分布，即 $N \sim \mathrm{Exp}(2\lambda)$;
- 最大值 $M = \max(X, Y)$ 的密度为

$$f_M(z) = 2\lambda\big(e^{-\lambda z} - e^{-2\lambda z}\big), \qquad z > 0.$$

值得注意的是，这个最大值的密度与前面例题中"参数分别为 λ 和 2λ 的两个独立指数分布之和"的密度完全一致。也就是说，

$$\max(X, Y) \text{ 与 } X + Y \text{ 同分布}, \qquad X, Y \overset{i.i.d.}{\sim} \mathrm{Exp}(\lambda).$$

这是一个很有意思的概率恒等式，可以通过卷积公式或分布函数直接验证。

注 3.26 (n 个独立随机变量的最大值与最小值)**.** 上面关于最大值和最小值的结果可以自然地推广到 n 个相互独立的随机变量 $X_1, X_2, \ldots, X_n$ 的情形。

设 $X_1, X_2, \ldots, X_n$ 相互独立，分布函数均为 $F(x)$。

(1) 最大值 $M = \max(X_1, \ldots, X_n)$ 的分布函数为

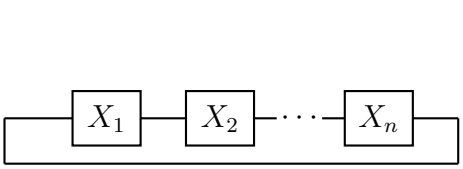
$$F_M(z) = P(M \le z) = P(X_1 \le z, \ldots, X_n \le z) = [F(z)]^n.$$

(2) 最小值 $N = \min(X_1, \ldots, X_n)$ 的分布函数为

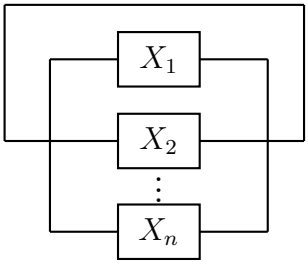
$$F_N(z) = 1 - P(N > z) = 1 - P(X_1 > z, \ldots, X_n > z) = 1 - [1 - F(z)]^n.$$

在可靠性理论中，这两个结果有着非常直观的物理背景:

- **最小值对应串联系统**：若一个系统由 n 个元件串联而成，只要有一个元件失效，整个系统就会失效。因此，**系统的寿命等于各元件寿命的最小值**。若各元件寿命独立同分布于 $\mathrm{Exp}(\lambda)$，则系统寿命 $N \sim \mathrm{Exp}(n\lambda)$。系统寿命的"失效率"随元件个数 n 的增加而线性增大。
- **最大值对应并联系统**：若一个系统由 n 个元件并联而成，只要有一个元件正常工作，整个系统就能正常工作。因此，**系统的寿命等于各元件寿命的最大值**。若各元件寿命独立同分布于 $\mathrm{Exp}(\lambda)$，则系统寿命 M 的分布函数为 $F_M(z) = (1 - e^{-\lambda z})^n$。随着 n 的增大，系统寿命会显著延长。



串联系统：寿命 $N = \min(X_1, \ldots, X_n)$



并联系统：寿命 $M = \max(X_1, \ldots, X_n)$

二维随机变量函数的雅可比行列式变换法

前面我们通过"分布函数法"求解了 $Z = X + Y$ 的分布，该方法（先求二重积分，再对 z 求导）虽然直观，但在处理一些复杂的函数关系时往往积分困难。为此，我们引入基于多重积分的**变量代换法（雅可比行列式法）**。

设 (X, Y) 是二维连续型随机变量，联合密度为 $f_{X,Y}(x, y)$。现有两个函数

$$U = g_1(X, Y), \qquad V = g_2(X, Y),$$

我们想求新的二维随机变量 (U, V) 的联合密度 $f_{U,V}(u, v)$。

假设映射 $(x, y) \mapsto (u, v)$ 是一一对应的（或在支撑区域内分段一一对应），且存在连续偏导数，其逆映射为

$$x = h_1(u, v), \qquad y = h_2(u, v).$$

定义**雅可比行列式（Jacobian determinant）**为：

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \begin{vmatrix} \dfrac{\partial x}{\partial u} & \dfrac{\partial x}{\partial v} \\ \dfrac{\partial y}{\partial u} & \dfrac{\partial y}{\partial v} \end{vmatrix}.$$

则 (U, V) 的联合密度为：

$$f_{U,V}(u, v) = f_{X,Y}\big(h_1(u, v), h_2(u, v)\big) \cdot |J|.$$

如果只是为了求 $U = g_1(X, Y)$ 的一维分布，我们可以引入一个辅助变量 V（通常令 $V = X$ 或 $V = Y$），求出 (U, V) 的联合密度后，再对 v 积分（即求边缘密度）：

$$f_U(u) = \int_{-\infty}^{+\infty} f_{U,V}(u, v)\, dv.$$

例 3.28 (雅可比法：求两个随机变量之和的分布)**.** 设 (X,Y) 的联合密度为 $f_{X,Y}(x,y)$。求 $Z=X+Y$ 的密度函数 $f_Z(z)$。

解. 引入辅助变量 $W=X$，考虑变换

$$Z=X+Y,\qquad W=X.$$

求逆映射，可得：

$$X=W,\qquad Y=Z-W.$$

计算雅可比行列式：

$$J=\frac{\partial(x,y)}{\partial(z,w)}=\begin{vmatrix}\dfrac{\partial x}{\partial z} & \dfrac{\partial x}{\partial w}\\ \dfrac{\partial y}{\partial z} & \dfrac{\partial y}{\partial w}\end{vmatrix}=\begin{vmatrix}0 & 1\\ 1 & -1\end{vmatrix}=0\cdot(-1)-1\cdot 1=-1.$$

因此 $|J|=|-1|=1$。

由变换法公式，(Z,W) 的联合密度为：

$$f_{Z,W}(z,w)=f_{X,Y}(w,z-w)\cdot 1=f_{X,Y}(w,z-w).$$

为了求 Z 的边缘密度，对 w 从 $-\infty$ 到 $+\infty$ 积分：

$$f_Z(z)=\int_{-\infty}^{+\infty}f_{Z,W}(z,w)\,dw=\int_{-\infty}^{+\infty}f_{X,Y}(w,z-w)\,dw.$$

将积分变量 w 重新记为 x，即得我们熟知的卷积公式：

$$f_Z(z)=\int_{-\infty}^{+\infty}f_{X,Y}(x,z-x)\,dx.$$

□

例 3.29 (雅可比法：求两个随机变量之商的分布)**.** 设 (X,Y) 的联合密度为 $f_{X,Y}(x,y)$，且 $Y>0$。求 $Z=\dfrac{X}{Y}$ 的密度。

解. 引入辅助变量 $W=Y$，考虑变换

$$Z=\frac{X}{Y},\qquad W=Y.$$

求逆映射，可得：

$$X=ZW,\qquad Y=W.$$

计算雅可比行列式：

$$J=\frac{\partial(x,y)}{\partial(z,w)}=\begin{vmatrix}\dfrac{\partial x}{\partial z} & \dfrac{\partial x}{\partial w}\\ \dfrac{\partial y}{\partial z} & \dfrac{\partial y}{\partial w}\end{vmatrix}=\begin{vmatrix}w & z\\ 0 & 1\end{vmatrix}=w\cdot 1-z\cdot 0=w.$$

因为 $W=Y>0$，所以 $|J|=w$。

(Z,W) 的联合密度为：

$$f_{Z,W}(z,w) = f_{X,Y}(zw,w)\cdot|w| = f_{X,Y}(zw,w)\cdot w.$$

对 w 积分，得到 Z 的边缘密度：

$$f_Z(z) = \int_0^{+\infty} w\cdot f_{X,Y}(zw,w)\,dw.$$

若 X 与 Y 相互独立，则 $f_{X,Y}(x,y) = f_X(x)f_Y(y)$，此时：

$$f_Z(z) = \int_0^{+\infty} w f_X(zw) f_Y(w)\,dw.$$

这与我们之前用分布函数法得出的公式是完全一致的。 □

注 3.27 (推广到 n 维)**.** 雅可比行列式法可以极其自然地推广到 n 维。设 n 维随机向量 $\mathbf{X} = (X_1, X_2, \ldots, X_n)$ 有联合密度 $f_{\mathbf{X}}(\mathbf{x})$。设 $\mathbf{U} = \mathbf{g}(\mathbf{X})$，即

$$U_1 = g_1(X_1,\ldots,X_n),\quad \ldots,\quad U_n = g_n(X_1,\ldots,X_n).$$

如果该映射可逆，即 $X_i = h_i(U_1,\ldots,U_n)$，则 $\mathbf{U}$ 的联合密度为

$$f_{\mathbf{U}}(\mathbf{u}) = f_{\mathbf{X}}\big(h_1(\mathbf{u}),\ldots,h_n(\mathbf{u})\big)\cdot|J|,$$

其中雅可比行列式为：

$$J = \frac{\partial(x_1,\ldots,x_n)}{\partial(u_1,\ldots,u_n)} = \begin{vmatrix} \dfrac{\partial x_1}{\partial u_1} & \cdots & \dfrac{\partial x_1}{\partial u_n} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial x_n}{\partial u_1} & \cdots & \dfrac{\partial x_n}{\partial u_n} \end{vmatrix}.$$

在统计推断中，当我们寻找极大似然估计量时，由于 MLE 具有**不变性**，即如果 $\hat\theta$ 是 θ 的 MLE，那么 $g(\hat\theta)$ 也是 $g(\theta)$ 的 MLE。这背后其实隐藏着变量代换和雅可比矩阵在局部极值点处的作用。

小结

注 3.28. 求两个随机变量函数的分布，常用方法有：

- **离散型**：直接对满足 $g(x_i,y_j) = z_k$ 的概率求和；
- **连续型**：用分布函数法，先求 $F_Z(z) = P(g(X,Y)\le z)$，再对 z 求导；
- **独立情形下的常用公式**：
  - 和的密度（卷积）：$f_{X+Y}(z) = \displaystyle\int_{-\infty}^{+\infty} f_X(x)f_Y(z-x)\,dx$；
  - 积的密度：$f_{XY}(z) = \displaystyle\int_{-\infty}^{+\infty} f_X(u)f_Y\left(\frac{z}{u}\right)\frac{1}{|u|}\,du$；
  - 商的密度：$f_{X/Y}(z) = \displaystyle\int_{-\infty}^{+\infty} |y| f_X(zy)f_Y(y)\,dy$；
  - 最大值分布：$F_{\max}(z) = F_X(z)F_Y(z)$；
  - 最小值分布：$F_{\min}(z) = 1-[1-F_X(z)][1-F_Y(z)]$。

3.5 多维随机变量

前面我们详细讨论了二维随机变量的分布、边缘分布、条件分布、独立性以及函数的分布。在实际问题中，我们常常需要同时研究三个或更多个随机变量，例如一个物体的长、宽、高，或者一段时间内某地区的温度、湿度、风速等。这就需要把二维随机变量的概念推广到 n 维。

本节重点介绍 n 维随机变量的基本概念与主要结果。由于大多数定义和性质都是二维情形的自然推广，我们将直接给出结论，不再重复繁琐的证明。

3.5.1 n 维随机变量及其分布函数

定义 3.12 (n 维随机变量)**.** 设 $X_1, X_2, \ldots, X_n$ 是定义在同一样本空间 Ω 上的 n 个随机变量，称有序组

$$(X_1, X_2, \ldots, X_n)$$

为n **维随机变量**，也称n **维随机向量**。

定义 3.13 (联合分布函数)**.** 设 $(X_1, \ldots, X_n)$ 是 n 维随机变量。对任意实数 $x_1, x_2, \ldots, x_n$，称

$$F(x_1, x_2, \ldots, x_n) = P(X_1 \le x_1,\ X_2 \le x_2,\ \ldots,\ X_n \le x_n)$$

为 $(X_1, \ldots, X_n)$ 的**联合分布函数**。

与二维情形类似，n 维联合分布函数 $F(x_1, \ldots, x_n)$ 具有单调性、有界性、右连续性。此外，它满足 n 维的矩形概率公式，即当 $a_i < b_i$（$i = 1, \ldots, n$）时，

$$P(a_1 < X_1 \le b_1,\ \ldots,\ a_n < X_n \le b_n) = \Delta_{a_1}^{b_1} \cdots \Delta_{a_n}^{b_n} F \ge 0,$$

其中 $\Delta_{a_i}^{b_i} F = F(\ldots, b_i, \ldots) - F(\ldots, a_i, \ldots)$。

3.5.2 n 维离散型随机变量

定义 3.14 (n 维离散型随机变量)**.** 设 n 维随机变量 $(X_1, \ldots, X_n)$ 的每个分量都是离散型的，则称其为n **维离散型随机变量**。

设其所有可能取值为 $(x_{1i_1}, x_{2i_2}, \ldots, x_{ni_n})$，则称

$$p_{i_1 i_2 \ldots i_n} = P(X_1 = x_{1i_1},\ X_2 = x_{2i_2},\ \ldots,\ X_n = x_{ni_n})$$

为 $(X_1, \ldots, X_n)$ 的**联合分布律**。

联合分布律满足非负性和规范性：

$$p_{i_1 i_2 \ldots i_n} \ge 0, \qquad \sum_{i_1} \sum_{i_2} \cdots \sum_{i_n} p_{i_1 i_2 \ldots i_n} = 1.$$

3.5.3 n 维连续型随机变量

定义 3.15 (n 维连续型随机变量)**.** 设 n 维随机变量 $(X_1,\dots,X_n)$ 的联合分布函数为 $F(x_1,\dots,x_n)$。若存在非负可积函数 $f(x_1,\dots,x_n)$，使得对任意实数 $x_1,\dots,x_n$，都有

$$F(x_1,\dots,x_n)=\int_{-\infty}^{x_1}\cdots\int_{-\infty}^{x_n} f(u_1,\dots,u_n)\,du_n\cdots du_1,$$

则称其为n **维连续型随机变量**，并称 $f(x_1,\dots,x_n)$ 为**联合概率密度函数**。

联合密度函数满足：

(1) **非负性**：$f(x_1,\dots,x_n)\geq 0$；

(2) **规范性**：

$$\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} f(x_1,\dots,x_n)\,dx_1\cdots dx_n=1;$$

(3) **区域概率**：对 $\mathbb{R}^n$ 中的任意区域 G，

$$P\big((X_1,\dots,X_n)\in G\big)=\iint\cdots\int_G f(x_1,\dots,x_n)\,dx_1\cdots dx_n.$$

3.5.4 边缘分布

在 n 维随机变量中，如果我们只关心其中 k 个分量（$k<n$）的分布，就需要求边缘分布。

定义 3.16 (边缘分布函数)**.** 设 n 维随机变量 $(X_1,X_2,\dots,X_n)$ 的联合分布函数为 $F(x_1,x_2,\dots,x_n)$。

单个分量的边缘分布：如果只关心其中一个分量，比如 X_1 的分布，就需要把其余 $n-1$ 个变量的限制解除（即让它们趋于 $+\infty$）。此时称

$$F_{X_1}(x_1)=P(X_1\leq x_1)$$

为 X_1 的**边缘分布函数**。由联合分布函数的性质，它可以通过在联合分布函数中令其它变量趋于 $+\infty$ 得到：

$$F_{X_1}(x_1)=F(x_1,+\infty,\dots,+\infty)=\lim_{x_2\to+\infty}\cdots\lim_{x_n\to+\infty}F(x_1,x_2,\dots,x_n).$$

同理，任意一个分量 X_i 的边缘分布函数为

$$F_{X_i}(x_i)=F(+\infty,\dots,+\infty,x_i,+\infty,\dots,+\infty).$$

多个分量的边缘分布：更一般地，如果只关心其中某 k 个分量（$k<n$），例如前 k 个分量 $(X_1,\dots,X_k)$ 的分布，只需让剩余的 $n-k$ 个分量 $X_{k+1},\dots,X_n$ 都趋于 $+\infty$。此时称

$$F_{X_1,\dots,X_k}(x_1,\dots,x_k)=P(X_1\leq x_1,\dots,X_k\leq x_k)$$

为 $(X_1,\dots,X_k)$ 的**边缘分布函数**，其表达式为

$$F_{X_1,\dots,X_k}(x_1,\dots,x_k)=F(x_1,\dots,x_k,+\infty,\dots,+\infty)=\lim_{x_{k+1}\to+\infty}\cdots\lim_{x_n\to+\infty}F(x_1,\dots,x_k,x_{k+1},\dots,x_n).$$

注 3.29. 边缘分布刻画了多维随机变量中"局部"的概率规律。它的物理意义是：**我们不再关心其余变量的具体取值，因此让它们取遍所有可能的值（趋于 $+\infty$）**，从而把这部分随机性"边缘化"掉。

需要指出的是，联合分布可以唯一确定所有的边缘分布；但反过来，已知边缘分布一般**不能**唯一确定联合分布（除非已知变量之间相互独立）。

离散型情形

如果 $(X_1,\dots,X_n)$ 是离散型随机变量，联合分布律为 $p_{i_1\dots i_n}$，则 X_1 的边缘分布律为对其它下标求和：

$$p_{1i_1} = P(X_1 = x_{1i_1}) = \sum_{i_2}\cdots\sum_{i_n} p_{i_1 i_2\dots i_n}.$$

即"固定一个下标，对其它所有下标求和"。

连续型情形

如果 $(X_1,\dots,X_n)$ 是连续型随机变量，联合密度为 $f(x_1,\dots,x_n)$，则 X_1 的边缘密度为对其余变量积分：

$$f_{X_1}(x_1) = \int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} f(x_1,x_2,\dots,x_n)\,dx_2\cdots dx_n.$$

类似地，前 k 个分量的边缘密度是对后 $n-k$ 个变量积分。

3.5.5 独立性

定义 3.17 (n 个随机变量的独立性)**.** 设 $X_1,X_2,\dots,X_n$ 是 n 个随机变量，$F(x_1,\dots,x_n)$ 为其联合分布函数，$F_{X_i}(x_i)$ 为各自的边缘分布函数。若对任意实数 $x_1,\dots,x_n$，都有

$$F(x_1,x_2,\dots,x_n) = F_{X_1}(x_1)\,F_{X_2}(x_2)\cdots F_{X_n}(x_n),$$

则称 $X_1,X_2,\dots,X_n$ **相互独立**。

- **离散型**：相互独立当且仅当对一切下标，

$$p_{i_1 i_2\dots i_n} = p_{1i_1}\,p_{2i_2}\cdots p_{ni_n}.$$

- **连续型**：相互独立当且仅当对一切 $x_1,\dots,x_n$，

$$f(x_1,\dots,x_n) = f_{X_1}(x_1)\,f_{X_2}(x_2)\cdots f_{X_n}(x_n).$$

- **快速判定法**：若联合密度的非零区域是 n 维"长方体"（即各变量取值相互独立，不构成斜交或曲面边界），且密度函数可分离为各单变量函数之积，则各分量相互独立。

3.5.6 n 维随机变量的函数

在实际问题中，我们常需要由已知的 n 维随机变量 $(X_1, X_2, \ldots, X_n)$ 构造新的随机变量 $Z = g(X_1, X_2, \ldots, X_n)$，并求 Z 的分布律或密度函数。其基本思想与二维情形一致，但计算更为复杂。

离散型情形

若 $(X_1, \ldots, X_n)$ 是 n 维离散型随机变量，联合分布律为

$$p_{i_1 i_2 \ldots i_n} = P(X_1 = x_{1i_1}, \ldots, X_n = x_{ni_n}),$$

则 $Z = g(X_1, \ldots, X_n)$ 的分布律为

$$P(Z = z_k) = \sum_{g(x_{1i_1}, \ldots, x_{ni_n}) = z_k} p_{i_1 i_2 \ldots i_n}.$$

即把所有使得函数值等于 z_k 的联合概率相加。

连续型情形

对于 n 维连续型随机变量，求 $Z = g(X_1, \ldots, X_n)$ 的密度，最通用的方法是**分布函数法**：

(1) 写出 Z 的分布函数 $F_Z(z) = P(g(X_1, \ldots, X_n) \le z)$；

(2) 在 $\mathbb{R}^n$ 中找出区域 $D_z = \{(x_1, \ldots, x_n) : g(x_1, \ldots, x_n) \le z\}$；

(3) 将概率转化为联合密度在区域 D_z 上的多重积分；

(4) 对 z 求导，得到密度 $f_Z(z) = F_Z'(z)$。

注 3.30 (极大似然估计中的常用统计量)**.** 在数理统计中，最常用的 n 维随机变量的函数是由样本构成的**统计量**，例如：

- **样本均值**：$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$；
- **样本方差**：$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \bar{X})^2$；
- **最大值与最小值**：$X_{(n)} = \max(X_1, \ldots, X_n)$，$X_{(1)} = \min(X_1, \ldots, X_n)$。

几个重要结论

由于一般的 n 维函数分布计算十分繁琐，下面直接给出几个在概率论与数理统计中极其重要的 n 维函数分布结论。假设以下涉及的 $X_1, \ldots, X_n$ 均相互独立。

命题 3.4 (独立随机变量和的分布)**.** *若 $X_1, X_2, \ldots, X_n$ 相互独立，且均服从正态分布 $X_i \sim N(\mu_i, \sigma_i^2)$，则它们的和 $Z = X_1 + \cdots + X_n$ 服从正态分布：*

$$Z \sim N\left(\sum_{i=1}^{n} \mu_i,\ \sum_{i=1}^{n} \sigma_i^2 \right).$$

命题 3.5 (最大值与最小值的分布)**.** *若 $X_1, \dots, X_n$ 相互独立，且分布函数均为 $F(x)$，则最大值 $M = \max(X_1, \dots, X_n)$ 和最小值 $N = \min(X_1, \dots, X_n)$ 的分布函数分别为：*

$$F_M(z) = [F(z)]^n, \qquad F_N(z) = 1 - [1 - F(z)]^n.$$

特别地，若 $X_i \sim \mathrm{Exp}(\lambda)$，则 $N \sim \mathrm{Exp}(n\lambda)$。

命题 3.6 (χ^2 分布的形成)**.** *设 $X_1, X_2, \dots, X_n$ 相互独立，且均服从标准正态分布 $N(0,1)$。则它们的平方和*

$$\chi^2 = X_1^2 + X_2^2 + \cdots + X_n^2$$

*服从自由度为 n 的**卡方分布**，记作 $\chi^2 \sim \chi^2(n)$。其密度函数为*

$$f_{\chi^2}(x) = \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}, \qquad x > 0.$$

注 3.31. 上述结论（特别是正态分布之和与 χ^2 分布）是后续学习**抽样分布**（如 t 分布、F 分布）的基础。读者只需了解这些常见函数的分布结果，具体的多重积分推导在此不作深入要求。

小结

注 3.32. 本节将二维随机变量的概念推广到了 n 维：

- **联合分布**：用 n 元分布函数或联合密度刻画，具有单调性、有界性、右连续性和多维矩形概率公式；
- **边缘分布**：通过令无关变量趋于无穷（离散则求和，连续则积分）得到。联合分布可以唯一确定边缘分布，但反之一般不成立；
- **独立性**：要求联合分布等于各边缘分布之积，即 $F(x_1, \dots, x_n) = \prod_{i=1}^n F_{X_i}(x_i)$；
- **随机变量的函数**：求 n 维随机变量函数的分布，依然采用“分布函数法”，特别地，独立正态随机变量之和仍服从正态分布，多个独立标准正态变量的平方和服从卡方分布；

这些结论与二维情形完全平行，读者只需注意符号和求和/积分维数的变化，并体会“多维向量”与“单个变量”在计算上的统一性。